

**UNIVERSIDADE FEDERAL DE MINAS GERAIS**  
**Instituto de Ciências Exatas**  
**Programa de Pós-Graduação em Ciência da Computação**

Felipe Glicério Gomes Marcelino

**Deteção de Glaucoma Através de Aprendizado de Máquina**

Belo Horizonte  
2022

Felipe Glicério Gomes Marcelino

## **Deteção de Glaucoma Através de Aprendizado de Máquina**

**Versão Final**

Dissertação apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Minas Gerais, como requisito parcial à obtenção do título de Mestre em Ciência da Computação.

Orientador: Adriano Alonso Veloso

Belo Horizonte  
2022

## [Ficha Catalográfica em formato PDF]

A ficha catalográfica será fornecida pela biblioteca. Ela deve estar em formato PDF e deve ser passada como argumento do comando `ppgccufmg` no arquivo principal `.tex`, conforme o exemplo abaixo:

```
\ppgccufmg{  
    ...  
    fichacatalografica={ficha.pdf}  
}
```

## [Folha de Aprovação em formato PDF]

A folha de aprovação deve estar em formato PDF e deve ser passada como argumento do comando `ppgccufmg` no arquivo principal `.tex`, conforme o exemplo abaixo:

```
\ppgccufmg{  
    ...  
    folhadeaprovacao={folha.pdf}  
}
```

*Dedico este trabalho aos meus pais falecidos, a quem agradeço  
as bases que deram para me tornar a pessoa que sou hoje.*

# Agradecimentos

Agradeço primeiramente a minha esposa Isabel que sempre me deu suporte, apoio e companheirismo durante toda minha caminhada acadêmica. Agradeço a minhas tias com quem convivi durante toda minha graduação e o começo do meu mestrado e sempre valorizou meu esforço com os estudos. Agradeço ao meu orientador Adriano que me ajudou e me proporcionou oportunidades durante todo o trajeto. Agradeço ao laboratório Laboratório de Inteligência Artificial da UFMG (LIA) por ter sido um espaço de aprendizado e experiências ilustres com colegas e amigos, e por fim agradeço a Universidade Federal de Minas Gerais pela sua excelência no ensino e pesquisa.



# Resumo

O glaucoma é uma condição capaz de afetar os olhos, causando danos ao nervo ocular e fazendo com que o paciente tenha seu campo visual reduzido aos poucos. Se o glaucoma não for tratado, o paciente pode ser levado à cegueira. Entre os sintomas estão:

- Perda gradual da visão lateral
- Visão embaçada
- Olhos vermelhos e inchados
- Sensibilidade a luz

A doença é bastante comum para pessoas acima de 40 anos, portanto, é recomendável uma visita anual ao médico oftalmologista com o intuito de descartar a presença da doença e que esta se torne intratável. Entre os exames realizados estão imagem do olho e o Tomografia de Coerência Óptica.

Dado isso, utilizando dados de imagens e clínicos, algoritmos de aprendizado de máquina, do inglês *Machine Learning*, vem sendo utilizados para dar suporte aos profissionais com diagnósticos automatizados com rapidez e eficiência. Somado isso, é possível que os diagnósticos tragam uma explicabilidade, dando ainda mais suporte e recursos que o profissional tenha uma decisão mais assertiva quanto ao tratamento.

Diante do exposto, este projeto tem como intuito utilizar modelos de aprendizado de máquina para a detecção do glaucoma. Além disso, o projeto também apresenta múltiplas possibilidades de modelagem do problema, utilizando diferentes estratégias e seus benefícios. Ao final do projeto, não somente é explicitado o desempenho do modelo como também sua eficiência computacional e a explicabilidade por trás das respostas dos modelos de aprendizado de máquina.

**Palavras-chave:** Aprendizado de Máquina. Computação Visual. Modelagem. Glaucoma. Diagnóstico. Explicabilidade.

# Abstract

Glaucoma is a condition that can affect the eyes, causing damage to the ocular nerve and causing the patient's visual field to decrease slowly. If glaucoma is left untreated, the patient can be driven to blindness. Symptoms include:

- Gradual loss of side vision
- blurred vision
- red and swollen eyes
- Sensitivity to light

The disease is quite common for people over 40, so an annual visit to an eye doctor is recommended to detect the presence of the disease and in a positive case, being able to make treatment suitable for the patient to avoid the advance of the disease. Among the tests performed are fundus exams and Optical coherence tomography.

Given this, using the fundus image and clinical data, machine-learning algorithms support professionals with quick, efficient, and automated diagnoses. In addition, the diagnoses may bring an explicability, giving even more support and resources so that the professional has a bold and more fearless decision about the treatment.

Given the above, this project aims to use machine learning models to detect glaucoma. In addition, the project also presents multiple possibilities for modeling the problem, using different strategies and their benefits. Furthermore, this project explains model performance, its computational efficiency, and the explainability behind the answers of the machine learning models.

**Keywords:** Machine Learning. Computer Vision. Modeling. Glaucoma. Diagnostic. Explainability

# Lista de Figuras

|      |                                                                                                                                                                                                                                                                                                                                                                                       |    |
|------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1.1  | Exemplos de imagem do fundo do olho com presença e ausência de glaucoma.                                                                                                                                                                                                                                                                                                              | 15 |
| 1.2  | Exemplo de exame OCT, sendo o olho direito (OD) com a presença de glaucoma e o esquerdo(OS) em estado saudável . . . . .                                                                                                                                                                                                                                                              | 16 |
| 3.1  | Corpo de um modelo RegNet contendo 4 (Fixo) estágios. Cada estágio contém número X de blocos. . . . .                                                                                                                                                                                                                                                                                 | 29 |
| 3.2  | Exemplo de um bloco <b>X</b> baseado em uma rede residual. . . . .                                                                                                                                                                                                                                                                                                                    | 29 |
| 3.3  | A imagem da esquerda mostra os <i>Design Spaces</i> A, B, e C, sendo o C mais restritivo entre eles. A imagem da direita mostra a distribuição de erro de cada desses espaços, sendo o C aquele que possui melhor desempenho entre eles.                                                                                                                                              | 30 |
| 3.4  | Uma rede neural MLP, com 3 camadas. Uma de entrada com 3 neurônios, uma camada intermediária com 4 neurônios e uma de saída com dois neurônios. . .                                                                                                                                                                                                                                   | 32 |
| 3.5  | Uma imagem representando o problema de sobreajuste e subajuste. . . . .                                                                                                                                                                                                                                                                                                               | 35 |
| 3.6  | Exemplo de uma convolução com filtro 5×5. Cada quadrado com este tamanho produz um número com utilizando operações matemáticas. Em seguida, o quadrado é deslocado para o lado ou para baixo e um novo filtro é formado. .                                                                                                                                                            | 36 |
| 3.7  | Arquitura de modelos. O <i>backbone</i> pode ser um dos modelos citados anteriormente (RegNet, ResNet, Inception e etc), e o <i>classifier</i> é uma rede neural de múltiplas camadas (MLP), assim como o modelo <i>MLP</i> que recebe os dados tabelados e também o que faz operação de concatenar ( <i>concat</i> ) juntando todas as saídas e passar para o classificador. . . . . | 37 |
| 3.8  | AUC e curva ROC. . . . .                                                                                                                                                                                                                                                                                                                                                              | 39 |
| 3.9  | Imagem contendo ilustrando a validação cruzada. Cada parte assume o papel de teste uma vez e treino K-1 vezes. . . . .                                                                                                                                                                                                                                                                | 42 |
| 3.10 | Gráfico sumarizado para o dataset Boston Housing ordenado pelas características mais importantes do modelo. . . . .                                                                                                                                                                                                                                                                   | 44 |
| 3.11 | Explicação de uma imagem utilizando SHAP. Os pontos vermelhos e azul mostram onde o modelo julgou como parte importante para a imagem. Seguindo a mesma lógica do ??, pontos vermelhos aumenta a probabilidade na saída do modelo, enquanto pontos azuis diminuem. . . . .                                                                                                            | 45 |
| 4.1  | Duas imagens do fundo do olho com distâncias diferentes . . . . .                                                                                                                                                                                                                                                                                                                     | 47 |
| 4.2  | Contagem de casos de glaucoma por gênero e por olhos . . . . .                                                                                                                                                                                                                                                                                                                        | 49 |
| 4.3  | Distribuição do Glaucoma por variável . . . . .                                                                                                                                                                                                                                                                                                                                       | 50 |

---

|      |                                                                                                                                                                                                       |    |
|------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.4  | Boxplot do Glaucoma por variável. . . . .                                                                                                                                                             | 51 |
| 4.5  | Correlação absoluta das variáveis . . . . .                                                                                                                                                           | 52 |
| 4.6  | Correlação das características criadas pela operação razão. . . . .                                                                                                                                   | 54 |
| 5.1  | <i>Learning Rate Decay</i> aplicado a modelos visuais. . . . .                                                                                                                                        | 57 |
| 6.1  | Avaliação geral dos modelos divididos em uso de duas imagens e presença das métricas do OCT. O gráfico violino mostra a distribuição dos valores máximos atingidos por cada <i>backbone</i> . . . . . | 60 |
| 6.2  | Comparação das estatísticas da métrica AUC. O eixo y é o melhor resultado do modelo durante todas as épocas, enquanto o eixo x é a média do modelo durante o treinamento. . . . .                     | 61 |
| 6.3  | Distribuição dos desempenhos separado por arquiteturas de modelos . . . . .                                                                                                                           | 63 |
| 6.4  | Comportamento da função de custo durante as épocas de treinamento. O gráfico mostra um valor médio e um intervalo de confiança de 0.95 . . . . .                                                      | 64 |
| 6.5  | Comparação do uso do <i>Learning Rate Decay</i> nos melhores modelos. Os melhores modelos da etapa anterior foram re-executados utilizando validação cruzada para uma comparação justa. . . . .       | 65 |
| 6.6  | Imagem com explicabilidade do modelo. Sendo o da esquerda o modelo utilizando somente uma imagem e o da direita utilizando duas imagens. Foto distante. . . . .                                       | 70 |
| 6.7  | Imagem com explicabilidade do modelo. Sendo o da esquerda o modelo utilizando somente uma imagem e o da direita utilizando duas imagens. Foto próxima. . . . .                                        | 70 |
| 6.8  | Importância das características calculada utilizando o melhor modelo usando OCT ( $AUC = 0.99$ ). . . . .                                                                                             | 72 |
| 6.9  | Mapa de calor importância das características para os backbones presentes na etapa de validação cruzada. As características estão ordenada de acordo com sua importância geral. . . . .               | 73 |
| 6.10 | Gráfico de cascata para casos com presença de glaucoma. . . . .                                                                                                                                       | 74 |
| 6.11 | Gráfico de cascata para casos com ausência de glaucoma. . . . .                                                                                                                                       | 75 |

# Lista de Tabelas

|     |                                                                                                                                                                                                                                                                                                                                           |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Tabela de restrições dos modelos até chegar no modelo RegNet (?). O índice $i$ é o estágio, fixado em 4. O $b_i$ representa razão do gargalo, $g_i$ representa o total de canais da convolução, $d_i$ representa o total de blocos e o $w_i$ representa o tamanho do bloco. . . . .                                                       | 30 |
| 4.1 | Tabela contendo sumarização dos dados utilizando as estatísticas: máximo, mínimo, média, desvio e contagem. . . . .                                                                                                                                                                                                                       | 52 |
| 5.1 | Versões dos modelos visuais utilizados como Backbones e o total de parâmetros de cada um. O modelo ViT é o que possui maior número de parâmetros, aproximadamente 86 milhões, enquanto o modelo Shuffle possui somente 2.5 milhões. . . . .                                                                                               | 58 |
| 6.1 | Tabela contendo os resultados quanto a métrica AUC separado por backbone. Todos os modelos parecem possuir resultados próximos. . . . .                                                                                                                                                                                                   | 61 |
| 6.2 | Tabela contendo os resultados separado por dois grupos: OCT e Dual Image. A tabela mostra que Dual Image não trás benefícios, enquanto a utilização do exame OCT agrega performance aos resultados . . . . .                                                                                                                              | 62 |
| 6.3 | Tabela com os resultados comparando a utilização da técnica LDR na validação cruzada. Foi calculado uma média e desvio padrão entre os <i>backbones</i> dos melhores modelos. Os <i>backbones</i> com desvio padrão igual a 0 significa que só houve uma arquitetura de modelo entre os modelos utilizando este <i>backbone</i> . . . . . | 66 |
| 6.4 | Tabela contendo desempenho do modelo. A memória é medida em megabytes (mb) e o tempo de inferência em milisegundos (ms). . . . .                                                                                                                                                                                                          | 67 |
| 6.5 | Experimentos utilizando diferentes parâmetros de <i>RandAugment</i> (Coluna <i>OP</i> ). O número na coluna representa o número de operações seguidas aplicada na imagem. . . . .                                                                                                                                                         | 68 |

# Sumário

|          |                                                                      |           |
|----------|----------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                                    | <b>14</b> |
| 1.1      | Aprendizado de máquina aplicado a diagnósticos com imagens . . . . . | 17        |
| 1.2      | Motivação . . . . .                                                  | 18        |
| 1.2.1    | Flexibilidade . . . . .                                              | 18        |
| 1.2.2    | Explicabilidade . . . . .                                            | 18        |
| 1.3      | Declaração de Tese . . . . .                                         | 19        |
| 1.4      | Contribuição . . . . .                                               | 19        |
| 1.5      | Organização . . . . .                                                | 20        |
| <b>2</b> | <b>Referências Teóricas</b>                                          | <b>21</b> |
| 2.1      | Aplicações Gerais . . . . .                                          | 21        |
| 2.2      | Aplicações de Glaucoma . . . . .                                     | 22        |
| <b>3</b> | <b>Metodologia e Ferramental Teórico</b>                             | <b>26</b> |
| 3.1      | Modelos . . . . .                                                    | 26        |
| 3.2      | RegNet: O modelo mais flexível para visão computacional . . . . .    | 27        |
| 3.2.1    | Parâmetros . . . . .                                                 | 28        |
| 3.2.2    | Estrutura . . . . .                                                  | 28        |
| 3.3      | Conceitos . . . . .                                                  | 31        |
| 3.3.1    | Camadas . . . . .                                                    | 31        |
| 3.3.2    | Pesos ou Parâmetros . . . . .                                        | 31        |
| 3.3.3    | Taxa de aprendizado . . . . .                                        | 32        |
| 3.3.4    | Treino, Teste e Inferência . . . . .                                 | 33        |
| 3.3.5    | Batch e Época . . . . .                                              | 33        |
| 3.3.6    | Função de perda . . . . .                                            | 34        |
| 3.3.7    | Otimizadores . . . . .                                               | 34        |
| 3.3.8    | Hiperparâmetros . . . . .                                            | 34        |
| 3.3.9    | Sobrajuste . . . . .                                                 | 35        |
| 3.3.10   | Convolução . . . . .                                                 | 36        |
| 3.4      | Arquiteturas . . . . .                                               | 36        |
| 3.5      | Métricas de Avaliação . . . . .                                      | 38        |
| 3.6      | RandAugment . . . . .                                                | 40        |
| 3.7      | Treinamento e Avaliação dos Modelos . . . . .                        | 41        |

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| 3.8      | Explicabilidade: SHAP . . . . .                          | 43        |
| <b>4</b> | <b>Sumário e Preprocessamento dos dados</b>              | <b>46</b> |
| 4.1      | Sumário dos dados . . . . .                              | 46        |
| 4.2      | Limpeza . . . . .                                        | 47        |
| 4.3      | Exploração . . . . .                                     | 48        |
| 4.4      | Engenharia de características e Normalização . . . . .   | 53        |
| <b>5</b> | <b>Experimentos</b>                                      | <b>55</b> |
| 5.1      | Setup . . . . .                                          | 55        |
| 5.2      | <i>Fine-Tuning</i> . . . . .                             | 55        |
| 5.3      | <i>Learning Rate Decay</i> . . . . .                     | 56        |
| 5.4      | Experimentação . . . . .                                 | 57        |
| <b>6</b> | <b>Resultados</b>                                        | <b>59</b> |
| 6.1      | Desempenho Geral . . . . .                               | 59        |
| 6.2      | Validação Cruzada e <i>Learning Rate Decay</i> . . . . . | 64        |
| 6.2.1    | <i>RandAugment</i> . . . . .                             | 67        |
| 6.3      | Explicabilidade . . . . .                                | 69        |
| 6.3.1    | Explicabilidade Visual . . . . .                         | 69        |
| 6.3.2    | Importância das Características . . . . .                | 71        |
| 6.3.3    | Análise de casos individuais . . . . .                   | 74        |
| <b>7</b> | <b>Conclusão</b>                                         | <b>76</b> |
|          | <b>Apêndice A Validação Cruzada Resultados</b>           | <b>77</b> |

# Capítulo 1

## Introdução

Glaucoma é uma doença neuropática progressiva que resulta na mudanças de características do disco ótico e causa danos irreversíveis nas fibras nervosas (?). Apesar de ser irreversível, é possível que com tratamento a evolução da doença seja mais lenta (?). Uma das formas de diagnóstico do glaucoma é feito através de imagens que requer análise e interpretação de um especialista da área. Dado que o número de pessoas com a doença aumentará em 111,8 milhões até 2040 (?), métodos utilizando inteligência artificial vem sendo utilizados para automatizar o processo (?).

Um dos grandes desafios quanto ao diagnóstico do glaucoma são os aspectos assintomáticos da doença antes dos estágios severos. Dado isso, o número de pessoas não diagnosticadas corretamente é grande (?). Atualmente, um dos recursos mais utilizados para detectar a doença é a imagem da retina ou imagem do fundo do olho. Com a imagem do fundo do olho é possível verificar o o formato e o tamanho do disco óptico, já que este sofre alterações na presença da doença (?). Algoritmos de aprendizado por máquina (*machine learning*) são utilizados juntos com imagens de retinas para identificar a doença. Estes algoritmos podem utilizar técnicas de aprendizado estatísticos ou aprendizado profundo (?).


Aprendizado de máquina vem se tornando um dos desenvolvimentos mais importantes no campo de ciência e tecnologia, principalmente na medicina. Classificação é uma das principais técnicas de aprendizado de máquina utilizado no campo médico. Isto porque porque utilizando modelos classificadores é possível prever diagnósticos de doenças utilizando dados médicos clínicos e exames de imagens. Desta forma, classificação se torna uma técnica inerente para detecção de glaucoma. No futuro, aprendizado de máquina será essencial não somente para diagnosticar mas também para tratar o glaucoma.

O fundoscopia do olho possibilita que especialista consiga identificar todas as estruturas oculares necessárias para identificar o glaucoma, como por exemplo: disco óptico (DO), copo óptico (CO), mácula lútea, fóvea e os vasos sanguíneos (???). As maiores vantagens de se utilizar a imagem do fundo do olho são: Não é um processo invasivo, é seguro e ajuda na detecção de outras doenças.

O exame OCT para glaucoma é também indicado para diagnosticar e dar suporte na evolução dos tratamentos (médicos ou cirurgia). O OCT permite estudar a espessura da

camada de fibras nervosas da retina peri-papilares assim como a escavação do disco ótico. Existem diferentes aparelhos de OCT, que apresentam variadas velocidades e definições de imagem. De qualquer forma, o OCT fornece medições da espessura da fibras em diferentes regiões retina. Estas medições forçenem aos profissiona um grande número de informações, dando mais recurso para uma melhor avaliação do glaucoma.


Figura 1.1: Exemplos de imagem do fundo do olho com presença e ausência de glaucoma.



Fonte: [Nature, 2021](#)

A figura

Figura 1.2: Exemplo de exame OCT, sendo o olho direito (OD) com a presença de glaucoma e o esquerdo(OS) em estado saudável



A figura

Dado as características citadas acima, a imagem do fundo do olho e OCT são primordialmente utilizados por sistemas inteligentes. Tais sistemas, utilizando exames médicos, são capazes de trazer um diagnóstico e uma segunda opinião, dando suporte ao profissional da saúde. Sistemas inteligentes de diagnósticos são capazes de provê inter-

preações clínicas para auxiliar o profissional nas decisões de tratamento e diminuir as chances de ações prejudiciais ao paciente (??).

## 1.1 Aprendizado de máquina aplicado a diagnósticos com imagens

O desenvolvimento novas tecnologias envolvendo aprendizado de máquina vem mostrando grandes avanços, principalmente no campo médico. O envolvimento da inteligência artificial (IA) em outros campos, fez com que as aplicações de aprendizado de máquina seja interdisciplinar, adentrando soluções que envolve reconhecimento de voz, reconhecimento de objetos, predição de demanda, veículos autônomos e etc. Para a área médica, além do diagnóstico, é possível utilizar IA para descobrir novas drogas, melhorar a comunicação entre médico e paciente, transcrever documentos médicos, como por exemplo receita e também tratamento remoto dos pacientes.

O aprendizado da máquina é uma técnica que utiliza de dados (imagens, videos, áudio, clínicos e etc) para aprender e executar algum tipo de tarefa específica. Em alguns casos, a desempenho de uma IA pode ser melhor do que a do humano em algumas tarefas, como por exemplo na detecção de objetos (?), video games (?), imitação e estilo e arte (?) e em previsões de comportamento (?).

O artigo (?) traz um sumário de técnicas aplicadas no diagnóstico de glaucoma. Os autores coletam artigos durante o ano 2014 e 2019 em que existe um problema de classificação (presença ou ausência do glaucoma). Quanto aos métodos analisados eles se dividem em métodos que extraem as características da imagem e fazem redução de dimensão enquanto outros utilizamos modelos profundos como redes convolucionais (CNN)(?) para detecção direta da doença. A maior influência da escolha do método se resume ao número de dados disponíveis e o custo necessário para processar estas imagens.

## 1.2 Motivação

Este trabalho tem como objetivo criar um modelo de aprendizado de máquina que seja capaz de auxiliar no diagnóstico do glaucoma de forma eficiente explorando diferentes arquiteturas de modelos de aprendizado de máquina. Adicionado ao diagnóstico, também

trazer a explicabilidade do modelo quanto ao diagnóstico. Além disso, com a exploração de diferentes arquiteturas, é possível adaptar o diagnóstico aos recursos disponibilizados. Podendo este recurso ser supercomputadores ou combinações de computadores (cluster<sup>1</sup>) ou até mesmo um smartphone com acesso a uma câmera.

### 1.2.1 Flexibilidade

Sabemos que em distâncias remotas o acesso a saúde é um problema no Brasil. Dado isso, soluções que sejam acessíveis em questão de custo e mobilidade é a opção recomendada. Com isso, o modelo além de trazer o aspecto explicativo para o diagnóstico da doença também irá trazer custo computacional flexível, podendo ser utilizados em diferentes ambientes.

Regiões remotas do Brasil, em que a infra-estrutura de saúde possui poucos recursos acessíveis, modelos de baixo custo é a opção a ser utilizada. Outra opção, seria também adotar um servidor central que irá ficar responsável por executar todo o processo de diagnóstico e tratamento dos dados e retornar o resultado para o profissional responsável. Utilizando um servidor central é possível que os dados sejam centralizados e com o passar do tempo o modelo possa ser melhorado com variabilidade maior de dados disponíveis.

### 1.2.2 Explicabilidade

O modelo também trará aspectos. Esta explicabilidade poderá ser utilizado tanto com arquiteturas mais simples, utilizando somente uma imagem do fundo do olho ou arquiteturas mais complexas, adicionando à imagem os dados demográficos e os resultados do exame OCT do paciente na modelagem.

Desta forma o profissional pode utilizar modelos diferentes de acordo com os dados que estejam disponíveis para ele, dando assim mais flexibilidade para o diagnóstico do glaucoma.

Para explicar os modelos iremos utilizar uma biblioteca conhecida como SHAP (?). Esta biblioteca será abordada na seção ?? com maior detalhes, no entanto, a ideia

---

<sup>1</sup>Um cluster (do inglês cluster: 'grupo, aglomerado') consiste em computadores fracamente ou fortemente ligados que trabalham em conjunto, de modo que, em muitos aspectos, podem ser considerados como um único sistema. Diferentemente dos computadores em grade, computadores em cluster têm cada conjunto de nós, para executar a mesma tarefa, controlado e programado por software. Fonte: Wikipedia

do SHAP é calcular o impacto de cada uma das características da imagem ou dos dados clínicos quanto ao diagnóstico do modelo.

## 1.3 Declaração de Tese

A pergunta principal desse projeto é: Modelos computacionalmente eficientes e flexíveis (em termos de usabilidade e acesso) desempenho a tarefa de forma eficaz igual ou melhor do que modelos computacionalmente mais caros e menos flexíveis?

## 1.4 Contribuição

Este projeto apresenta uma modelagem e análise dos resultados para detecção/diagnóstico do glaucoma utilizando modelos de inteligência artificial. Os modelos aqui apresentados são focados em tarefas que envolvem computação visual, ou seja, quando se utiliza de imagens para resolver uma tarefa.

Será apresentado diferentes modelos com diferentes arquiteturas e hiperparâmetros para verificarmos quais destes modelos se encaixam melhor à questão apresentada anteriormente. Além das arquiteturas, também será analisado a explicabilidade destes modelos, dando recursos para que se possa interpretar os resultados gerado pelos modelos.

Além disso, todos os passos de limpeza e engenharia dos dados também serão explicitiadas, e todas as decisões tomadas para que o projeto seja concluído, como por exemplo a seleção dos melhores modelos. Também será apresentado técnicas de manipulações de dados do tipo imagem e tabular para melhorar a desempenho do modelo.

E por fim, teremos o resultado comparando cada um dos modelos experimentados e testados com um intervalo de confiança, levando em consideração também flexibilidade, usabilidade e custo computacional.

## 1.5 Organização

Esta dissertação está separada em 7 capítulos. O primeiro capítulo

## Capítulo 2

# Referências Teóricas

### 2.1 Aplicações Gerais

Modelos de redes neurais convolucionais possuem múltiplas aplicações, inclusive na detecção de doenças de pele (?). Neste trabalho os autores exploram diferentes modelos, entre eles RegNet (?) e EfficientNet (?) como modelos mais eficientes, e também modelos tradicionais como ResNet (?) e VGG (?). Além disso, os autores também trouxeram uma versão modificada do *RandAugment*, explicado na seção ??, para melhorar a desempenho do modelo utilizando *Data Augmentation*. Com tudo, utilizando um conjunto de dados extremamente desbalanceado, os autores também criam uma função de aprendizado que leva em consideração o desbalanceamento dos dados. Ao final, os autores apresentaram os resultados dos diferentes modelos, inclusive das versões mais leves computacional do RegNet desempenho próximo, igual ou até melhor do que os modelos tradicionais custosos.

Utilizando modelos de computacionais visuais, é possível identificar doenças nas folhas da maçã (?). De acordo com os autores, o de dados é conjunto pequeno, com um total de 2200 imagens aproximadamente e 5 diferentes doenças para serem detectadas. Os modelos testados foram ShuffleNet, EfficientNet-B0, MobileNetV3, RegNet e ViT (?????). Dentre os modelos citados anteriormente, o que atingiu a melhor acurácia de 99.8% foi o modelo RegNet. Todos os modelos foram treinados com 4 diferentes otimizadores, explicado na seção ??, e 5 diferentes taxa de aprendizado ??.

Utilizando uma combinação de imagens e dados clínicos, é possível utilizar de modelos de aprendizado de máquina para detectar cancer de mama (?). O modelo convolucional processa múltiplas imagens com diferentes ângulos de uma tomografia do torax. Cada imagem é processada por um modelo independente, ou seja, eles não compartilham os pesos e parâmetros entre si ??. Os dados clínicos, contendo idade, histórico da família em relação ao cancer, presença de diabetes, é processado por uma outra rede neural multicamadas ??. Ao final, os resultados é concatenados por uma outra rede neural multicamadas e em seguida o modelo faz o diagnóstico quanto a presença do cancer. Os autores concluem que a adição de um modelo convolucional com múltiplas entradas (*multi-input*)

e dados clínicos conseguem trazer resultados melhores do que o modelo utilizando somente uma imagem (*single-input*) frontal do torax.

É possível de utilizar modelos de IA para detectar doenças cardiovasculares (?). Os modelos foram divididos em dois grupos: *single-input* e *multi-input*. As arquiteturas *single-input* utilizam o modelo visual Inception-V3 (?) quando os dados é imagem, e utilizam redes neurais multicamadas e modelos de árvore de decisão (?) com os dados clínicos. Quanto a arquitetura *multi-input* utiliza o modelo Inception-V3 para os dados de imagem e o de redes neurais multicamadas para passar processar os dados clínicos e concatenar a saída dos dois modelos. O modelo *multi-input* atingiu uma acurácia 0.79 enquanto o *single-input* atingiu uma acurácia de 0.75.

Utilizando *Visual Transformers* (ViT) ??, foi capaz de detectar Pneumonia nos pulmões, inclusive quando adivindo do Covid-19 (?). Utilizando tomografia computadorizada, a imagem é dividida em vários pedaços e cada um destes pedaços é codificados dentro do modelo ViT e em seguida repassado para uma rede neural multicamadas para diagnosticar a imagem com a presença de pneumonia (Ocasionalada pelo vírus da COVID-19 ou outro vírus) ou não. Ao final, o modelo dos autores apresentaram uma acurácia de 97% na detecção da doença.

O trabalho apresentado a seguir traz a uma forma diferente de trabalhar com redes neurais convolucionais utilizando um modelo conhecido como DCGAN (?). Os modelos DCGAN são baseados em modelos neurais generativos (??). O intuito destes modelos é utilizar dados reais para criar dados que sejam sintéticos e próximo da distribuição dos dados reais. Para isso, o modelo se divide em duas partes: codificador e decodificador. O modelo codificador aprenda uma representação vetorial dos dados de entrada, enquanto o decodificador processa essa representação vetorial e tenta criar uma amostra parecida com a original. Neste artigo (?), os autores utilizaram o modelo DCGAN para criar representação vetorial que consiga explicar a distribuição dos dados. E em seguida, os autores utilizaram essa representação em um modelo classificador baseado em regressão logística para detectar a presença de Alzheimer nos pacientes. Os dados utilizado pelo modelo DCGAN são imagens neurais multimodais.

## 2.2 Aplicações de Glaucoma

É possível utilizar dedes neurais convolucionais, mais especificamente uma Res-Net34 pre-treinada, para poder prever a espessura das camadas das fibras nervosas do disco ótico (?). Para evitar que haja qualquer tipo de vazamento de dados entre os dados de treino e de teste ??, a divisão dos dados foram feita por paciente, desta

forma nenhum dado de paciente está presente no treino e no teste ao mesmo tempo. As imagens foram padronizadas altura e largura de  $256 \times 256$  pixels, e os valores de pixels foram normalizados entre 0 e 1. Adicionado a isso, foram utilizados algumas técnicas de *data augmentation* para aumentar o número de variabilidade das amostras do conjunto de dados, dando mais recurso para o modelo treinar sem precisar coletar mais dados. Contudo, um modelo binário foi treinado para detectar anormalidades (ou normalidades) na espessura das fibras utilizando fotografias do disco ótico. As métricas utilizadas foram MAE (*Mean Absolute Error*) para predição da espessura da fibra e AUC (*Area under the ROC curve*) para a classificação binária. Dado um total de aproximadamente 1200 amostras (pacientes), com um total de 2312 olhos, os modelos apresentaram resultados de 0.944 para curva ROC, uma acurácia de 83.7% e um erro de predição (MAE) da espessura da fibra de aproximadamente 7.39 micromilímetros.

Neste trabalho, a imagem do fundo do olho foi utilizada para extrair uma característica da imagem utilizando redes CNN, que o autor deu nome de *CNN Degree* (?). Além da característica extraída pelas redes CNNs, foram também utilizados dados clínicos para o segundo modelo preditor final, como por exemplo: espessura da fibra (temporal, nasal, inferior, superior), espessura da cornea, tamanho do copo e do disco, idade, sexo do paciente e etc. Para o modelo preditor final, foram utilizados modelos com estruturas diferentes. Estes modelos além de usar a característica extraída da CNN, também irá utilizar dados clínicos para diagnosticar o glaucoma, dentre eles estão: *support vector machine* (SVM), *random forest*, *C5.0* e *XGBoost*. As métricas utilizadas foram AUC, ROC, sensibilidade e especificidade. Ao final os autores constataram que melhor modelo foi o XGBoost, apresentando AUC igual a 0.945, sensibilidade de 0.950 e especificidade de 0.945. Além disso, os autores apresentaram explicabilidade para o modelo, sendo a característica mais importante a espessura das camada das fibra da nervosas da retina superior (*RFNLsuperior*), apontando pessoas com glaucoma apresenta valores menores para essa caracterísitca e pessoas saudáveis o oposto. Em segundo lugar o modelo apontou *RNFLinferior* e em terceiro lugar a pressão intracocular (*IOP*) como características mais importantes.

O próximo artigo utiliza o modelo Inception-V3 (?) para detecção do Glaucoma (?). O autor também traz técnicas de Data Augmentation ?? para aumentar heterogeneidade dos dados mas mantendo características prognósticas das imagens. As fotos foram padronizadas para o tamanho  $299 \times 299$  e os pixels foram normalizados entre 0 e 1. Quanto ao Data Augmentation, foram aplicado as seguintes operações: rotações randomizadas de 90, 180 e 270 graus e também um deslocamento entre 0 e 3 pixels na horizontal. Este último é aplicado para aumentar o detalhe de captura das imagens sem a necessidade de aumentar o número de pixels da mesma. Quanto aos parâmetros do treino, o autor utilizou o otimizador Adam (?) com um taxa de aprendizagem de 0.002 e um tamanho de *batch* de 32 imagens. Com um total de 48 mil imagens e dentro de um intervalo de

confiança de 95%, o autor atinge um desempenho de AUC entre 0.984 e 0.988. Além disso o autor aponta quais foram as características que mais gerou falso negativo:

- Glaucoma normal aparece junto com outras doenças, como por exemplo miopia, retinopatia diabética e degeneração macular devido a idade.
- Defeito nas camadas das fibras nervosas da retina ou disco ótico apresentam hemorragias.

Para um uso mais extensivo ao público, é possível misturar um acesso público e aprendizado de máquina para detecção do Glaucoma (?). Esta framework<sup>1</sup> é acessível para o público envia as fotos do fundo dos olhos e em seguida recebe o resultado do modelo. Se o resultado for negativo é enviado direto para o paciente. Caso resultado seja positivo, este é enviado para um oftalmologista para uma análise mais profunda. A framework é dividida em duas partes: a parte pública onde as pessoas podem carregar as imagens do fundo do olho e a parte privada, onde é feito todo o processamento e a geração do relatório. O acesso público pode ser pela web ou por um dispositivo móvel. O resultado é baseado na proporção entre o disco e o copo ótico (CDR). Se o CDR é maior que 0.5 o modelo retorna possibilidade de glaucoma. Para segmentar e classificar a imagem, os modelos utilizados foram: EfficientNet (?) (Codificador) e UNet++ (?) (Decodificador). O codificador cria um mapa de características que será decodificado, pelo decodificador, de forma que cada segmento da imagem seja separado e o CDR seja calculado. O acesso ao banco de dados também é gerenciado por um servidor público, de forma que todas as pessoas tenham acesso. Enquanto o processamento da imagem é feito por um servidor privado.

O seguinte trabalho compara a acurácia do modelo de aprendizado de máquina quanto as fotos coletadas utilizando a câmera padrão dos centros óticos e das fotos coletadas utilizando um smartphone e um aparelho acoplado D-Eye Lens (?). O autor descreve que a utilização do smartphone possibilita que mais pessoas sejam avaliadas devido ao fácil acesso e manuseio do dispositivo. Para capturar as fotos pelo smartphone um vídeo de 1 minuto é gravado, e deste vídeo, uma imagem é extraída, sendo a imagem a que melhor captura o disco ótico. Além de possibilitar que pacientes com demência também sejam diagnosticados. Os autores utilizaram uma ResNet para classificar a presença do glaucoma. Quanto aos dados foram utilizadas técnicas de *Data Augmentation*, abordado na seção ??, para diversificar o dado e por consequência melhorar o desempenho do modelo quanto a generalização. Dentre elas, estão: rotação da imagem (10 graus), translação vertical e horizontal, mudança de contraste e saturação de forma randômica e variação

---

<sup>1</sup>Um framework em desenvolvimento de software, é uma abstração que une códigos comuns entre vários projetos de software provendo uma funcionalidade genérica. Um framework pode atingir uma funcionalidade específica, por configuração, durante a programação de uma aplicação. Ao contrário das bibliotecas, é o framework quem dita o fluxo de controle da aplicação, chamado de Inversão de Controle. Fonte: Wikipedia

do tamanho das bordas da imagem. O modelo apresentou um desempenho AUC de 0.98 para a câmera padrão e 0.84 para o uso do smartphone. O autor discute que a diferença de desempenho, que apesar de boa é menor que a câmera tradicional, se dá pela capacidade de foco da câmera, gerando imagens que nem sempre possuem uma qualidade adequada para uma avaliação mais assertiva.

## Capítulo 3

# Metodologia e Ferramental Teórico

### 3.1 Modelos

Os modelos mencionados a seguir são modelos focados em visão computacional. Todos os modelos são baseados em redes neurais convolucionais, com exceção do modelo ViT, do inglês *Vision Transformers*. Para uma melhor experimentação para diagnosticar o glaucoma, diferentes modelos foram testados. Com intuito de trazer mais flexibilidade ao diagnóstico de glaucoma, foram testados modelos com número de parâmetros reduzidos e consequentemente com requisitos menor de poder computacional. Alguns dos modelos são capazes de serem executados em dispositivos menores, como por exemplo um smartphone. Outros modelos trazem rápida inferência quando a carga de acesso à uma aplicação pode ser alta e é necessário que o modelo responda rápido. Mas também, modelos com uso maior de poder computacional, com intuito em alcançar um desempenho melhor quanto a assertividade do modelo, foram incluídos nos experimentos. Toda a experimentação é com objetivo de trazer diferentes flexibilidade, à depender da infraestrutura disponível, de forma que os modelos sejam capazes de serem utilizados em múltiplos cenários. Logo, os modelos testados foram: RegNet, MobileNet, ShuffleNet, EfficientNet, ResNet, Inception-V3, ViT (???????)

Cada um dos modelos citados anteriormente possui suas vantagens. A MobileNet, como o próprio nome já diz, é otimizada para rodar em celulares ou dispositivos menores do que um computador (?). As redes MobileNet, são menores do que as redes convolucionais tradicionais, por isso utilizam menos energia, para atender recursos limitados, e também possuem baixa latência para ter respostas rápidas. A EfficientNet, tem como objetivo ser eficiente em tarefas que envolve reconhecimento visual. Estas redes podem ser escaladas facilmente para ser utilizadas em larga escala ou melhorar sua desempenho sem trazer custos adicionais exagerados e de forma simples (?). A ShuffleNet traz uma rede neural que seria o extremo de redução de custo tentando manter a acurácia do modelo. A ShuffleNet pode ter uma eficiência 13 vezes uma ResNet sem perder muito da sua desempenho quanto a acurácia do modelo. ShuffleNet possuem o número de operação por segundo reduzidas

(MFLOps<sup>1</sup>) e também o tempo de resposta (?).

Quanto aos modelos mais custosos, temos ViT, Inception-V3 e ResNet. A ResNet traz um modelo robusto com uma desempenho em acurácia alta devido ao número de parâmetros (?). A ViT são redes neurais que conseguem trazer capacidade de aprendizado mesmo com um número pequeno de dados mas mantendo o poder computacional das redes neurais convolucionais mais profundas como a ResNet citado anteriormente. Como toda rede neural, quanto mais dados disponíveis melhor será o poder de generalizar da rede, no entanto, redes neurais ViT apresentam resultados melhores utilizando técnicas de *self-attention* (??)

E além dos modelos convolucionais citados acima iremos também utilizar um modelo de múltiplas camadas conhecida como MLP, ou do inglês *Multi Layer Perceptron*. As MLP são modelos mais simples, no entanto, com alto poder de generalização. Neste projeto, os modelos MLP serão utilizados na parte de classificação e concatenação das arquiteturas que serão citadas na próxima seção ??.

## 3.2 RegNet: O modelo mais flexível para visão computacional

O modelo RegNet é um tipo de rede neural criada através de um *Network Design Space* (NDS). Diferente dos modelos de arquitetura padrão, onde existe uma arquitetura que foi descoberta através de NAS<sup>2</sup> (?), o RegNet é um espaço contendo todas as redes neurais possíveis dado um grupo de parâmetros. Ou seja, NDS fornece um mecanismo de testagem de arquiteturas mais sofisticado, sem a necessidade de testar cada uma das arquiteturas, mas sim uma amostragem dela, reduzindo custo computacional, e ao mesmo tempo fornece modelos simples e performáticos, já que este consegue trazer uma experimentação/testagem/amostragem mais robustas.

O NDS é um conjunto de possíveis arquiteturas dentro de um espaço de busca. Em cada iteração, esse espaço de amostragem é restringido com o intuito de criar obter redes neurais com desempenho maior ou pelo menos igual, no entanto, utilizando uma arquitetura muito mais simples. Desta forma, com a amostragem, é possível verificar que utilizando uma certa combinação de grupo de parâmetros, conseguimos testar se um população amostral de arquitetura de redes neurais, consegue desempenhar bem em

---

<sup>1</sup>Medida de operação de ponto flutuante por segundo. Quanto menor este número para um rede neural menos energia é gasta para ser calculado os resultados.

<sup>2</sup>*Neural Architecture Search* é uma técnica de automatizar o processo de busca de arquitetura de redes neurais, desempenhando melhor do que redes neurais montadas manualmente.

um problema ao invés de procurar uma arquitetura única que traga o melhor resultado possível, como é utilizado na metodologia NAS(?).

Dentre os parâmetros e estruturas de uma RegNet, esta é composta por:

### 3.2.1 Parâmetros


- Total de blocos: Cada bloco é composto por um grupo de convoluções ??.
- Largura do bloco: Total de canais ?? de cada um das convoluções.
- Razão do gargalo: Utilizado para diminuir o número de canais entre uma convolução e outra, diminuindo o total de operações a serem executadas.
- Largura do grupo: Total de convoluções para cada bloco.

### 3.2.2 Estrutura

- Tronco: Contém as camadas ?? de entrada da rede neural.
- Corpo: A parte principal da rede neural, sendo esta a estrutura que vai ser influenciada pelos parâmetros citados acima.
- head: Camada de saída do modelo, contendo o classificador.

A figura a seguir ??, apresenta um modelo RegNet.

Figura 3.1: Corpo de um modelo RegNet contendo 4 (Fixo) estágios. Cada estágio contém número  $X$  de blocos.



Fonte: Imagem retirada do artigo (?).

Um ponto de atenção citado pelos autores é a decisão de manter todos os blocos iguais e com a mesma estrutura de uma ResNet (?). A imagem ?? a seguir exemplifica:

Figura 3.2: Exemplo de um bloco  $X$  baseado em uma rede residual.




Imagem retirada do artigo (?).

A tabela ?? explica um pouco como o modelo RegNet é montado. Como citado anteriormente, é possíveis infinitas combinações de arquitetura de redes neurais dependendo dos parâmetros a serem testados. A primeira arquitetura de rede neural, **AnyNetA**, não possui nenhuma restrição, totalizando aproximadamente  $1.8 \cdot 10^{18}$  combinações possíveis.


Tabela 3.1: Tabela de restrições dos modelos até chegar no modelo RegNet (?). O índice  $i$  é o estágio, fixado em 4. O  $b_i$  representa razão do gargalo,  $g_i$  representa o total de canais da convolução,  $d_i$  representa o total de blocos e o  $w_i$  representa o tamanho do bloco.

|                     | restriction         | dim. | combinations                                | total                    |
|---------------------|---------------------|------|---------------------------------------------|--------------------------|
| AnyNet <sub>A</sub> | none                | 16   | $(16 \cdot 128 \cdot 3 \cdot 6)^4$          | $\sim 1.8 \cdot 10^{18}$ |
| AnyNet <sub>B</sub> | $+b_{i+1} = b_i$    | 13   | $(16 \cdot 128 \cdot 6)^4 \cdot 3$          | $\sim 6.8 \cdot 10^{16}$ |
| AnyNet <sub>C</sub> | $+g_{i+1} = g_i$    | 10   | $(16 \cdot 128)^4 \cdot 3 \cdot 6$          | $\sim 3.2 \cdot 10^{14}$ |
| AnyNet <sub>D</sub> | $+w_{i+1} \geq w_i$ | 10   | $(16 \cdot 128)^4 \cdot 3 \cdot 6 / (4!)$   | $\sim 1.3 \cdot 10^{13}$ |
| AnyNet              | $+d_{i+1} \geq d_i$ | 10   | $(16 \cdot 128)^4 \cdot 3 \cdot 6 / (4!)^2$ | $\sim 5.5 \cdot 10^{11}$ |
| RegNet              | quantized linear    | 6    | $\sim 64^4 \cdot 6 \cdot 3$                 | $\sim 3.0 \cdot 10^8$    |

No último modelo, após adicionar todas as restrições e avaliar todas as **AnyNets** o modelo enfim chega no Regnet utilizando uma metodologia conhecida como *quantized linear parameterization*, para que todo os blocos do mesmo estágio tenham o mesmo tamanho.

A desempenho dos modelos amostrados do NDS é calculada através de um procedimento que se resume em treinar o modelo no conjunto de dados ImageNet (?) por 10 épocas ?? e calcular o erro de inferência nesse mesmo conjunto de dados. É amostrado em torno de 100 modelos para cada NDS com seu conjunto de parâmetros e restrições.

Figura 3.3: A imagem da esquerda mostra os *Design Spaces* A, B, e C, sendo o C mais restritivo entre eles. A imagem da direita mostra a distribuição de erro de cada desses espaços, sendo o C aquele que possui melhor desempenho entre eles.



Fonte: Imagem retirada do artigo (?).

[H]

Ao final, os autores chegam a conclusão que os modelos amostrados do espaço **RegNet** possuem desempenho melhor do que os modelos amostrados do **AnyNet** para qualquer valor dos parâmetros escolhidos. Além disso, os autores apresentam o modelo **RegNetY** que é uma variação do **RegNetX** contendo uma técnica conhecida como *squeeze-and-excitation* (?) para que cada bloco seja capaz de adaptar os pesos para capturar as partes mais importantes da imagem com um adicional de custo computacional baixo.

## 3.3 Conceitos

### 3.3.1 Camadas


As camadas são onde se encontra os neurônios ou unidades de processamento. Um rede neural normalmente possui múltiplas camadas, ou pelo menos duas, camada de entrada e saída. Quanto mais camada a rede neural possui mais profunda ela é, ou seja, mais neurônios são utilizados. No entanto, é necessário tomar cuidado, pois quanto mais neurônios mais cálculos e dados são necessários para utilizar o modelo, demandando mais poder computacional.

### 3.3.2 Pesos ou Parâmetros

As redes neurais é composta por várias unidades de processamento, cujo o funcionamento é o mais simples possível. As unidades das redes neurais, conhecido também como neurônios, são interligados entre si, e cada um dessas unidades possui um peso, também conhecido como parâmetro. As unidades fazem operações matemáticas com os dados locais, sendo estes dados as entradas processada por outra unidade de processamento ou uma tabela de dados se esta unidade estiver na primeira camada do modelo, também conhecida como camada de entrada, do inglês *input layer*.

A figura ?? representa uma MLP contendo três camadas. Uma camada de entrada, uma camada intermediária e uma camada de saída. Cada uma dessas camadas possui um número  $N$  de neurônios. Cada neurônio, ou unidade de processamento, possui conexões com outras unidades, sendo essa conexão seria o **peso** ou **parâmetro**. O peso então é multiplicado pela saída de um neurônio que entra em um próximo neurônio. Dentro do neurônio, todas as entradas são somadas e em seguida passa o resultado da soma em uma função de ativação, como por exemplo uma sigmoide (?), para transformar ou limitar os valores. Todos os neurônios de uma camada possui ligações com todos os neurônios da próxima camada.

Figura 3.4: Uma rede neural MLP, com 3 camadas. Uma de entrada com 3 neurônios, uma camada intermediária com 4 neurônios e uma de saída com dois neurônios.



Fonte: Imagem elaborada pelo autor.

### 3.3.3 Taxa de aprendizado

A taxa de aprendizado é o valor de atualização dos pesos. Toda vez que uma rede neural erra sua previsão ou resposta, é necessário que estes pesos se ajustem, de forma a diminuir o valor do erro. A taxa de aprendizado é o tanto que esta atualização vai mudar o peso. Quanto mais alta a atualização maior o valor atualizado, e quanto menor menor será essa mudança. É necessário balancear este valor para que as atualizações sejam em tamanho corretos para que o modelo consiga chegar em um mínimo local quanto a métrica de erro (?).

### 3.3.4 Treino, Teste e Inferência

O processo passa-se obter e usar um modelo de aprendizado de máquina e divide-se em três fases: treino, teste e inferência. O treino é a fase onde ajustamos os parâmetros do modelo para que ele complete uma tarefa da melhor forma possível, que neste projeto seria diagnosticar o glaucoma. O teste é a fase onde avaliamos o desempenho do modelo utilizando as métricas previamente estabelecidas. E a fase de inferência é quando um modelo já treinado e avaliado será utilizado pelo público alvo. Normalmente, os modelos na fase de inferência são colocados na nuvem<sup>3</sup> ou em alguma infraestrutura computacional local para que possam ser acessados e utilizados e por consequência traga valor para o negócio (?).

Cada uma dessas fases possui seu conjunto de dados. É necessário ressaltar que se deve ter cuidado em dividir o conjunto de dados do treinamento e do teste para que não haja vazamento de dados entre os dois conjuntos e o modelo atinja um desempenho que não representa a realidade. O conjunto de dados da inferência vem da utilização do modelo, ou seja, todos aqueles dados que não estavam presentes dentro do conjunto de treino e teste e é totalmente novo para o modelo. Após um certo tempo, normalmente incluem os dados de inferência dentro do conjunto de dados de treino e teste e o modelo é retreinado e reavaliado.

### 3.3.5 Batch e Época

O treinamento se divide em épocas. Cada época é uma passagem por todos os dados dentro do conjunto de dados de treinamento e teste para o modelo, para que este então possa ajustar os seus pesos (parâmetros). No entanto, não é possível passar todos os dados para o modelo de uma única vez devido ao custo computacional e ao tamanho limitado da memória. Logo, os dados são divididos em *minibatches* que nada mais são que um subgrupo de um grupo de dados. O tamanho deste subgrupo é ajustado de acordo com a tarefa e recursos computacionais disponíveis. No entanto, o ideal é que ele seja menor que o grupo todo e maior do que 1. Neste último caso, o modelo precisará fazer muitas atualizações e também usará recurso computacional excessivamente, além de que, a generalização poderá ser afetada para pior já que 1 amostra dificilmente irá representar

---

<sup>3</sup>Infraestrutura de computação necessários para rodar uma aplicação que seja acessado através da internet. Os recursos virtuais refletem uma infraestrutura física local, com servidores, memórias, clusters e armazenamentos. Tudo isso voltado para uma escalabilidade e fácil uso.

ou aproximar mínimamente a distribuição de dados do conjunto todo (?).

### 3.3.6 Função de perda

A função de perda mede o quão longe da resposta correta o modelo está. Também conhecida como **função de custo**, esta função irá indicar a qualidade do modelo e quais são os valores de atualização necessárias para os parâmetros utilizando apenas um número real. O que esta função faz é comparar o que é conhecido como *ground truth*<sup>4</sup> com a saída do modelo. Neste projeto o *ground truth* é a classe dos dados, indicando presença ou ausência do glaucoma.

### 3.3.7 Otimizadores

Os otimizadores são algoritmos ou funções responsáveis por atualizar os parâmetros dos modelos. O otimizador acha o melhor valor para esses parâmetros com o objetivo de diminuir o erro do modelo em uma devida tarefa. Dado isso, o otimizador recebe os parâmetros do modelo, a taxa de aprendizado e o erro através da função de custo, e com todos estes recursos e dados, o otimizador escolhe a melhor atualização para os parâmetros. Contudo, é essencial escolher o melhor otimizador para cada uma das tarefas ou modelos que serão utilizados. Desta forma, o aprendizado do modelo possa ser efetivo e o modelo consiga desempenhar com qualidade.

### 3.3.8 Hiperparâmetros

Os hiperparâmetros dos modelos são configurações de cada um destes modelos ligado ao processo de aprendizado. Por exemplo, citado anteriormente??, a taxa de aprendizado é um hiperparâmetro a ser escolhido e indica a magnitude de atualização dos parâmetros. Outro hiperparâmetro é o tamanho do *minibatch* ?? e também qual otimizador ?? será utilizado (?). Normalmente, para encontrar os melhores hiperparâmetros para o modelo

---

<sup>4</sup> *Ground truth* é uma informação que sabemos que é real utilizando métricas ou através da observação.


é necessário repetir o processo de treino e teste múltiplas vezes, tornando este processo extremamente caro.

### 3.3.9 Sobreajuste

O sobreajuste, do inglês *overfitting*, é um cenário onde o modelo se ajusta de forma quase que perfeita para um conjunto de dados X e por consequência, acaba tendo uma perda de desempenho no conjunto de dados Y que possui uma distribuição diferente de X. É ideal que o modelo consiga generalizar bem para todos os conjuntos de dados disponíveis, no entanto, é praticamente impossível já que qualquer comportamento diferente nos dados pode causar distribuições totalmente diferentes entre eles. Logo, se conjunto de dados X e Y possuem distribuições próximas, mas não iguais, é possível utilizar de um para conseguir inferir o outro. Portanto, se o modelo sobreajusta para X e tenta inferir Y, este modelo irá ter um erro grande quanto a sua inferência, já que apesar das distribuições serem próximas, a distribuição de X é diferente de Y (?).

Com isto, para se evitar o sobreajuste do modelo, este projeto aplicou uma técnica conhecida como *Early Stopping* ???. A técnica tem como intuito parar o processo de treinamento quando o modelo começa a aumentar sua desempenho no conjunto de dados de treino (X) e sofre uma piora significativa no conjunto de dados de teste (Y) utilizado para avaliação. A figura ?? a seguir mostra visualmente como acontece o sobreajuste.

Figura 3.5: Uma imagem representando o problema de sobreajuste e subajuste.




Fonte: IBM

### 3.3.10 Convolução

As convoluções funcionam como filtros que enxergam pequenos quadrados e vão “escorregando” por toda a imagem captando os traços mais marcantes. Explicando melhor, com uma imagem  $32 \times 32 \times 3$  e um filtro que cobre uma área de  $5 \times 5$  da imagem com movimento de 2 saltos (chamado de stride), o filtro passará pela imagem inteira, por cada um dos canais, formando no final um *feature map* ou *activation map* de  $28 \times 28 \times 1$ . A image ?? mostra como uma convolução funciona.

Figura 3.6: Exemplo de uma convolução com filtro  $5 \times 5$ . Cada quadrado com este tamanho produz um número com utilizando operações matemáticas. Em seguida, o quadrado é deslocado para o lado ou para baixo e um novo filtro é formado.




A profundidade da saída de uma convolução é igual a quantidade de filtros aplicados (Total de canais). Quanto mais profundas são as camadas das convoluções, mais detalhados são os traços identificados com o *activation map*. No entanto, quanto maior o número de canais, maior será o número de operações e consequentemente uma demanda maior de hardware.

## 3.4 Arquiteturas


Neste projeto foram testadas 4 arquiteturas de modelos. Não confundir com arquitetura de redes neurais. Cada uma das arquiteturas visuais apresentadas a seguir será testada com diferentes combinações de hiperparâmetros. O intuito de testar diferentes arquiteturas é que cada uma delas pode se sair melhor à depender da tarefa a ser realizada e os dados disponíveis. Dado isso, iremos testar as seguintes arquiteturas mostradas na figura ??.

Figura 3.7: Arquitetura de modelos. O *backbone* pode ser um dos modelos citados anteriormente (RegNet, ResNet, Inception e etc), e o *classifier* é uma rede neural de múltiplas camadas (MLP), assim como o modelo *MLP* que recebe os dados tabelados e também o que faz operação de concatenar (*concat*) juntando todas as saídas e passar para o classificador.


(a) Arquitetura utilizando uma imagem de olho (Single Input)




(b) Arquitetura utilizando uma imagem do olho e os dados tabulados (Single Input Tabular)



(c) Arquitetura utilizando duas imagens do mesmo olho (Dual Input)



(d) Arquitetura utilizando duas imagens do mesmo olho e os dados tabulados (Dual Input Tabular)



Fonte: Imagem elaborada pelo autor.

Todos as arquiteturas de modelos citados na figura ??, representados por um retângulo e com exceção do *backbone*, é um modelo de múltiplas camadas (MLP). Os modelos *backbone*, com tradução literária de *espinha dorsal*, são os modelos principais e os utilizados para extrair os padrões mais importantes dos dados. No nosso caso, estes dados serão um conjunto de imagens de fundo de olho.

A primeira arquitetura (SI) ?? utilizará somente uma imagem do fundo do olho. Entre as arquiteturas citadas na figura ?? esta é a arquitetura mais simples e que utiliza a menor quantidade de recurso computacional. Além disso, temos a arquitetura que utiliza uma imagem do fundo de olho e os dados tabelados do OCT ??. Esta segunda arquitetura junta os dados de imagens e os dados clínicos para trazer mais informações e consequentemente ajudar na classificação/diagnóstico da presença/ausência do glaucoma (SIT).

A terceira arquitetura (DI) ?? utiliza duas imagens do fundo de olho. Para que isso fosse possível, foi feita uma limpeza dos dados e uma avaliação manual de cada uma das fotos para cada paciente da base de dados. Escolhendo uma foto mais próxima e outra mais distante. A limpeza de dados é descrita e explicada na seção ??. A quarta e última arquitetura é a que utiliza duas imagens do fundo do olho e os dados clínicos. Esta é a arquitetura que utiliza mais recurso computacional, dado que o modelo de imagem é duplicado (*backbone*), utilizando o dobro de memória e adicionamos uma rede MLP para processar os dados clínicos (DIT).


Um **ponto de atenção**, a arquitetura de modelo utilizando somente uma imagem, seleciona aleatoriamente uma das duas imagens disponíveis para processar. Desta forma, este modelo aprende tanto a trabalhar com imagens mais próximas e mais distantes. Para o modelo que utiliza duas imagens, cada imagem passa por um *backbone* diferente. Logo, o mesmo padrão de imagem passa em cada um dos modelos, ou seja, imagens mais próximas são processadas por um modelo de imagem e imagens mais longes são processadas pelo segundo modelo de imagem. Desta forma, cada *backbone* fica responsável por aprender um padrão de cada uma das imagens. Isto é feito tanto no processo de treinamento do modelo quanto no processo de testagem e inferência, quando o modelo já está treinado e é utilizado.

## 3.5 Métricas de Avaliação

Para modelagem de diagnóstico na área médica, as métricas certas devem ser utilizadas para que possamos avaliar a qualidade do modelo com robustez. Neste projeto, as métricas utilizadas são:

- Sensibilidade (SN): É a capacidade do modelo de ser assertivo ao fazer diagnósticos positivo quanto a presença do glaucoma no paciente.
- Especificidade (SP): É a capacidade do modelo em detectar todos os casos verdadeiros de glaucoma.
- Característica de Operação do Receptor (ROC): Esta curva ajuda os profissionais e desenvolvedores do modelo a escolher um limiar de corte entre sensibilidade e especificidade que esteja de acordo com o problema de negócio. Esta métrica é a mais importante e utilizada em diagnósticos, pois como citado anteriormente, é possível termos uma flexibilidade de acordo com a regra de negócio, dado mais importância para sensibilidade ou para especificidade (?).
- Área sob a curva ROC (AUC): Permite verificar o quão bom o classificador binário desempenha no problema. O cálculo é feito utilizando a área sob a curva ROC. Quanto maior este valor mais flexível o modelo consegue ser quanto a especificidade e sensibilidade. Esta métrica varia de 0 a 1, sendo o melhor modelo aquele que tem valor igual a 1.

Figura 3.8: AUC e curva ROC.



Fonte: [Ciencias e Negocios, 2020](#)

Para selecionar o melhor modelo entre todos os experimentados, iremos utilizar a AUC como métrica principal, já que esta métrica consegue sumarizar, utilizando somente um número, o quão bom a curva ROC se encontra para cada um dos modelos. A figura ?? explica, de forma ilustrativa, como a curva ROC e a AUC funcionam. Em aplicações médicas, é mais válido trazer o maior número de verdadeiro positivos sem aumentar significativamente a taxa dos falsos positivos. Normalmente é mais prejudicial deixar de diagnosticar uma doença do que dar um diagnóstico positivo falso. Neste caso, o interesse maior é na sensibilidade. No entanto, se abaixarmos o threshold demais iremos

ter bastante falso positivos, ou seja, muito casos para serem analisados pelos especialistas, gerando um custo humano e de tempo ???. As duas métricas, sensibilidade e especificidade, interagem entre si. Quando se aumenta uma, movimentando threshold, é possível que se perca desempenho na outra. Contudo, o valor da métrica AUC carrega consigo a informação de variação desse ganho e dessa perda, ou seja, quanto melhor o AUC mais fácil movimentar o threshold ganhando de um lado e abdicando menos do outro. O modelo perfeito, com 100% de AUC, na imagem da direita ??, mostra que se movimentarmos o threshold não perderíamos nada, e seria possível capturar todos os casos verdadeiro sem nenhum caso de falso positivo. No entanto, é impossível construir um modelo perfeito, e normalmente os modelos ficam entre 50% e 100%.

## 3.6 RandAugment

*Data Augmentation* (?) é uma técnica de aumento do número de dados de forma sintética. Neste caso, operações são aplicadas na imagem de forma que novas imagens sejam criadas a partir das originais e por fim aumentando heterogeneidade dos dados para modelagem. Com os dados mais heterogêneos é possível atingir desempenhos melhores para o modelo sem aumentar de forma exponencial o custo computacional (mais poder computacional) que por fim será refletido em custo real.

Para realizar o *Data Augmentation* utilizamos neste projeto o *RandAugment* (?). De acordo com os autores, o *RandAugment* traz benefícios como: diminuir drasticamente o uso computacional pois não se utiliza políticas para escolher as operações a serem aplicadas nas imagens, mas sim uma probabilidade  $X$  de acontecer para cada uma delas. Desta forma, é possível manter a diversidade das imagens e ter um custo baixo para isso. As transformações possíveis são: transformação identidade, auto-contraste, equalizador, rotação, solarização, cor tremida, mudança de contraste, mudança de brilho, posterização, mudança de formato, translações e cortes.


Uma decisão feita para a utilização do *RandAugment* é que ele só foi aplicado nos modelos que tiveram a melhor performance entre todos os outros. Evitando assim, que infinitas combinações sejam testadas e ao mesmo tempo fosse possível avaliar o benefício da técnica.

## 3.7 Treinamento e Avaliação dos Modelos

Os modelos foram treinados e avaliados utilizando uma técnica conhecida como validação cruzada, do inglês *cross-validation*. A validação cruzada tem como objetivo avaliar a capacidade de generalização de um modelo a partir de um conjunto de dados. Busca-se então estimar o quão preciso é este modelo na prática, ou seja, o desempenho para um novo conjunto de dados. Dado isso, iremos utilizar o método K-Fold (?). Os autores do artigo (?) citam que dentre o processo de treinamento e validação, a validação cruzada é uma das mais utilizadas.

O método K-Fold consiste em separar os dados em K partes, sendo que K-1 partes serão utilizadas para o treino do modelo e a parte restante será utilizada para validação do modelo. Em uma próxima iteração um novo grupo é selecionado para teste e os outros K-1 para treino, até que todos os grupos passem pela fase de teste. Com isto, é possível que o modelo seja avaliado com mais robustez e com variabilidade controlada.

Figura 3.9: Imagem contendo ilustrando a validação cruzada. Cada parte assume o papel de teste uma vez e treino K-1 vezes.



Fonte: Elaborado pelo autor.

A imagem ?? mostra como os dados são divididos. Existem dois conjunto de dados que são AC (Amostras Conhecidas) e o AD (Amostras Desconhecidas). Dado isso, utilizando o conjunto AC aplicando a metodologia de validação cruzada, validando assim os melhores modelos. Em seguida, utilizados o conjunto AD para mensurar o desempenho do modelo. Este conjunto AD não entra nas iterações da validação cruzada, portando é possível avaliar a capacidade de generalização do modelo em dados que simulam os dados

na etapa de inferência.

Além disso, para que não houvesse *overfitting* (?) do modelo utilizamos o *Early Stopping* para finalizar o treinamento quando o modelo não melhora seu desempenho durante um número  $E$  de épocas. Adicionado à isso, economizamos também no custo computacional. E por fim, foram salvos os melhores modelos para cada experimento de acordo com a métrica escolhida, **AUC**.

## 3.8 Explicabilidade: SHAP

O SHAP (Shapley Additive Explanations) é uma das ferramentas mais utilizadas quando o assunto é explicabilidade. O objetivo por trás do SHAP é trazer um entendimento quanto a decisão de modelos complexos, modelos antes conhecidos como caixa preta devido sua falta de interpretabilidade. Logo, modelos estatísticos como XGBoost, LightGBM e modelos profundos como redes neurais convolucionais (CNN) agora são possíveis de serem entendidos ou interpretados (?).

A interpretação dos modelos trouxe uma forma inovadora de aplicar modelos de aprendizado de máquina, principalmente na área de saúde. O modelo interpretável traz informações extra para que o profissional seja capaz de tomar melhores decisões quanto ao problema que enfrenta.

Modelos foram propostos para diagnosticar e verificar a progressão da evolução da doença de Alzheimer (?). Os autores aplicam o modelo SHAP para pegar as características que são mais críticas para o modelo. O modelo SHAP foi capaz de dar explicações sobre quais características mais impactam a progressão da doença. Além disso, o modelo também forneceu explicações individuais para cada um dos pacientes. E em seguida foi utilizado um sistema baseado em lógica fuzzy (?) e linguagem natural para poder criar um formulário que os médicos e os pacientes pudessem consumir a explicação do modelo.


Utilizando modelos mais simples, como Árvore de Decisão (?), Regressão Logística (?) e kNN (?) e modelos mais complexos, como SVM (?), XGBoost (?), e RF (?), os autores criaram um sistema de prognóstico da doença de hepatite (?). Os autores utilizaram o modelo SHAP para verificar as variáveis mais importantes para os modelos, fornecem explicação para cada um dos pacientes e também geraram gráficos de dependência entre as variáveis de entrada e o rótulo dos dados (presença ou ausência de hepatite).

Utilizando modelos como XGBoost (?) para selecionar qual cirurgia refratária deve ser aplicada em um paciente (?). A escolha certa de uma cirurgia aumenta a satisfação de um paciente ao final do processo. Antes da escolha da cirurgia, o paciente consulta um expert da área e em seguida 80 características da tomografia da cornea são

extraídas, 40 características demográficas são coletadas e mais 22 características de exames oftalmológicos, como por exemplo diâmetro da pupila. Ao final, os autores fazem uma validação cruzada de 10 grupos e atinge uma acurácia média de 72% quanto a cirurgia a ser aplicada. Os autores também apresentam as características globais mais importantes e para cada um dos 3 exames aplicados: LASEK, LASIK, SMILE e contraindicação.

O shap utiliza o que chamamos de *Shapley Values* ou valores de *Shapley*. Os valores de *Shapley* é uma média ponderada da contribuição marginal de cada um das características (?). Isto é caracterizado pelo impacto que cada um destas características tem no valor preditivo do modelo (?).

Figura 3.10: Gráfico sumarizado para o dataset Boston Housing ordenado pelas características mais importantes do modelo.




Fonte: [SHAP Github](#)

Na figura ?? representa um gráfico SHAP para previsão dos preços de moradias em Boston-MA. Se o ponto é azul a variável apresentação um valor baixo, se o ponto é vermelho ela apresenta um valor alto. Se o ponto está do lado direito quer dizer que aquele valor da variável contribui para a resposta seja positiva ou maior, se do lado esquerdo, negativa ou menor. Por exemplo, a variável mais importante é a **LSTAT**. É a proporção

de adultos sem ensino superior e a proporção de trabalhadores braçal ou árduo masculinos em uma certa área. Significa que quanto maior essa proporção menor será um preço das casas na vizinhança. Enquanto a variável **RM** é a quantidade de quartos nas casas. Quanto mais quartos na casa maior será o valor atribuído para aquela residência.

Figura 3.11: Explicação de uma imagem utilizando SHAP. Os pontos vermelhos e azul mostram onde o modelo julgou como parte importante para a imagem. Seguindo a mesma lógica do ??, pontos vermelhos aumenta a probabilidade na saída do modelo, enquanto pontos azuis diminuem.



Fonte: [SHAP Github](#)

No entanto, para imagens, o SHAP funciona um pouco diferente. Na figura ?? a explicabilidade do modelo fornece quais são as áreas das imagens mais importantes para identificação de um animal. Por exemplo, para o passaro podemos observar que existem vários pontos vermelhos fortes na mesma área do bico, indicando dessa forma que essa parte foi uma das mais importantes para a identificação do passáro.

# Capítulo 4

## Sumário e Preprocessamento dos dados

### 4.1 Sumário dos dados

O dado recebido possui múltiplas imagens de fundo de olho para cada paciente. As imagens estão divididas para cada um dos olhos que foram feitos os exames. Foram recebidos um total de 492 pacientes e 887 olhos. Além disso, também está presente nos dados uma tabela contendo algumas informações do paciente e do exame OCT. Na tabela contém os seguintes dados:

- Dados demográficos: Nome, Idade, Gênero
- Presença ou ausência do glaucoma
- Indicação do olho examinado: esquerdo ou direito. Quando não há indicação, ambos os olhos foram examinados
- Medições de espessura das fibras retiradas do OCT: região nasal (N), nasal inferior (NI), nasal superior (NS), temporal (T), temporal inferior (TI), temporal superior (TS) e a média de todos os quadrantes (G).


Um exemplo na figura ?? contendo duas imagens do fundo dos olhos:

Figura 4.1: Duas imagens do fundo do olho com distâncias diferentes

(a) Imagem do fundo do olho distante do disco e copo



(b) Imagem do fundo do olho próxima do disco e copo



Fonte: Imagem extraída do conjunto de dados.

A primeira imagem ?? é mais distante quando comparada a segunda imagem ??, que possui um zoom mais próximo do disco. Cada paciente testado aqui deve possuir pelo menos duas fotos similares à essa.

Portnato, na próxima seção, será descrito todo o processo de limpeza dos dados realizados como requisitos do experimentos executados neste projeto.

## 4.2 Limpeza

Antes da exploração e modelagem dos dados, o dado precisa ser padronizado para que todo o processo fique mais simples, automatizado e consistente. Em seguida, algumas manipulações manuais foram aplicado aos dados:

- Verificação de duas vias: Verificar se o paciente está presente nos dados tabulares e se existe uma pasta contendo fotos do fundo dos olhos.
- Foi contabilizado o número de fotos para cada um dos pacientes, sendo assim, grande parte dos pacientes possuem pelo menos duas fotos para cada olho. Todos que tivessem uma foto ou nenhuma foram eliminados.
- Foram selecionadas, de forma manual, duas fotos para cada olho de cada paciente. Uma foto mais distante e uma segunda foto mais próxima, sem a parte marginal preta. As fotos foram renomeadas para indicar qual das duas imagens é a mais próxima ou distante, de forma que o modelo receba em cada uma das entradas o mesmo tipo de foto.
- Foram selecionados somente fotos com cores. Fotos preto e branco foram eliminadas.


- Alguns pacientes possuem diferentes datas de exames OCT e imagens do fundo do olhos. Dado isso, foi considerado as fotos que estão, em data, mais próximo do dado tabular contendo o dia que o exame foi realizado.

No total de 492 pacientes e 987 olhos, após a limpeza dos dados, restaram 476 pacientes e 858 olhos que serão utilizados na modelagem.


## 4.3 Exploração

Para entender melhor o problema é necessário que os dados sejam explorados e que a sua distribuição seja entendida. Nesta seção iremos avaliar os dados quanto as características presentes, como por exemplo, a correlação entre as espessuras das fibras e a presença do glaucoma, a presença do glaucoma quanto a idade e o gênero do paciente, e por fim, criar um entendimento sólido para dar base aos resultados que irão ser apresentados nas próxima seção.


Figura 4.2: Contagem de casos de glaucoma por gênero e por olhos




(a) total de pacientes por gênero



(b) total de pacientes com presença de glaucoma em 0(ausência), 1, 2



(c) Total de olhos com e sem glaucoma




(d) Total de olhos com ou sem glaucoma por gênero

Fonte: Elaborado pelo autor.

Como podemos observar nos histogramas da figura ?? é possível observar que temos mais casos de pessoas contendo glaucoma, dentro da base de dados recebida, em somente um dos olhos do que nos dois olhos. Além disso, temos a maior presença de pacientes do gênero feminino comparado ao masculino. Em proporção, a presença de glaucoma é maior em homens do que em mulheres. De acordo com Pesquisa Nacional Nacional de Saúde (?), as mulheres continuam sendo em maior proporção as pessoas que vão ao médico e procuram manter-se saudável. Com isto, o dado acima pode ser uma consequência dessa cultura, onde temos a maior presença feminina, no entanto, com proporções menores quanto a presença de glaucoma. Na seção de resultados, iremos observar se o modelo coloca a variável gênero como uma das principais para predição do glaucoma.

Figura 4.3: Distribuição do Glaucoma por variável


Distribuição das dos dados numéricos baseado nas classes



Fonte: Elaborado pelo autor.

Os gráficos da figura ?? mostra a distriuição das variáveis do OCT quanto a presença de glaucoma ou não. Existe uma separação visível das distribuições das variáveis G, TS, N e TI quanto a presença de glaucoma. Outro ponto importante, é a presença das distribuições contendo caudas para esquerda ou para direita. Estes pontos provavelmente serão detectados pelo modelo mais facilmente.

Figura 4.4: Boxplot do Glaucoma por variável.



Fonte: Elaborado pelo autor.


Existe uma presença de valores atípicos mostrados na figura ???. A idade, como mostrado na figura, pode ser um bom separador, já que existe uma tendência a esquerda (menor idade) quando to a ausência do glaucoma. As variáveis TI, G e TS são as que mais distanciam os casos quanto a presença ou não do glaucoma. Existe uma possibilidade de que essas variáveis sejam umas das mais importantes dos modelos para aqueles que usam os dados OCT.

Tabela 4.1: Tabela contendo sumarização dos dados utilizando as estatísticas: máximo, mínimo, média, desvio e contagem.

|       | Classe | G      | T      | NS     | TS     | N      | NI     | TI     | Idade  |
|-------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| count | 758.00 | 758.00 | 758.00 | 758.00 | 758.00 | 758.00 | 758.00 | 758.00 | 758.00 |
| mean  | 0.28   | 87.73  | 62.65  | 98.15  | 117.77 | 67.15  | 103.76 | 122.49 | 58.57  |
| std   | 0.45   | 18.82  | 14.26  | 28.11  | 31.97  | 16.94  | 28.63  | 34.75  | 15.90  |
| min   | 0.00   | 27.00  | 20.00  | 13.00  | 12.00  | 9.00   | 25.00  | 17.00  | 3.00   |
| max   | 1.00   | 145.00 | 129.00 | 188.00 | 228.00 | 136.00 | 204.00 | 228.00 | 96.00  |

Fonte: Elaborado pelo autor.

Figura 4.5: Correlação absoluta das variáveis



Fonte: Elaborado pelo autor.

Existe uma forte correlação entre a variável TS e G ???. Sendo G uma média global, existe a possibilidade que a variável TS tenha uma influência forte na média. As variáveis que mais se correlacionam com a classe são: TS, TI e G. A seguir, uma sumarização dos dados após a limpeza:

## 4.4 Engenharia de características e Normalização


Quanto a engenharia de características, apenas uma operação matemática foi aplicada. Sabendo que uma das características importante para detecção do glaucoma é a razão entre o copo e o disco presente no fundo do olho, as características criadas é a razão entre as medições numéricas do exame do OCT (?). Desta forma, cada caraterística numérica do OCT irá criar uma característica de razão entre pares com as outras. No total, 15 novas características foram criadas para serem utilizadas nos modelos. Além de serem características facilmente criadas, são fáceis de ser interpretadas pelos profissionais responsáveis ao analisar os resultados e a explicabilidade do modelo.

A normalização é um processo de redimensionar os valores das características numéricas para limites entre 0 e 1. A importância da normalização nas redes neurais está diretamente ligado ao fato de atualização dos pesos e otimização do modelo. Os algoritmos de otimização utilizam a descida gradiente para encontrar os melhores valores para diminuir o erro. Dentro da formula de descida gradiente, é utilizado os valores das características e da saída do modelo para em seguida os valores sejam somados ou subtraídos aos pesos e o modelo seja atualizado. Contudo, se os valores das características não forem normalizados e se dentro dos dados existem características com valores altos de magnitude diferentes, características com magnitudes maiores terão mais importância, o que não podemos assumir como verdade. Com isto, o ideal é que todas as caraterísticas tenham a mesma magnitude e o modelo escolhe a importância de cada um delas.

Foi uma comparação entre os modelos de redes neurais, modelos de árvore de decisão e modelos matemáticos como SVM e regressão logística (?). Para os modelos que não são redes neurais, 22 características foram medidas utilizando um scanner OCT. Uma destas características é a razão entre o copo e o disco. Todas as características foram normalizadas antes de serem processadas pelos modelos de aprendizado de máquina. Um ponto importante que os autores citaram, e que também foi aplicado nesse projeto, é que a normalização foi calculada e mensurada utilizando os dados de treino e aplicadas ao dados de teste. Desta forma, evita-se que haja qualquer tipo de vazamento de dados entre o conjunto de treino e teste.

Sendo assim, todas as variáveis numéricas como a idade, os medidas do exame OCT e as características derivadas do OCT mencionadas acima, foram normalizadas entre 0 e 1. Quanto ao gênero do paciente, foi utilizado 1 para o gênero masculino e 0 para o gênero feminino. Deste modo, o modelo consegue mensurar de forma o correto o impacto de cada um destas características.

Figura 4.6: Correlação das características criadas pela operação razão.



Fonte: Elaborado pelo autor.

A figura ?? mostra a correlação das características criadas sinteticamente com a operação de razão. Podemos observar que as duas características que mais apresentam correlação com a classe (presença ou ausência de glaucoma) são: N/TI e T/TI. No capítulo de resultados ??, mais especificamente na seção de explicabilidade ??, será averiguado se alguma destas características criadas foram importantes para o modelo.

# Capítulo 5

## Experimentos

### 5.1 Setup

Todos os experimentos foram executados em uma máquina com processador i7-3770, 16 gigabytes<sup>1</sup> de ram e uma placa de video Nvidia RTX-3060 com 12 gigabytes de memória.

Dentre os *softwares*<sup>2</sup> utilizados estão as seguintes bibliotecas de Python<sup>3</sup>: *Pytorch*<sup>4</sup>, *Seaborn*<sup>5</sup>, *SHAP*<sup>6</sup> e *Pandas*<sup>7</sup>. Para execução das análises foi utilizada o *Jupyter Notebook*<sup>8</sup>.

### 5.2 *Fine-Tunning*

Os modelos que foram utilizados como *backbones* são modelos que já foram treinados anteriormente com algum conjunto de dados de imagens, não necessariamente similar ao desse projeto. Dado isso, existem três formas mais utilizadas para fazer o treinamento para cada modelo. A primeira, conhecida como *scratch*, é um treinamento em que inicializamos os modelos com parâmetros de forma randômica e em seguida aplicamos nossos dados para que o modelo consiga aprender padrões do zero. O segundo método

---

<sup>1</sup>Gigabyte (símbolo Gbyte, GB, G) é uma unidade de medida de informação, segundo o Sistema Internacional de Unidades S.I., que equivale a um bilhão (milhar de milhões) de bytes, ou seja, 1.000.000.000 bytes, ou ainda  $10^9$  bytes

<sup>2</sup>Software é um termo técnico que foi traduzido para a língua portuguesa como suporte lógico e trata-se de uma sequência de instruções a serem seguidas e/ou executadas, na manipulação, redirecionamento ou modificação de um dado (informação) ou acontecimento.

<sup>3</sup><https://www.python.org/>

<sup>4</sup><https://pytorch.org/>

<sup>5</sup><https://seaborn.pydata.org/>

<sup>6</sup><https://github.com/slundberg/shap>

<sup>7</sup><https://pandas.pydata.org/>

<sup>8</sup><https://jupyter.org/>

é conhecido como *feature extract* que é quando utilizamos os modelos *backbones*, com os pesos já treinados em um grupo de dados diferente, e queremos utilizar deste pesos e apenas adicionar uma nova camada (normalmente a última) que será adaptada para o nosso conjunto de dados. Neste caso, todo o treinamento será feito apenas nessa última camada adicionada, enquanto os pesos das redes neurais pretrainedas serão congelados. E existe um terceiro modo, conhecido como *fine-tunning*, onde iremos treinar todo o modelo pretrainedo com os dados desejados.

Dos métodos citado acima, as literaturas apontam que o *fine-tunning* consegue desempenhar melhor em grande maioria das tarefas. Primeiro, para o caso de treinamento utilizando o método *scratch* é necessário um volume grande dados, já que redes neurais convolucionais possuem um número grande pesos ou parâmetros a serem treinados. Desta forma, quanto mais parâmetros mais dados são necessários para generalizar. Para o segundo caso de *feature extraction* o modelo preserva os pesos em que foi treinado originalmente e então é treinado somente a camada nova adicionada com o conjunto de dados que queremos utilizar. No entanto, o modelo não consegue se especializar já que teremos algumas poucas adaptações dos pesos para tarefa que queremos aplicar, limitado em pequenas mudanças nesta última camada adicionada. Enquanto no terceiro caso, o *fine-tunning*, conseguimos aproveitar a complexidade do modelo treinado em um conjunto de dados mais volumoso e heterogeneo e ao mesmo tempo conseguimos adaptar este modelo para a tarefa que desejamos (?????).

Logo, para este projeto, iremos utilizar somente o *fine-tunning* como método de treinamento dos modelos.


## 5.3 *Learning Rate Decay*

*Learning Rate Decay* (LRD) é uma técnica de treinamento de rede neurais. O modelo começa com taxa de aprendizagem e vai decaindo essa taxa múltiplas vezes durante o treinamento. Dessa maneira, o modelo começa atualizando os pesos mais rapidamente até que se chega em um certo ponto onde é necessário trabalhar com números menores e atualizações mais lentas. Dado isto, a taxa de aprendizagem do modelo irá diminuir, diminuindo os valores de atualização dos parâmetros e consequentemente atingindo valores melhores em desempenho.

Os seguinte trabalhos trazem um pouco do benefício do *learning rate decay* (??). A imagem na figura ?? mostra que em um certo momento os modelos ResNet-18 e ResNet-34 chegam em um platô onde o erro do modelo não decrementa. A partir deste momento, a taxa de aprendizagem é subtraída por um valor e em seguida, o modelo volta a melhorar

sua desempenho. Com isso, o modelo com taxas menores consegue fazer ajustes mais finos, ou em outras palavras, dar passos menores.

Figura 5.1: *Learning Rate Decay* aplicado a modelos visuais.



Fonte: [Towards Data Science](#)

## 5.4 Experimentação

Os experimentos foram divididos em etapas, da seguinte forma:

- Primeiro foram testados os seguintes modelos utilizando diferentes configurações: MobileNet, RegNet (X e Y), ShuffleNet, EfficientNet, Inception-V3, ResNet, e ViT. Cada um dos modelos citados anteriormente foram testados com 4 diferentes otimizadores (Adam, RAdam, SGD, Ranger) de parâmetros e 4 valores de taxa de aprendizagem (0.01, 0.001, 0.0001, 0.0005). Ao final desta etapa, foram selecionados os melhores modelos de acordo com a métrica AUC para a próxima etapa. Além disso, esta etapa forneceu o melhor momento para aplicar o *Learning Rate Decay* e o *Early Stopping* para ser utilizado nas próximas etapas.

- Em seguida os melhores K modelos são testado, utilizando decaimento de taxa de aprendizagem e *Early Stopping* utilizando validação cruzada.
- Em seguida, os melhores M modelos dos K foram selecionados e é aplicado o *RandomAugment* ?? para trazer mais diversidade para os dados de treino e verificar o impacto, em questão de desempenho, do *Data Augmentation*

A partir do segundo passo, todos os testes foram feitos utilizando a metodologia validação cruzada citada anteriormente com parâmetro igual 5, ou seja, dividido em 5 grupos. A decisão de aplicar somente a partir do segundo passo é o número exponencial de modelos a serem treinados caso fosse aplicado desde primeiro passo. Em todas as etapas, o número de épocas padrão é 100.

Uma **observação** importante é sobre a separação dos dados de treino e teste. A separação deve acontecer a nível de paciente e não de olho, para que assim, um paciente não tenha dados de um olho no treino e dados de outro olho no teste. Desta modo, evitou-se que houvesse vazamento de dados e o modelo demonstre um desempenho irreal.

Tabela 5.1: Versões dos modelos visuais utilizados como Backbones e o total de parâmetros de cada um. O modelo ViT é o que possui maior número de parâmetros, aproximadamente 86 milhões, enquanto o modelo Shuffle possui somente 2.5 milhões.

| <i><b>Backbone</b></i> | <b>Parâmetros</b> |
|------------------------|-------------------|
| RegNet800MFX           | 6.586.329         |
| RegNet800MFY           | 5.648.297         |
| RegNet1.6GFX           | 8.279.048         |
| RegNet1.6GFY           | 10.314.319        |
| RegNet3.2GFX           | 14.288.561        |
| RegNet3.2GFY           | 17.824.851        |
| MobileV3Large          | 4.203.313         |
| Resnet50               | 23.510.081        |
| EfficientNetb0         | 4.008.829         |
| ShuffleNetV1X1.5       | 2.479.649         |
| VitBase16_224          | 85.799.425        |
| InceptionV3            | 24.346.082        |

Fonte: Elaborado pelo autor.

A tabela ?? possui a versão e o total de parâmetros dos modelos citados na seção ?? implementados dentro da biblioteca Pytorch<sup>9</sup>.

<sup>9</sup>Biblioteca Python de aprendizado de máquina

# Capítulo 6


## Resultados

Neste capítulo iremos apresentar os resultados. Na primeira seção iremos apresentar uma visão geral dos modelos quanto a desempenho relação a nossa métrica principal, AUC ???. Além disso, pela gráfico de perda (loss) teremos um ponto ideal para cada um dos modelos quanto a hora de aplicarmos a técnica de *Learning Rate Decay* ?? para conseguirmos uma desempenho ainda melhor nas próximas etapas.

### 6.1 Desempenho Geral

A figura ?? mostra como foi a desempenho geral dos modelos. Nota-se que os modelos utilizando os dados de OCT atingiram melhores resultados do que aqueles que não usa, tanto para modelos utilizando uma imagem quanto para modelos utilizando duas imagens. A distuição do modelo que não utiliza OCT é menos esparsa quanto aos resultados no teste, com exceção do ViT. Enquanto, os modelos utilizando OCT possuem uma variabilidade maior quanto ao desempenho. Este comportamento é encontrado quanto nos modelos utilizando uma ou duas imagens.

Figura 6.1: Avaliação geral dos modelos divididos em uso de duas imagens e presença das métricas do OCT. O gráfico violino mostra a distribuição dos valores máximos atingidos por cada *backbone*





Fonte: Elaborado pelo autor.

O gráfico ?? usa a média da AUC no treinamento e o valor máximo atingido para comparar os modelos. É perceptível que os modelos estão distribuídos de forma uniforme no gráfico quando comparamos os grupos. Os modelos RegNetY e RegNetX não sobream quando comparados juntos. Além disso, existe uma relação direta entre a média de AUC no treinamento e o valor máximo que essa atinge durante todo o processo, com raros casos de discrepância.

Figura 6.2: Comparação das estatísticas da métrica AUC. O eixo y é o melhor resultado do modelo durante todas as épocas, enquanto o eixo x é a média do modelo durante o treinamento.

(a) Comparação entre grupo de modelos RegNet e todos os outros.

(b) Comparação entre os modelos RegNet por si.



Fonte: Elaborado pelo autor.

As tabelas ?? e ?? resumizam todas as execuções dos *backbone* em todas as arquiteturas discutidas ???. Quanto a máxima AUC atingida pelos modelos, todos estes tiveram valor próximo de 0.93. Quanto as arquiteturas testadas, podemos observar que a presença do OCT traz benefícios para o modelo, aumentando até em 12% o desempenho dos modelos. No entanto, não houve melhora dos modelos quando utilizamos uma ou duas imagens na arquitetura. Dito isso, foi limitado daqui pra frente o uso de modelos utilizando somente uma imagem de entrada.

Tabela 6.1: Tabela contendo os resultados quanto a métrica AUC separado por backbone. Todos os modelos parecem possuir resultados próximos.

| Backbone  | Melhor AUC |      |      |      | AUC Média |      |      |      |
|-----------|------------|------|------|------|-----------|------|------|------|
|           | min        | max  | mean | std  | min       | max  | mean | std  |
| efficient | 0.5        | 0.93 | 0.8  | 0.11 | 0.5       | 0.85 | 0.72 | 0.1  |
| inception | 0.5        | 0.94 | 0.79 | 0.14 | 0.5       | 0.86 | 0.7  | 0.12 |
| mobile    | 0.5        | 0.93 | 0.79 | 0.11 | 0.5       | 0.84 | 0.69 | 0.1  |
| regnet16x | 0.5        | 0.93 | 0.79 | 0.1  | 0.5       | 0.86 | 0.71 | 0.09 |
| regnet16y | 0.5        | 0.94 | 0.79 | 0.11 | 0.5       | 0.87 | 0.71 | 0.09 |
| regnet32x | 0.5        | 0.94 | 0.79 | 0.11 | 0.5       | 0.87 | 0.71 | 0.1  |
| regnet32y | 0.52       | 0.93 | 0.8  | 0.1  | 0.5       | 0.86 | 0.71 | 0.09 |
| regnetx   | 0.5        | 0.94 | 0.79 | 0.11 | 0.5       | 0.86 | 0.71 | 0.09 |
| regnety   | 0.51       | 0.93 | 0.78 | 0.11 | 0.5       | 0.85 | 0.7  | 0.09 |
| resnet    | 0.5        | 0.95 | 0.79 | 0.1  | 0.5       | 0.87 | 0.7  | 0.1  |
| shuffle   | 0.5        | 0.95 | 0.8  | 0.09 | 0.5       | 0.88 | 0.7  | 0.1  |
| vit       | 0.5        | 0.92 | 0.75 | 0.15 | 0.5       | 0.85 | 0.67 | 0.12 |

Fonte: Elaborado pelo autor.

Tabela 6.2: Tabela contendo os resultados separado por dois grupos: OCT e Dual Image. A tabela mostra que Dual Image não trás benefícios, enquanto a utilização do exame OCT agrega performance aos resultados


| Dual Image | Usando OCT | Melhor AUC |      |      |      | AUC Média |      |      |      |
|------------|------------|------------|------|------|------|-----------|------|------|------|
|            |            | min        | max  | mean | std  | min       | max  | mean | std  |
| Não        | Não        | 0.5        | 0.85 | 0.75 | 0.08 | 0.5       | 0.74 | 0.66 | 0.07 |
| Não        | Sim        | 0.5        | 0.95 | 0.85 | 0.1  | 0.5       | 0.88 | 0.75 | 0.1  |
| Sim        | Não        | 0.5        | 0.85 | 0.74 | 0.11 | 0.5       | 0.77 | 0.66 | 0.09 |
| Sim        | Sim        | 0.5        | 0.95 | 0.83 | 0.11 | 0.5       | 0.87 | 0.74 | 0.1  |

Fonte: Elaborado pelo autor.

A distribuição dos desempenhos apresentados na figura ?? mostra uma separação clara entre OCT e não. No entanto, como citado anteriormente não há diferença do modelo utilizando uma ou duas imagens. Dado isso, foi selecionado os melhores 5%, baseado na AUC, dos modelos usando uma image e uma imagem mais os dados de OCT. Para seleção foi utilizado o percentil<sup>1</sup> 95 e todos os modelos abaixo desse valor foram filtrados. Ao final, restaram um total 28 modelos.

<sup>1</sup>Em estatística descritiva, os percentis são medidas que dividem a amostra (por ordem crescente dos dados) em 100 partes, cada uma com uma percentagem de dados aproximadamente igual. O k-ésimo percentil  $P_k$  é o valor  $x$  ( $x_k$ ) que corresponde à frequência cumulativa de  $N.k/100$ , onde  $N$  é o tamanho amostral.


Figura 6.3: Distribuição dos desempenhos separado por arquiteturas de modelos



Fonte: Elaborado pelo autor.

E por último, o gráfico ?? da função de custo durante o treinamento. O gráfico mostrou uma média global de todos os modelos treinados com um intervalo de confiança de 0.95. O gráfico mostra que a partir da época 30 o modelo não consegue ter uma melhoria no seu desempenho. Portanto, é nesse momento que aplicamos o *Early Stopping* e o *Learning Rate Decay* para próxima fase de experimentos utilizando validação cruzada.

Figura 6.4: Comportamento da função de custo durante as épocas de treinamento. O gráfico mostra um valor médio e um intervalo de confiança de 0.95




Fonte: Elaborado pelo autor.

## 6.2 Validação Cruzada e *Learning Rate Decay*

Nesta seção iremos avaliar os melhores modelos selecionados na etapa anterior e verificar seu desempenho utilizando a validação cruzada (?). O total de grupos para experimento foi igual 5, ou seja, cada configuração de hiperparâmetros gerou 5 modelos diferentes, totalizando 140 modelos, com seus respectivos desempenhos. Além disso, foram será ilustrada uma comparação entre a utilização do *Learning Rate Decay* utilizando validação cruzada.

A figura ?? mostra a distribuição do desempenho dos modelos testados. O *Learning Rate Decay* trouxe uma melhora significativa para as duas arquiteturas. Apesar de ter aumentando a variabilidade da AUC, a técnica trouxe benefícios positivos quanto a métrica. O salto maior foi para a arquitetura de modelos utilizando somente imagem.

Figura 6.5: Comparação do uso do *Learning Rate Decay* nos melhores modelos. Os melhores modelos da etapa anterior foram re-executados utilizando validação cruzada para uma comparação justa.



Fonte:

Elaborado pelo autor

A tabela a seguir ?? sumariza as melhorias da aplicação da técnica LRD. A tabela mostra que houve melhorias nas métricas AUC, SP e SN. O modelo que mais se beneficiou foi o modelo RegNet16x quanto a AUC, no entanto possui uma variabilidade alta nos resultados. Outra fator importante foi a perda de desempenho do modelo ResNet. O motivo por trás disto foi que a aplicação da técnica *Early Stopping* fez com que o modelo parasse seu treinamento antes da hora após 10 épocas sem melhorar o desempenho em AUC. O desvio padrão maior está no grupo de médias das métricas, os valores máximos de desempenho atingido pelos modelos trouxeram menos variabilidade. Para os resultados completo, uma tabela contendo os hiperpâmetros utilizados e os resultados detalhados estará presente no apêndice dessa dissertação.

Tabela 6.3: Tabela com os resultados comparando a utilização da técnica LDR na validação cruzada. Foi calculado uma média e desvio padrão entre os *backbones* dos melhores modelos. Os *backbones* com desvio padrão igual a 0 significa que só houve uma arquitetura de modelo entre os modelos utilizando este *backbone*.

| Backbone  | AUC (%)       |                  | SN (%)         |                  | SP (%)        |                |
|-----------|---------------|------------------|----------------|------------------|---------------|----------------|
|           | Melhor        | Média            | Melhor         | Média            | Melhor        | Média          |
| efficient | 5.57 ± (0.0)  | -2.10 ± (0.0)    | 9.65 ± (0.0)   | 0.77 ± (0.0)     | 2.86 ± (0.0)  | 3.56 ± (0.0)   |
| inception | 5.50 ± (4.44) | 5.54 ± (4.06)    | 17.33 ± (8.1)  | 15.8 ± (8.74)    | 2.41 ± (2.1)  | 1.45 ± (4.19)  |
| mobile    | 0.26 ± (0.0)  | 7.79 ± (0.0)     | 8.24 ± (0.0)   | 34.54 ± (0.0)    | 1.83 ± (0.0)  | -0.99 ± (0.0)  |
| regnet16x | 9.01 ± (3.92) | 9.32 ± (2.13)    | 14.58 ± (7.09) | 12.54 ± (12.77)  | 8.88 ± (9.09) | 9.59 ± (10.42) |
| regnet16y | 3.41 ± (3.01) | 4.34 ± (5.8)     | 4.66 ± (4.16)  | 19.1 ± (9.8)     | 3.43 ± (1.48) | 3.32 ± (2.36)  |
| regnet32x | 2.33 ± (5.26) | 6.06 ± (7.63)    | 9.51 ± (8.63)  | 17.62 ± (8.33)   | 0.53 ± (2.63) | -0.53 ± (3.82) |
| regnet32y | 1.38 ± (0.23) | 4.28 ± (4.73)    | 5.62 ± (5.87)  | 9.47 ± (16.26)   | 0.48 ± (1.92) | 1.92 ± (2.57)  |
| regnetx   | 6.61 ± (1.03) | 7.03 ± (3.3)     | 14.18 ± (3.27) | 32.93 ± (13.03)  | 0.95 ± (1.83) | 2.21 ± (0.7)   |
| resnet    | 1.56 ± (1.51) | -10.57 ± (18.94) | 2.73 ± (4.06)  | -28.48 ± (30.21) | 2.31 ± (2.02) | 5.26 ± (4.48)  |
| shuffle   | 1.36 ± (4.13) | 2.14 ± (7.55)    | 5.48 ± (4.56)  | 8.53 ± (20.61)   | 0.88 ± (1.4)  | 1.23 ± (1.89)  |

Fonte: Elaborado pelo autor.

Tabela 6.4: Tabela contendo desempenho do modelo. A memória é medida em megabytes (mb) e o tempo de inferência em milissegundos (ms).

| Backbone  | Memória (mb) | Inferência (ms) | Tamanho Batch |
|-----------|--------------|-----------------|---------------|
| efficient | 3002         | 0.033           | 16            |
| inception | 4747         | 0.041           | 16            |
| mobile    | 1662         | 0.019           | 16            |
| regnet16x | 2405         | 0.022           | 16            |
| regnet16y | 2812         | 0.024           | 16            |
| regnet32x | 3600         | 0.024           | 16            |
| regnet32y | 4182         | 0.027           | 16            |
| regnetx   | 1679         | 0.02            | 16            |
| resnet    | 3762         | 0.044           | 16            |
| shuffle   | 1057         | 0.022           | 16            |

Fonte: Elaborado pelo autor.

Quanto ao uso de memória e tempo de inferência, é possível observar na tabela ?? que os modelos RegNets possuem tempo de inferência próximo dos modelos mais simples, como ShuffleNet e MobileNet, e menor do que os modelos mais complexos, como por exemplo o Inception. Isto proporciona flexibilidade para que o modelo RegNet possa ser utilizado em diferentes contextos que é necessário uma resposta rápida, como por exemplo processamento de quadros de um vídeo ou em algum sistema nuvem que recebe milhares de requisições ao mesmo tempo. Quanto ao uso de memória, os modelos RegNets apresentam versões com diferentes uso de recursos computacionais. Variando de 1600 até 4182 megabytes, o modelo consegue apresentar desempenho melhor ou próximo do que os modelos que utilizam mais memória, e também aqueles que são mais eficientes computacionalmente.

### 6.2.1 *RandAugment*

Dado os resultados da seção anterior, foram selecionados 3 modelos para aplicar *data augmentation*. Um dos hiperparâmetros do *RandAugment* (RandOP na seguinte tabela) é o nome de operações sequenciais em uma foto. Por esse motivo, foram testados diferentes valores para este hiperparâmetro: 1, 2, 3 e 4. Nesta etapa também foi utilizada validação cruzada para avaliar o modelo. A tabela ?? a seguir mostra os resultados dos experimentos e os respectivos hiperparâmetros associados a este experimento:

O *RandAugment* trouxe uma variância menor nas métricas, principalmente na

Tabela 6.5: Experimentos utilizando diferentes parâmetros de *RandAugment* (Coluna *OP*). O número na coluna representa o número de operações seguidas aplicada na imagem.

| Backbone  | Optim  | LR    | OP | OCT | Melhor AUC | AUC Média             | Melhor SP | Melhor SN | SP Médio | SN Médio |
|-----------|--------|-------|----|-----|------------|-----------------------|-----------|-----------|----------|----------|
| inception | ranger | 0.001 | 0  | Não | 0.899      | 0.795 ( $\pm 0.066$ ) | 0.935     | 0.882     | 0.923    | 0.666    |
| inception | ranger | 0.001 | 1  | Não | 0.89       | 0.802 ( $\pm 0.057$ ) | 0.971     | 0.882     | 0.914    | 0.69     |
| inception | ranger | 0.001 | 2  | Não | 0.847      | 0.787 ( $\pm 0.045$ ) | 0.971     | 0.765     | 0.884    | 0.69     |
| inception | ranger | 0.001 | 3  | Não | 0.871      | 0.787 ( $\pm 0.055$ ) | 0.943     | 0.853     | 0.897    | 0.677    |
| inception | ranger | 0.001 | 4  | Não | 0.855      | 0.785 ( $\pm 0.056$ ) | 0.935     | 0.794     | 0.892    | 0.679    |
| regnet16x | radam  | 0.001 | 0  | Não | 0.899      | 0.818 ( $\pm 0.052$ ) | 0.929     | 0.882     | 0.913    | 0.722    |
| regnet16x | radam  | 0.001 | 1  | Não | 0.872      | 0.811 ( $\pm 0.038$ ) | 0.962     | 0.794     | 0.911    | 0.711    |
| regnet16x | radam  | 0.001 | 2  | Não | 0.865      | 0.808 ( $\pm 0.049$ ) | 0.941     | 0.872     | 0.88     | 0.737    |
| regnet16x | radam  | 0.001 | 3  | Não | 0.871      | 0.805 ( $\pm 0.047$ ) | 0.962     | 0.853     | 0.913    | 0.697    |
| regnet16x | radam  | 0.001 | 4  | Não | 0.855      | 0.8 ( $\pm 0.046$ )   | 0.971     | 0.794     | 0.93     | 0.669    |
| regnet16x | radam  | 0.01  | 0  | Sim | 0.991      | 0.927 ( $\pm 0.04$ )  | 0.99      | 1.0       | 0.963    | 0.891    |
| regnet16x | radam  | 0.01  | 1  | Sim | 0.973      | 0.922 ( $\pm 0.031$ ) | 0.991     | 0.955     | 0.945    | 0.9      |
| regnet16x | radam  | 0.01  | 2  | Sim | 0.984      | 0.919 ( $\pm 0.039$ ) | 0.991     | 0.977     | 0.971    | 0.868    |
| regnet16x | radam  | 0.01  | 3  | Sim | 0.984      | 0.93 ( $\pm 0.028$ )  | 0.991     | 0.977     | 0.969    | 0.892    |
| regnet16x | radam  | 0.01  | 4  | Sim | 0.989      | 0.928 ( $\pm 0.038$ ) | 1.0       | 0.977     | 0.954    | 0.902    |

AUC. Dado isso, é possível verificar que o *DataAugmentation* é uma ferramenta para lidar com o problema de sobreajuste ?? dos modelos quando o número de dados disponíveis é pequeno e uma heterogeneidade irá trazer benefícios quanto a generalização do modelo.


## 6.3 Explicabilidade

Nesta seção iremos trazer a explicabilidade dos melhores modelos. O objetivo é entender a interação do modelos com os dados, tanto de imagen quanto os tabulares, para então seja possível entender o porque da decisão do modelo. Iremos avaliar tanto as imagens do fundo do olho e verificar quais foram as partes cruciais das imagens, quanto os valores tabelados contendo as medições e as características criadas e descritas na seção ??.

### 6.3.1 Explicabilidade Visual


A figura abaixo ?? compara duas arquiteturas de modelos. A da esquerda utilizando somente uma imagem e a da direita utilizando duas imagens. Na primeira foto, existe uma concentração de pontos dentro dos círculos e também alguns pontos na linha inferior da imagem. Isto se da ao fato que a arquitetura utilizando somente uma entrada com um modelo visual deve lidar com os dois tipos de imagem citadas ??. No entanto, o modelo da direita reserva um modelo visual pra cada umas das imagens. No entanto, na segunda imagem os dois modelos deram exatamente a mesma explicabilidade para a imagem do fundo do olho. Desta forma, podemos perceber que o modelo utilizando uma imagem consegue se adaptar na utilização de duas imagens de fundo de olho.

Figura 6.6: Imagem com explicabilidade do modelo. Sendo o da esquerda o modelo utilizando somente uma imagem e o da direita utilizando duas imagens. Foto distante.



Fonte: Elaborado pelo autor.

Figura 6.7: Imagem com explicabilidade do modelo. Sendo o da esquerda o modelo utilizando somente uma imagem e o da direita utilizando duas imagens. Foto próxima.



Fonte: Elaborado pelo autor.

A segunda figura ?? de explicabilidade de imagem traz a explicabilidade para imagens mais próximas do fundo do olho, sem a margem preta presente no primeiro tipo ?. O primeiro modelo adaptou a explicabilidade para extrair características desse tipo de imagem, formando círculos e uma pequena concentração arredondada no meio. Da mesma forma como na figura anterior ?, o primeiro modelo possui uma concentração na linha inferior também. Estas concentrações inferior se da ao fato que o disco e copo ótico podem estar em qualquer posição da imagem, e para isto, o modelo precisa analisar todos os cantos possíveis. Um ponto de atenção, é que o modelo utilizando duas imagens como entrada, o da direita, praticamente não extraiu nenhum benefício da segunda foto. Isto corrobora com os resultados obtidos nesta tabela ?, onde o modelo de duas imagens nada acrescenta para o desempenho da tarefa.

E por último, podemos perceber que a explicabilidade é concentrada nas mesmas regiões tanto para identificar a presença do glaucoma quanto a sua ausência. Isto é explicado pela mistura de pontos azuis (diagnóstico negativo) e pontos vermelhos (diagnóstico positivo) se misturando na área da imagem em geral.


### 6.3.2 Importância das Características

Nesta seção iremos avaliar a importância de cada um das características utilizada pelo modelo, inclusive aquelas que foram criadas através de engenharia de características. As análises a seguir mostra quais foram os dados mais importantes para modelo quanto ao seu diagnósticos. Ale disso, será possível verificar como cada um das características influência na decisão do valor a depender do seu valor.

Figura 6.8: Importância das características calculada utilizando o melhor modelo usando OCT ( $AUC = 0.99$ ).

(a) Importância das características nos dados de treino do conjunto AC.

(b) Importância das características nos dados de teste AD.




Fonte: Elaborado pelo autor.

A figura ?? mostra, de cima para baixo, as características mais importantes para os modelos. O gráfico da esquerda é do conjunto AC e o da direita do AD. As 3 primeiras características, valor médio global (G), temporal superior (TS) e temporal inferior (TI) estão nas mesmas posições para os dois conjuntos de dados. Isto mostra, que os dois conjunto de dados possuem distribuição quanto a sua importância. Relativo as outras características, sua importância mudam entre o conjunto de dados, no entanto, nenhuma mudança que seja significativa. As figuras ?? e ?? demonstra que quando a mudança quanto a importância a variação costuma ser de 1,2 ou 3 posições.

Ainda analisando a mesma figura ?? que valores grande para TS/G/TI, ou seja, mais presença de fibras na parte temporal e na média total esta associado a ausência do glaucoma. Outro ponto importante é que os dados afirma que quanto mais avançado a idade maior as chances de diagnosticar o glaucoma. Quanto ao gênero o modelo não trouxe nenhum tipo de relação importante. Para as características criadas sinteticamente, T/TS mostra que quando a razão aumenta, ou seja, quando o total de fibras na região temporal T diminuem, isto ocorre de forma distribuída entre TS e TI, já que se TS diminuísse mais rápido que TI é provável que a razão aumentaria diminuindo as chances do glaucoma.

Para N/TI pode ser o oposto, ou seja, significa que as fibras se degradam mais rápido na área temporal comparado a Nasal (N).

Figura 6.9: Mapa de calor importância das características para os backbones presentes na etapa de validação cruzada. As características estão ordenada de acordo com sua importância geral.




Fonte: Elaborado pelo autor.

O mapa de calor ?? mostra que TS assume um papel importante em quase todos os modelos. Ou seja, podemos dizer que esta característica é de fato importante para diagnóstico do glaucoma pelo exame OCT e deve ser analisada com cuidado pelos profissionais. Em suma, toda as características relacionada a área temporal, com exceção das criadas sinteticamente, ficaram acima das características nasais, dando ainda mais relevância para esta região. A área TI assumiu um papel importante quando se utiliza o *backbone* do modelo Mobile. Outra análise importante é que este mesmo *backbone* trouxe importância para as caraterísticas que envolve gênero e idade, que foi de certa forma irrelevante para os outros modelos. Algumas outras características parece ser irrelevantes para qualquer modelo, como por exemplo: TS/NI, T/NI, TS/NS, NS/NI, T/N, NS/N e TS/TI. Para características não-sintéticas e regionais, a menos relevante para a modelagem foi a área nasal geral (N).

6.3.3 Análise de casos individuais

Neste seção iremos avaliar casos individuais de decisão do modelo. Na primeira parte sera analisado dois casos com glaucoma onde o modelo tomou a decisão certa em um e errou na outra. Para isto, iremos o gráfico de cascata (*waterfall*) do SHAP, onde a temos cada um dos atributos do paciente e como cada um deste contribui em magnitude para a decisão do modelo de acordo com os valores do atributo.


Figura 6.10: Gráfico de cascata para casos com presença de glaucoma.



A figura ?? possui dois gráficos de cascata, sendo o da direita o modelo tomou a decisão correta e o da esquerda errada. O valor abaixo na figura mostra o valor esperado  $E[f(x)]$ , ou seja, a média de decisão do modelo. Para valores acima dessa média o modelo toma o diagnóstico como positivo, caso contrário negativo. A saída do modelo é visto na parte superior do gráfico  $f(x)$ . A média global G foi a característica que mais contribuí para decisão do modelo. Pela distribuição da figura ?? é possível verificarmos que valores de G entre 40 e 70 é composto grupo de pessoas que estão diagnosticado com o Glaucoma. O mesmo vale para TS e para T, apesar da última estar no limiar entre a população com Glaucoma e sem Glaucoma. A idade de 75 anos foi um fator também que contribui para

o modelo diagnosticar como positivo. No gráfico de cascata da esquerda, a característica mais importante foi NS com um valor de 155. Este valor, dado a figura ??, está na cauda da população com Glaucoma e uma concentração maior de casos com a ausência da doença, o que pode ter confundido o modelo.

Figura 6.11: Gráfico de cascata para casos com ausência de glaucoma.



Fonte: Elaborado pelo autor.

Na figura ?? o valor de TS e razão entre T/TS foram o que causaram distorção na saída do modelo. Com a medição de TS igual a 12, a razão ficou 6 vezes maior entre T e TS. O valor de TS pode ser um possível outlier, dado a figura ??, um problema de medição ou apenas um erro esporádica na anotação dos dados. No entanto, de qualquer forma, o modelo foi impactado por este valor e como consequência um diagnóstico positivo errado. Quanto ao diagnóstico da imagem da direita ??, é possível verificarmos que TI tem mais que o dobro de fibra de N e utilizando dessa informação o modelo foi capaz de verificar a ausência do glaucoma.

# Capítulo 7

## Conclusão

Ao final do projeto foi perceptível como os modelos RegNet conseguem ser flexíveis em todos os contextos. O modelo apresentou desempenho ótimo em diferentes arquiteturas de modelos. Dentre os melhores modelos, o modelo RegNet é o que mais aparece com suas diferentes versões quanto ao uso de memória e ao número de parâmetros. Contudo, a escolha do modelo RegNet proporciona uma maior probabilidade de se obter um desempenho na detecção do glaucoma utilizando imagens do fundo do olho e do exame OCT. Além disso, o modelo também apresenta um custo computacional (memória) menor em vários casos e ao mesmo tempo sobresaindo em desempenho, inclusive quanto ao tempo de inferência. Dado isso, é possível que o modelo RegNet seja uma escolha sólida em tarefas de visão computacional que exige eficiência, eficácia e flexibilidade ao mesmo tempo.

O *Rand Augmentation* mostrou benefícios quanto a variabilidade dos resultados, sendo uma ferramenta essencial para evitar o sobreajuste.. Por outra lado, a técnica de *Learning Rate Decay* apresentou benefícios para os modelos, aumentando seu desempenho quanto a métrica AUC e as outras métricas SP e SN, porém, aumentando também a variabilidade do modelo quanto a estas métricas.

O modelo trouxe uma explicabilidade para corroborar com os resultados. A arquitetura que utiliza somente uma imagem como entrada (SI) consegue extrair características de diferentes fotos de fundo de olho, sem a necessidade de se ter um segundo modelo para processamento de uma segunda imagem. As características G, T e TS foram as mais importantes para os modelos utilizando dados clínicos tabulares. Além disso, utilizando casos individuais, conseguimos observar como cada uma das características pode desempenhar um papel fundamental na decisão do modelo, seja ela correta ou não.

## Apêndice A

### Validação Cruzada Resultados

A tabela a seguir mostra os resultados completos obtidos pela utilização do *Learning Decay* (LRD) comparado aos experimentos sem sua utilização (C).

| Backbone   | Optim  | LR    | Usando OCT | AUC    |       |       |       | SP     |       |       |       | SN     |       |       |       |
|------------|--------|-------|------------|--------|-------|-------|-------|--------|-------|-------|-------|--------|-------|-------|-------|
|            |        |       |            | Melhor |       | Média |       | Melhor |       | Média |       | Melhor |       | Média |       |
|            |        |       |            | C      | LRD   | C     | LRD   | C      | LRD   | C     | LRD   | C      | LRD   | C     | LRD   |
| reg-net16x | radam  | 0.001 | Não        | 0.792  | 0.899 | 0.733 | 0.818 | 0.78   | 0.929 | 0.753 | 0.913 | 0.72   | 0.882 | 0.601 | 0.722 |
| reg-net16x | radam  | 0.0   | Não        | 0.828  | 0.888 | 0.746 | 0.801 | 0.874  | 0.924 | 0.857 | 0.906 | 0.783  | 0.853 | 0.711 | 0.695 |
| inception  | ranger | 0.0   | Não        | 0.81   | 0.859 | 0.724 | 0.781 | 0.946  | 0.951 | 0.911 | 0.891 | 0.674  | 0.794 | 0.526 | 0.67  |
| inception  | sgd    | 0.01  | Não        | 0.812  | 0.811 | 0.76  | 0.756 | 0.928  | 0.962 | 0.896 | 0.88  | 0.696  | 0.818 | 0.554 | 0.633 |
| inception  | ranger | 0.001 | Não        | 0.812  | 0.899 | 0.745 | 0.795 | 0.928  | 0.935 | 0.894 | 0.923 | 0.696  | 0.882 | 0.627 | 0.666 |
| reg-net32x | radam  | 0.001 | Não        | 0.849  | 0.882 | 0.763 | 0.805 | 0.937  | 0.947 | 0.906 | 0.905 | 0.761  | 0.882 | 0.59  | 0.706 |
| resnet     | adam   | 0.01  | Sim        | 0.939  | 0.943 | 0.885 | 0.673 | 0.964  | 1.0   | 0.916 | 0.993 | 0.913  | 0.912 | 0.703 | 0.353 |
| resnet     | ranger | 0.01  | Sim        | 0.937  | 0.961 | 0.813 | 0.836 | 0.982  | 0.991 | 0.949 | 0.969 | 0.891  | 0.941 | 0.756 | 0.702 |
| reg-net32y | adam   | 0.0   | Sim        | 0.93   | 0.945 | 0.833 | 0.897 | 0.991  | 0.982 | 0.95  | 0.951 | 0.87   | 0.955 | 0.696 | 0.842 |
| reg-net32y | adam   | 0.01  | Sim        | 0.926  | 0.937 | 0.837 | 0.845 | 0.982  | 1.0   | 0.953 | 0.989 | 0.87   | 0.882 | 0.787 | 0.771 |
| mobile     | radam  | 0.01  | Sim        | 0.926  | 0.928 | 0.828 | 0.892 | 0.982  | 1.0   | 0.955 | 0.946 | 0.87   | 0.941 | 0.623 | 0.839 |
| shuffle    | ranger | 0.01  | Sim        | 0.949  | 0.981 | 0.858 | 0.935 | 0.964  | 0.975 | 0.945 | 0.963 | 0.935  | 1.0   | 0.748 | 0.907 |
| shuffle    | radam  | 0.001 | Sim        | 0.934  | 0.926 | 0.867 | 0.826 | 0.955  | 0.953 | 0.915 | 0.924 | 0.913  | 0.971 | 0.747 | 0.728 |
| shuffle    | ranger | 0.001 | Sim        | 0.932  | 0.903 | 0.829 | 0.795 | 0.973  | 0.971 | 0.939 | 0.927 | 0.891  | 0.882 | 0.776 | 0.663 |

Fonte: Elaborado pelo autor.

| Backbone   | Optim  | LR    | Usando OCT | AUC    |       |       |       | SP     |       |       |       | SN     |       |       |       |
|------------|--------|-------|------------|--------|-------|-------|-------|--------|-------|-------|-------|--------|-------|-------|-------|
|            |        |       |            | Melhor |       | Média |       | Melhor |       | Média |       | Melhor |       | Média |       |
|            |        |       |            | C      | LRD   | C     | LRD   | C      | LRD   | C     | LRD   | C      | LRD   | C     | LRD   |
| shuffle    | radam  | 0.01  | Sim        | 0.932  | 0.989 | 0.865 | 0.937 | 0.973  | 1.0   | 0.945 | 0.976 | 0.891  | 0.977 | 0.691 | 0.897 |
| regnetx    | adam   | 0.01  | Sim        | 0.926  | 0.984 | 0.855 | 0.934 | 0.982  | 0.991 | 0.951 | 0.968 | 0.87   | 0.977 | 0.635 | 0.9   |
| regnetx    | adam   | 0.001 | Sim        | 0.915  | 0.986 | 0.885 | 0.914 | 0.982  | 0.973 | 0.949 | 0.967 | 0.848  | 1.0   | 0.618 | 0.86  |
| regnetx    | radam  | 0.01  | Sim        | 0.932  | 0.986 | 0.859 | 0.933 | 0.973  | 1.0   | 0.94  | 0.968 | 0.891  | 1.0   | 0.76  | 0.897 |
| reg-net16y | ranger | 0.01  | Sim        | 0.932  | 0.973 | 0.829 | 0.89  | 0.973  | 0.991 | 0.94  | 0.947 | 0.891  | 0.955 | 0.74  | 0.833 |
| reg-net16y | adam   | 0.01  | Sim        | 0.939  | 0.939 | 0.884 | 0.863 | 0.964  | 1.0   | 0.941 | 0.991 | 0.913  | 0.912 | 0.712 | 0.815 |
| reg-net16y | radam  | 0.01  | Sim        | 0.934  | 0.989 | 0.864 | 0.933 | 0.955  | 1.0   | 0.936 | 0.973 | 0.913  | 0.977 | 0.685 | 0.893 |
| efficient  | adam   | 0.01  | Sim        | 0.928  | 0.979 | 0.865 | 0.847 | 0.964  | 0.992 | 0.927 | 0.96  | 0.891  | 0.977 | 0.728 | 0.734 |
| reg-net32x | radam  | 0.01  | Sim        | 0.926  | 0.986 | 0.829 | 0.94  | 0.982  | 0.991 | 0.953 | 0.958 | 0.87   | 1.0   | 0.716 | 0.922 |
| reg-net32x | radam  | 0.001 | Sim        | 0.926  | 0.865 | 0.852 | 0.801 | 0.982  | 0.943 | 0.958 | 0.892 | 0.87   | 0.824 | 0.673 | 0.711 |
| reg-net32x | ranger | 0.01  | Sim        | 0.932  | 0.951 | 0.853 | 0.899 | 0.973  | 0.991 | 0.953 | 0.957 | 0.891  | 0.977 | 0.711 | 0.841 |
| reg-net32x | adam   | 0.01  | Sim        | 0.932  | 0.986 | 0.84  | 0.94  | 0.973  | 1.0   | 0.941 | 0.973 | 0.891  | 1.0   | 0.782 | 0.907 |
| reg-net16x | radam  | 0.01  | Sim        | 0.932  | 0.991 | 0.85  | 0.927 | 0.973  | 0.99  | 0.948 | 0.963 | 0.891  | 1.0   | 0.744 | 0.891 |
| inception  | ranger | 0.01  | Sim        | 0.929  | 0.979 | 0.84  | 0.909 | 0.946  | 0.99  | 0.909 | 0.969 | 0.913  | 0.977 | 0.738 | 0.85  |

Fonte: Elaborado pelo autor.