

apter]algoritmololAlgoritmo

UNIVERSIDADE FEDERAL DE MINAS GERAIS
Instituto de Ciências Exatas
Programa de Pós-Graduação em Ciência da Computação

Felipe Glicério Gomes Marcelino

Deteção de Glaucoma Através de Aprendizado de Máquina

Belo Horizonte
2022

Felipe Glicério Gomes Marcelino

Deteção de Glaucoma Através de Aprendizado de Máquina

Versão Final

Dissertação apresentada ao Programa de Pós-Graduação em Ciência da Computação da Universidade Federal de Minas Gerais, como requisito parcial à obtenção do título de Mestre em Ciência da Computação.

Orientador: Adriano Alonso Veloso

Belo Horizonte
2022

[Ficha Catalográfica em formato PDF]

A ficha catalográfica será fornecida pela biblioteca. Ela deve estar em formato PDF e deve ser passada como argumento do comando `ppgccufmg` no arquivo principal `.tex`, conforme o exemplo abaixo:

```
\ppgccufmg{  
    ...  
    fichacatalografica={ficha.pdf}  
}
```

[Folha de Aprovação em formato PDF]

A folha de aprovação deve estar em formato PDF e deve ser passada como argumento do comando `ppgccufmg` no arquivo principal `.tex`, conforme o exemplo abaixo:

```
\ppgccufmg{  
    ...  
    folhadeaprovacao={folha.pdf}  
}
```

Dedicuum cest laborae a quelquis personatum que ajudorat a facirelo.

Agradecimentos

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Sed ut perspiciatis unde omnis iste natus error sit voluptatem accusantium doloremque laudantium, totam rem aperiam, eaque ipsa quae ab illo inventore veritatis et quasi architecto beatae vitae dicta sunt explicabo. Nemo enim ipsam voluptatem quia voluptas sit aspernatur aut odit aut fugit, sed quia consequuntur magni dolores eos qui ratione voluptatem sequi nesciunt. Neque porro quisquam est, qui dolorem ipsum quia dolor sit amet, consectetur, adipisci velit, sed quia non numquam eius modi tempora incidunt ut labore et dolore magnam aliquam quaerat voluptatem. Ut enim ad minima veniam, quis nostrum exercitationem ullam corporis suscipit laboriosam, nisi ut aliquid ex ea commodi consequatur? Quis autem vel eum iure reprehenderit qui in ea voluptate velit esse quam nihil molestiae consequatur, vel illum qui dolorem eum fugiat quo voluptas nulla pariatur?

Resumo

O glaucoma é uma condição capaz de afetar os olhos, causando danos ao nervo ocular e fazendo com que o paciente tenha seu campo visual reduzido aos poucos. Se o glaucoma não for tratado, o paciente pode ser levado à cegueira. Entre os sintomas estão:

- Perda gradual da visão lateral
- Visão embaçada
- Olhos vermelhos e inchados
- Sensibilidade a luz

A doença é bastante comum para pessoas acima de 40 anos, portanto, é recomendável uma visita anual ao médico oftalmologista com o intuito de descartar a presença da doença e que esta se torne intratável. Entre os exames realizados estão imagem do olho e o Tomografia de Coerência Óptica.

Dado isso, utilizando dados de imagens e clínicos, algoritmos de aprendizado de máquina, do inglês *Machine Learning*, vem sendo utilizados para dar suporte aos profissionais com diagnósticos automatizados com rapidez e eficiência. Somado isso, é possível que os diagnósticos tragam uma explicabilidade, dando ainda mais suporte e recursos que o profissional tenha uma decisão mais assertiva quanto ao tratamento.

Diante do exposto, este projeto tem como intuito utilizar modelos de aprendizado de máquina para a detecção do glaucoma. Além disso, o projeto também apresenta múltiplas possibilidades de modelagem do problema, utilizando diferentes estratégias e seus benefícios. Ao final do projeto, não somente é explicitado o desempenho do modelo como também sua eficiência computacional e a explicabilidade por trás das respostas dos modelos de aprendizado de máquina.

Palavras-chave: Aprendizado de Máquina. Computação Visual. Modelagem. Glaucoma. Diagnóstico. Explicabilidade.

Abstract

Glaucoma is a condition that can affect the eyes, causing damage to the ocular nerve and causing the patient's visual field to decrease slowly. If glaucoma is left untreated, the patient can be driven to blindness. Symptoms include:

- Gradual loss of side vision
- blurred vision
- red and swollen eyes
- Sensitivity to light

The disease is quite common for people over 40, so an annual visit to an eye doctor is recommended to detect the presence of the disease and in a positive case, being able to make treatment suitable for the patient to avoid the advance of the disease. Among the tests performed are fundus exams and Optical coherence tomography.

Given this, using the fundus image and clinical data, machine-learning algorithms support professionals with quick, efficient, and automated diagnoses. In addition, the diagnoses may bring an explicability, giving even more support and resources so that the professional has a bold and more fearless decision about the treatment.

Given the above, this project aims to use machine learning models to detect glaucoma. In addition, the project also presents multiple possibilities for modeling the problem, using different strategies and their benefits. Furthermore, this project explains model performance, its computational efficiency, and the explainability behind the answers of the machine learning models.

Keywords: Machine Learning. Computer Vision. Modeling. Glaucoma. Diagnostic. Explainability

Lista de Figuras

1.1	Exemplos de imagem do fundo do olho com presença e ausência de glaucoma.	16
1.2	Exemplo de exame OCT, sendo o olho direito (OD) com a presença de glaucoma e o esquerdo(OS) em estado saudável	17
3.1	Corpo de um modelo RegNet contendo 4 (Fixo) estágios. Cada estágio contém número X de blocos.	29
3.2	Exemplo de um bloco X baseado em uma rede residual.	29
3.3	A imagem da esquerda mostra os <i>Design Spaces</i> A, B, e C, sendo o C mais restritivo entre eles. A imagem da direita mostra a distribuição de erro de cada desses espaços, sendo o C aquele que possui melhor desempenho entre eles.	30
3.4	Uma rede neural MLP, com 3 camadas. Uma de entrada com 3 neurônios, uma camada intermediária com 4 neurônios e uma de saída com dois neurônios. . .	32
3.5	Uma imagem representando o problema de sobreajuste e subajuste.	35
3.6	Exemplo de uma convolução com filtro 5×5. Cada quadrado com este tamanho produz um número com utilizando operações matemáticas. Em seguida, o quadrado é deslocado para o lado ou para baixo e um novo filtro é formado. .	36
3.7	Arquitura de modelos. O <i>backbone</i> pode ser um dos modelos citados anteriormente (RegNet, ResNet, Inception e etc), e o <i>classifier</i> é uma rede neural de múltiplas camadas (MLP), assim como o modelo <i>MLP</i> que recebe os dados tabelados e também o que faz operação de concatenar (<i>concat</i>) juntando todas as saídas e passar para o classificador.	37
3.8	AUC e curva ROC.	39
3.9	Imagem contendo ilustrando a validação cruzada. Cada parte assume o papel de teste uma vez e treino K-1 vezes.	42
3.10	Gráfico sumarizado para o dataset Boston Housing ordenado pelas características mais importantes do modelo.	44
3.11	Explicação de uma imagem utilizando SHAP. Os pontos vermelhos e azul mostram onde o modelo julgou como parte importante para a imagem. Seguindo a mesma lógica do 3.10, pontos vermelhos aumenta a probabilidade na saída do modelo, enquanto pontos azuis diminuem.	45
4.1	Duas imagens do fundo do olho com distâncias diferentes	47
4.2	Contagem de casos de glaucoma por gênero e por olhos	48
4.3	Distribuição do Glaucoma por variável	49

4.4	Boxplot do Glaucoma por variável.	50
4.5	Correlação absoluta das variáveis	51
4.6	Correlação das características criadas pela operação razão.	53
5.1	<i>Learning Rate Decay</i> aplicado a modelos visuais.	57
6.1	Avaliação geral dos modelos divididos em uso de duas imagens e presença das métricas do OCT. O gráfico violino mostra a distribuição dos valores máximos atingidos por cada <i>backbone</i>	61
6.2	Comparação das estatísticas da métrica AUC. O eixo y é o melhor resultado do modelo durante todas as épocas, enquanto o eixo x é a média do modelo durante o treinamento.	62
6.3	Distribuição dos desempenhos separado por arquiteturas de modelos	63
6.4	Comportamento da função de custo durante as épocas de treinamento. O gráfico mostra um valor médio e um intervalo de confiança de 0.95	63
6.5	Comparação do uso do <i>Learning Rate Decay</i> nos melhores modelos. Os melhores modelos da etapa anterior foram re-executados utilizando validação cruzada para uma comparação justa.	64

Lista de Tabelas

3.1	Tabela de restrições dos modelos até chegar no modelo RegNet [49]. O índice i é o estágio, fixado em 4. O b_i representa razão do gargalo, g_i representa o total de canais da convolução, d_i representa o total de blocos e o w_i representa o tamanho do bloco.	30
4.1	Tabela contendo sumarização dos dados utilizando as estatísticas: máximo, mínimo, média, desvio e contagem.	52
5.1	Versões dos modelos visuais utilizados como Backbones e o total de parâmetros de cada um. O modelo ViT é o que possui maior número de parâmetros, aproximadamente 86 milhões, enquanto o modelo Shuffle possui somente 2.5 milhões.	58
6.1	Valores médios, desvio padrão, mínimo e máximo, incluindo todas as arquiteturas visuais, dos modelos backbones em relação a AUC	62
6.2	Valores médios, desvio padrão, mínimo e máximo, incluindo todas as arquiteturas dos modelos, separado por uso de duas imagens e OCT	63
6.3	Resultados comparando a utilização do Learning Decay(ld) e sua ausência nas métricas de AUC, especificidade(sp) e sensibilidade(sn)	65

Lista de Algoritmos

Sumário

1	Introdução	15
1.1	Aprendizado de máquina aplicado a diagnósticos com imagens	17
1.2	Motivação	18
1.2.1	Flexibilidade	18
1.2.2	Explicabilidade	19
1.3	Declaração de Tese	19
1.4	Contribuição	19
1.5	Organização	20
2	Referências Teóricas	21
2.1	Aplicações Gerais	21
2.2	Aplicações de Glaucoma	22
3	Metodologia e Ferramental Teórico	26
3.1	Modelos	26
3.2	RegNet: O modelo mais flexível para visão computacional	27
3.2.1	Parâmetros	28
3.2.2	Estrutura	28
3.3	Conceitos	31
3.3.1	Camadas	31
3.3.2	Pesos ou Parâmetros	31
3.3.3	Taxa de aprendizado	32
3.3.4	Treino, Teste e Inferência	32
3.3.5	Batch e Época	33
3.3.6	Função de perda	34
3.3.7	Otimizadores	34
3.3.8	Hiperparâmetros	34
3.3.9	Sobrajuste	35
3.3.10	Convolução	36
3.4	Arquiteturas	36
3.5	Métricas de Avaliação	38
3.6	RandAugment	40
3.7	Treinamento e Avaliação dos Modelos	41

3.8	Explicabilidade: SHAP	41
4	Sumário e Preprocessamento dos dados	46
4.1	Sumário dos dados	46
4.2	Limpeza	47
4.3	Exploração	48
4.4	Engenharia de características e Normalização	52
5	Experimentos	55
5.1	Setup	55
5.2	<i>Fine-Tuning</i>	55
5.3	<i>Learning Rate Decay</i>	56
5.4	Experimentação	57
6	Resultados	60
6.1	Desempenho Geral	60
6.1.1	Validação Cruzada e <i>Learning Rate Decay</i>	64
6.1.2	<i>RandAugment</i>	66
6.2	Explicabilidade	66
6.2.1	Compara arquitetura 1 olho e dois olhos	67
6.2.2	1 olho e 1 olho + tabular	67
6.2.3	Importância média das features tab	67
6.2.4	Caso positivo e negativo	67
7	Conclusão	68
	Referências Bibliográficas	69

Capítulo 1

Introdução

Glaucoma é uma doença neuropática progressiva que resulta na mudanças de características do disco ótico e causa danos irreversíveis nas fibras nervosas [1]. Apesar de ser irreversível, é possível que com tratamento a evolução da doença seja mais lenta [21]. Uma das formas de diagnóstico do glaucoma é feito através de imagens que requer análise e interpretação de um especialista da área. Dado que o número de pessoas com a doença aumentará em 111,8 milhões até 2040 [2], métodos utilizando inteligência artificial vem sendo utilizados para automatizar o processo [8].


Um dos grandes desafios quanto ao diagnóstico do glaucoma são os aspectos assintomáticos da doença antes dos estágios severos. Dado isso, o número de pessoas não diagnosticadas corretamente é grande [12]. Atualmente, um dos recursos mais utilizados para detectar a doença é a imagem da retina ou imagem do fundo do olho. Com a imagem do fundo do olho é possível verificar o o formato e o tamanho do disco óptico, já que este sofre alterações na presença da doença [67]. Algoritmos de aprendizado por máquina (*machine learning*) são utilizados juntos com imagens de retinas para identificar a doença. Estes algoritmos podem utilizar técnicas de aprendizado estatísticos ou aprendizado profundo [8].

Aprendizado de máquina vem se tornando um dos desenvolvimentos mais importantes no campo de ciência e tecnologia, principalmente na medicina. Classificação é uma das principais técnicas de aprendizado de máquina utilizado no campo médico. Isto porque utilizando modelos classificadores é possível prever diagnósticos de doenças utilizando dados médicos clínicos e exames de imagens. Desta forma, classificação se torna uma técnica inerente para detecção de glaucoma. No futuro, aprendizado de máquina será essencial não somente para diagnosticar mas também para tratar o glaucoma.

O fundoscopia do olho possibilita que especialista consiga identificar todas as estruturas oculares necessárias para identificar o glaucoma, como por exemplo: disco óptico (DO), copo óptico (CO), mácula lútea, fóvea e os vasos sanguíneos [55, 6, 71]. As maiores vantagens de se utilizar a imagem do fundo do olho são: Não é um processo invasivo, é seguro e ajuda na detecção de outras doenças.

O exame OCT para glaucoma é também indicado para diagnosticar e dar suporte na evolução dos tratamentos (médicos ou cirurgia). O OCT permite estudar a espessura da

Figura 1.1: Exemplos de imagem do fundo do olho com presença e ausência de glaucoma.



Fonte: [Nature, 2021](#)


camada de fibras nervosas da retina peri-papilares assim como a escavação do disco ótico. Existem diferentes aparelhos de OCT, que apresentam variadas velocidades e definições de imagem. De qualquer forma, o OCT fornece medições da espessura das fibras em diferentes regiões da retina. Estas medições fornecem aos profissionais um grande número de informações, dando mais recurso para uma melhor avaliação do glaucoma.

A figura 1.1 traz duas imagens de fundo de olho para compararmos o caso em que há presença de glaucoma. É possível ver na segunda imagem do fundo do olho o aumento da proporção entre o copo ótico e o disco ótico (*cup-to-disc*).

A figura 1.2 mostra um exame OCT com suas respectivas medidas de espessura das fibras da retina. A espessura da fibra é dividida em 6 setores: nasal (N), nasal superior (NS), nasal inferior (NI), temporal (T), temporal superior (TS), temporal inferior (TI). Além disso, temos o valor G que é a média dos quadrantes dos setores. Dado isso, quanto menor o valor G maior a probabilidade de se ter glaucoma. A figura 1.2 nos mostra que o olho direito está com as fibras danificadas, com possibilidade de glaucoma, enquanto o olho esquerdo apresenta um estado saudável.

Dado as características citadas acima, a imagem do fundo do olho e OCT são primordialmente utilizados por sistemas inteligentes. Tais sistemas, utilizando exames médicos, são capazes de trazer um diagnóstico e uma segunda opinião, dando suporte ao profissional da saúde. Sistemas inteligentes de diagnósticos são capazes de fornecer interpretações clínicas para auxiliar o profissional nas decisões de tratamento e diminuir as chances de ações prejudiciais ao paciente [27, 53].

Figura 1.2: Exemplo de exame OCT, sendo o olho direito (OD) com a presença de glaucoma e o esquerdo(OS) em estado saudável



Fonte: *Glaucoma Today*, 2016

1.1 Aprendizado de máquina aplicado a diagnósticos com imagens

O desenvolvimento novas tecnologias envolvendo aprendizado de máquina vem mostrando grandes avanços, principalmente no campo médico. O envolvimento da inteligência artificial (IA) em outros campos, fez com que as aplicações de aprendizado de máquina seja interdisciplinar, adentrando soluções que envolve reconhecimento de voz, reconhecimento de objetos, predição de demanda, veículos autônomos e etc. Para a área médica, além do diagnóstico, é possível utilizar IA para descobrir novas drogas, melhorar a comunicação entre médico e paciente, transcrever documentos médicos, como por exemplo receita e também tratamento remoto dos pacientes.

O aprendizado da máquina é uma técnica que utiliza de dados (imagens, videos, áudio, clínicos e etc) para aprender e executar algum tipo de tarefa específica. Em alguns casos, a desempenho de uma IA pode ser melhor do que a do humano em algumas tarefas, como por exemplo na detecção de objetos [51], video games [42], imitação e estilo e arte [22] e em previsões de comportamento [23].

O artigo [7] traz um sumário de técnicas aplicadas no diagnóstico de glaucoma. Os autores coletam artigos durante o ano 2014 e 2019 em que existe um problema de classificação (presença ou ausência do glaucoma). Quanto aos métodos analisados eles se dividem em métodos que extraem as características da imagem e fazem redução de dimensão enquanto outros utilizamos modelos profundos como redes convolucionais (CNN)[25] para detecção direta da doença. A maior influência da escolha do método se resume ao número de dados disponíveis e o custo necessário para processar estas imagens.

1.2 Motivação

Este trabalho tem como objetivo criar um modelo de aprendizado de máquina que seja capaz de auxiliar no diagnóstico do glaucoma de forma eficiente explorando diferentes arquiteturas de modelos de aprendizado de máquina. Adicionado ao diagnóstico, também trazer a explicabilidade do modelo quanto ao diagnóstico. Além disso, com a exploração de diferentes arquiteturas, é possível adaptar o diagnóstico aos recursos disponibilizados. Podendo este recurso ser supercomputadores ou combinações de computadores (cluster¹) ou até mesmo um smartphone com acesso a uma câmera.

1.2.1 Flexibilidade

Sabemos que em distâncias remotas o acesso a saúde é um problema no Brasil. Dado isso, soluções que sejam acessíveis em questão de custo e mobilidade é a opção recomendada. Com isso, o modelo além de trazer o aspecto explicativo para o diagnóstico da doença também irá trazer custo computacional flexível, podendo ser utilizados em diferentes ambientes.

Regiões remotas do Brasil, em que a infra-estrutura de saúde possui poucos recursos acessíveis, modelos de baixo custo é a opção a ser utilizada. Outra opção, seria também adotar um servidor central que irá ficar responsável por executar todo o processo de diagnóstico e tratamento dos dados e retornar o resultado para o profissional responsável.

¹Um cluster (do inglês cluster: 'grupo, aglomerado') consiste em computadores fracamente ou fortemente ligados que trabalham em conjunto, de modo que, em muitos aspectos, podem ser considerados como um único sistema. Diferentemente dos computadores em grade, computadores em cluster têm cada conjunto de nós, para executar a mesma tarefa, controlado e programado por software. Fonte: Wikipédia

Utilizando um servidor central é possível que os dados sejam centralizados e com o passar do tempo o modelo possa ser melhorado com variabilidade maior de dados disponíveis.

1.2.2 Explicabilidade

O modelo também trará aspectos. Esta explicabilidade poderá ser utilizado tanto com arquiteturas mais simples, utilizando somente uma imagem do fundo do olho ou arquiteturas mais complexas, adicionando à imagem os dados demográficos e os resultados do exame OCT do paciente na modelagem.

Desta forma o profissional pode utilizar modelos diferentes de acordo com os dados que estejam disponíveis para ele, dando assim mais flexibilidade para o diagnóstico do glaucoma.

Para explicar os modelos iremos utilizar uma biblioteca conhecida como SHAP [54]. Esta biblioteca será abordada na seção 3.8 com maior detalhes, no entanto, a ideia do SHAP é calcular o impacto de cada uma das características da imagem ou dos dados clínicos quanto ao diagnóstico do modelo.

1.3 Declaração de Tese

A pergunta principal desse projeto é: Modelos computacionalmente eficientes e flexíveis (em termos de usabilidade e acesso) desempenho a tarefa de forma eficaz igual ou melhor do que modelos computacionalmente mais caros e menos flexíveis?

1.4 Contribuição

Este projeto apresenta uma modelagem e análise dos resultados para detecção/diagnóstico do glaucoma utilizando modelos de inteligência artificial. Os modelos aqui apresentados são focados em tarefas que envolvem computação visual, ou seja, quando se utiliza de imagens para resolver uma tarefa.

Será apresentado diferentes modelos com diferentes arquiteturas e hiperparâmetros para verificarmos quais destes modelos se encaixam melhor à questão apresentada anteriormente. Além das arquiteturas, também será analisado a explicabilidade destes modelos, dando recursos para que se possa interpretar os resultados gerado pelos modelos.

Além disso, todos os passos de limpeza e engenharia dos dados também serão explicitadas, e todas as decisões tomadas para que o projeto seja concluído, como por exemplo a seleção dos melhores modelos. Também será apresentado técnicas de manipulações de dados do tipo imagem e tabular para melhorar a desempenho do modelo.

E por fim, teremos o resultado comparando cada um dos modelos experimentados e testados com um intervalo de confiança, levando em consideração também flexibilidade, usabilidade e custo computacional.

1.5 Organização

Esta dissertação está separada em 7 capítulos. O primeiro capítulo 1 contém a introdução, motivação, a pergunta a ser respondida e as contribuições do projeto. O segundo capítulo 2 contém referências teóricas quanto a utilização de modelos de aprendizado de máquina para diagnóstico e detecção de doenças. O terceiro capítulo 3 possui as arquiteturas de redes neurais testadas, as técnicas de manipulação dos dados, métricas utilizadas e técnicas de avaliação e melhoria dos modelos. O quarto capítulo 4 contém todos os passos realizados antes da testagem dos modelos de cada um dos modelos. O quinto capítulo 5 descreve todos os experimentos realizados. O sexto capítulo 6 contém os resultados dos experimentos realizados, contendo as avaliação as métricas escolhidas e também da explicabilidade dos modelos. E o último capítulo 7 conclui esta dissertação.

Capítulo 2

Referências Teóricas

2.1 Aplicações Gerais

Modelos de redes neurais convolucionais possuem múltiplas aplicações, inclusive na detecção de doenças de pele [63]. Neste trabalho os autores exploram diferentes modelos, entre eles RegNet [62] e EfficientNet [59] como modelos mais eficientes, e também modelos tradicionais como ResNet [29] e VGG [38]. Além disso, os autores também trouxeram uma versão modificada do *RandAugment*, explicado na seção 3.6, para melhorar a desempenho do modelo utilizando *Data Augmentation*. Com tudo, utilizando um conjunto de dados extremamente desbalanceado, os autores também criam uma função de aprendizado que leva em consideração o desbalanceamento dos dados. Ao final, os autores apresentaram os resultados dos diferentes modelos, inclusive das versões mais leves computacional do RegNet desempenho próximo, igual ou até melhor do que os modelos tradicionais custosos.

Utilizando modelos de computacionais visuais, é possível identificar doenças nas folhas da maçã [35]. De acordo com os autores, o conjunto de dados é pequeno, com um total de 2200 imagens aproximadamente e 5 diferentes doenças para serem detectadas. Os modelos testados foram ShuffleNet, EfficientNet-B0, MobileNetV3, RegNet e ViT [68, 59, 62, 31, 70]. Dentre os modelos citados anteriormente, o que atingiu a melhor acurácia de 99.8% foi o modelo RegNet. Todos os modelos foram treinados com 4 diferentes otimizadores, explicado na seção 3.3.7, e 5 diferentes taxa de aprendizado 3.3.3.

Utilizando uma combinação de imagens e dados clínicos, é possível utilizar de modelos de aprendizado de máquina para detectar cancer de mama [58]. O modelo convolucional processa múltiplas imagens com diferentes ângulos de uma tomografia do torax. Cada imagem é processada por um modelo independente, ou seja, eles não compartilham os pesos e parâmetros entre si 3.3.2. Os dados clínicos, contendo idade, histórico da família em relação ao cancer, presença de diabetes, é processado por uma outra rede neural multicamadas 3.1. Ao final, os resultados é concatenados por uma outra rede neural multicamadas e em seguida o modelo faz o diagnóstico quanto a presença do cancer. Os autores concluem que a adição de um modelo convolucional com múltiplas entradas

(*multi-input*) e dados clínicos conseguem trazer resultados melhores do que o modelo utilizando somente uma imagem (*single-input*) frontal do torax.

É possível de utilizar modelos de IA para detectar doenças cardiovasculares [4]. Os modelos foram divididos em dois grupos: *single-input* e *multi-input*. As arquiteturas *single-input* utilizam o modelo visual Inception-V3 [57] quando os dados é imagem, e utilizam redes neurais multicamadas e modelos de árvore de decisão [10] com os dados clínicos. Quanto a arquitetura *multi-input* utiliza o modelo Inception-V3 para os dados de imagem e o de redes neurais multicamadas para passar processar os dados clínicos e concatenar a saída dos dois modelos. O modelo *multi-input* atingiu uma acurácia 0.79 enquanto o *single-input* atingiu uma acurácia de 0.75.

Utilizando *Visual Transformers* (ViT) [3.1], foi capaz de detectar Pneumonia nos pulmões, inclusive quando adivindo do Covid-19 [14]. Utilizando tomografia computadorizada, a imagem em dividida em vários pedaços e cada um destes pedaços é codificados dentro do modelo ViT e em seguida repassado para uma rede neural multicamadas para diagnosticar a imagem com a presença de pneumonia (Ocasionalada pelo vírus da COVID-10 ou outro vírus) ou não. Ao final, o modelo dos autores apresentaram uma acurácia de 97% na detecção da doença.

O trabalho apresentado a seguir traz a uma forma diferente de trabalhar com redes neurais convolucionais utilizando um modelo conhecido como DCGAN [9]. Os modelos DCGAN são baseados em modelos neurais generativos [25, 26]. O intuito destes modelos é utilizar dados reais para criar dados que sejam sintéticos e próximo da distribuição dos dados reais. Para isso, o modelo se divide em duas partes: codificador e decodificador. O modelo codificador aprenda uma representação vetorial dos dados de entrada, enquanto o decodificador processa essa representação vetorial e tenta criar uma amostra parecida com a original. Neste artigo [9], os autores utilizaram o modelo DCGAN para criar representação vetorial que consiga explicar a distribuição dos dados. E em seguida, os autores utilizaram essa representação em um modelo classificador baseado em regressão logística para detectar a presença de Alzheimer nos pacientes. Os dados utilizado pelo modelo DCGAN são imagens neurais multimodais.

2.2 Aplicações de Glaucoma

É possível utilizar dedes neurais convolucionais, mais especificamente uma Res-Net34 pre-treinada, para poder prever a espessura das camadas das fibras nervosas do disco ótico [41]. Para evitar que que haja qualquer tipo de vazamento de dados entre os dados de treino e de teste [3.7], a divisão dos dados foram feita por paciente, desta

forma nenhum dado de paciente está presente no treino e no teste ao mesmo tempo. As imagens foram padronizadas altura e largura de 256×256 pixels, e os valores de pixels foram normalizados entre 0 e 1. Adicionado a isso, foram utilizados algumas técnicas de *data augmentation* para aumentar o número de variabilidade das amostras do conjunto de dados, dando mais recurso para o modelo treinar sem precisar coletar mais dados. Contudo, um modelo binário foi treinado para detectar anormalidades (ou normalidades) na espessura das fibras utilizando fotografias do disco ótico. As métricas utilizadas foram MAE (*Mean Absolute Error*) para predição da espessura da fibra e AUC (*Area under the ROC curve*) para a classificação binária. Dado um total de aproximadamente 1200 amostras (pacientes), com um total de 2312 olhos, os modelos apresentaram resultados de 0.944 para curva ROC, uma acurácia de 83.7% e um erro de predição (MAE) da espessura da fibra de aproximadamente 7.39 micromilímetros.

Neste trabalho, a imagem do fundo do olho foi utilizada para extrair uma característica da imagem utilizando redes CNN, que o autor deu nome de *CNN Degree* [44]. Além da característica extraída pelas redes CNNs, foram também utilizados dados clínicos para o segundo modelo preditor final, como por exemplo: espessura da fibra (temporal, nasal, inferior, superior), espessura da cornea, tamanho do copo e do disco, idade, sexo do paciente e etc. Para o modelo preditor final, foram utilizados modelos com estruturas diferentes. Estes modelos além de usar a característica extraída da CNN, também irá utilizar dados clínicos para diagnosticar o glaucoma, dentre eles estão: *support vector machine (SVM)*, *random forest*, *C5.0* e *XGBoost*. As métricas utilizadas foram AUC, ROC, sensibilidade e especificidade. Ao final os autores constataram que melhor modelo foi o XGBoost, apresentando AUC igual a 0.945, sensibilidade de 0.950 e especificidade de 0.945. Além disso, os autores apresentaram explicabilidade para o modelo, sendo a característica mais importante a espessura das camada das fibra da nervosas da retina superior (*RFNLsuperior*), apontando pessoas com glaucoma apresenta valores menores para essa caracterísitca e pessoas saudáveis o oposto. Em segundo lugar o modelo apontou *RNFLinferior* e em terceiro lugar a pressão intracocular (*IOP*) como características mais importantes.

O próximo artigo utiliza o modelo Inception-V3 [57] para detecção do Glaucoma [36]. O autor também traz técnicas de Data Augmentation 3.6 para aumentar heterogeneidade dos dados mas mantendo características prognósticas das imagens. As fotos foram padronizadas para o tamanho 299×299 e os pixels foram normalizados entre 0 e 1. Quanto ao Data Augmentation, foram aplicado as seguintes operações: rotações randomizadas de 90, 180 e 270 graus e também um deslocamento entre 0 e 3 pixels na horizontal. Este último é aplicado para aumentar o detalhe de captura das imagens sem a necessidade de aumentar o número de pixels da mesma. Quanto aos parâmetros do treino, o autor utilizou o otimizador Adam [33] com um taxa de aprendizagem de 0.002 e um tamanho de *batch* de 32 imagens. Com um total de 48 mil imagens e dentro de um intervalo de

confiança de 95%, o autor atinge um desempenho de AUC entre 0.984 e 0.988. Além disso o autor aponta quais foram as características que mais gerou falso negativo:

- Glaucoma normal aparece junto com outras doenças, como por exemplo miopia, retinopatia diabética e degeneração macular devido a idade.
- Defeito nas camadas das fibras nervosas da retina ou disco ótico apresentam hemorragias.

Para um uso mais extensivo ao público, é possível misturar um acesso público e aprendizado de máquina para detecção do Glaucoma [20]. Esta framework¹ é acessível para o público envia as fotos do fundo dos olhos e em seguida recebe o resultado do modelo. Se o resultado for negativo é enviado direto para o paciente. Caso resultado seja positivo, este é enviado para um oftalmologista para uma análise mais profunda. A framework é dividida em duas partes: a parte pública onde as pessoas podem carregar as imagens do fundo do olho e a parte privada, onde é feito todo o processamento e a geração do relatório. O acesso público pode ser pela web ou por um dispositivo móvel. O resultado é baseado na proporção entre o disco e o copo ótico (CDR). Se o CDR é maior que 0.5 o modelo retorna possibilidade de glaucoma. Para segmentar e classificar a imagem, os modelos utilizados foram: EfficientNet [59] (Codificador) e UNet++ [70] (Decodificador). O codificador cria um mapa de características que será decodificado, pelo decodificador, de forma que cada segmento da imagem seja separado e o CDR seja calculado. O acesso ao banco de dados também é gerenciado por um servidor público, de forma que todas as pessoas tenham acesso. Enquanto o processamento da imagem é feito por um servidor privado.

O seguinte trabalho compara a acurácia do modelo de aprendizado de máquina quanto as fotos coletadas utilizando a câmera padrão dos centros óticos e das fotos coletadas utilizando um smartphone e um aparelho acoplado D-Eye Lens [43]. O autor descreve que a utilização do smartphone possibilita que mais pessoas sejam avaliadas devido ao fácil acesso e manuseio do dispositivo. Para capturar as fotos pelo smartphone um vídeo de 1 minuto é gravado, e deste vídeo, uma imagem é extraída, sendo a imagem a que melhor captura o disco ótico. Além de possibilitar que pacientes com demência também sejam diagnosticados. Os autores utilizaram uma ResNet para classificar a presença do glaucoma. Quanto aos dados foram utilizadas técnicas de *Data Augmentation*, abordado na seção 3.6, para diversificar o dado e por consequência melhorar o desempenho do modelo quanto a generalização. Dentre elas, estão: rotação da imagem (10 graus), translação vertical e horizontal, mudança de contraste e saturação de forma randômica e variação

¹Um framework em desenvolvimento de software, é uma abstração que une códigos comuns entre vários projetos de software provendo uma funcionalidade genérica. Um framework pode atingir uma funcionalidade específica, por configuração, durante a programação de uma aplicação. Ao contrário das bibliotecas, é o framework quem dita o fluxo de controle da aplicação, chamado de Inversão de Controle. Fonte: Wikipedia

do tamanho das bordas da imagem. O modelo apresentou um desempenho AUC de 0.98 para a câmera padrão e 0.84 para o uso do smartphone. O autor discute que a diferença de desempenho, que apesar de boa é menor que a câmera tradicional, se dá pela capacidade de foco da câmera, gerando imagens que nem sempre possuem uma qualidade adequada para uma avaliação mais assertiva.

Capítulo 3

Metodologia e Ferramental Teórico

3.1 Modelos

Os modelos mencionados a seguir são modelos focados em visão computacional. Todos os modelos são baseados em redes neurais convolucionais, com exceção do modelo ViT, do inglês *Vision Transformers*. Para uma melhor experimentação para diagnosticar o glaucoma, diferentes modelos foram testados. Com intuito de trazer mais flexibilidade ao diagnóstico de glaucoma, foram testados modelos com número de parâmetros reduzidos e consequentemente com requisitos menor de poder computacional. Alguns dos modelos são capazes de serem executados em dispositivos menores, como por exemplo um smartphone. Outros modelos trazem rápida inferência quando a carga de acesso à uma aplicação pode ser alta e é necessário que o modelo responda rápido. Mas também, modelos com uso maior de poder computacional, com intuito em alcançar um desempenho melhor quanto a assertividade do modelo, foram incluídos nos experimentos. Toda a experimentação é com objetivo de trazer diferentes flexibilidade, à depender da infraestrutura disponível, de forma que os modelos sejam capazes de serem utilizados em múltiplos cenários. Logo, os modelos testados foram: RegNet, MobileNet, ShuffleNet, EfficientNet, ResNet, Inception-V3, ViT [62, 31, 68, 29, 57, 18, 59]

Cada um dos modelos citados anteriormente possui suas vantagens. A MobileNet, como o próprio nome já diz, é otimizada para rodar em celulares ou dispositivos menores do que um computador [31]. As redes MobileNet, são menores do que as redes convolucionais tradicionais, por isso utilizam menos energia, para atender recursos limitados, e também possuem baixa latência para ter respostas rápidas. A EfficientNet, tem como objetivo ser eficiente em tarefas que envolve reconhecimento visual. Estas redes podem ser escaladas facilmente para ser utilizadas em larga escala ou melhorar seu desempenho sem trazer custos adicionais exagerados e de forma simples [59]. A ShuffleNet traz uma rede neural que seria o extremo de redução de custo tentando manter a acurácia do modelo. A ShuffleNet pode ter uma eficiência 13 vezes uma ResNet sem perder muito de seu desempenho quanto a acurácia do modelo. ShuffleNet possui o número de operação

por segundo reduzidas (MFLOps¹) e também o tempo de resposta [68].

Quanto aos modelos mais custosos, temos ViT, Inception-V3 e ResNet. A ResNet traz um modelo robusto com um desempenho em acurácia alta devido ao número de parâmetros [29]. As ViT são redes neurais que conseguem trazer capacidade de aprendizado mesmo com um número pequeno de dados mas mantendo o poder computacional das redes neurais convolucionais mais profundas como a ResNet citado anteriormente. Como toda rede neural, quanto mais dados disponíveis melhor será o poder de generalizar da rede, no entanto, redes neurais ViT apresentam resultados melhores utilizando técnicas de *self-attention* [34, 18]

E além dos modelos convolucionais citados acima iremos também utilizar um modelo de múltiplas camadas conhecida como MLP, ou do inglês *Multi Layer Perceptron*. As MLP são modelos mais simples, no entanto, com alto poder de generalização. Neste projeto, os modelos MLP serão utilizados na parte de classificação e concatenação das arquiteturas que serão citadas na próxima seção 3.4.

3.2 RegNet: O modelo mais flexível para visão computacional

O modelo RegNet é um tipo de rede neural criada através de um *Network Design Space* (NDS). Diferente dos modelos de arquitetura padrão, onde existe uma arquitetura que foi descoberta através de NAS² [72], o RegNet é um espaço contendo todas as redes neurais possíveis dado um grupo de parâmetros. Ou seja, NDS fornece um mecanismo de testagem de arquiteturas mais sofisticado, sem a necessidade de testar cada uma das arquiteturas, mas sim uma amostragem dela, reduzindo custo computacional, e ao mesmo tempo fornece modelos simples e performáticos, já que este consegue trazer uma experimentação/testagem/amostragem mais robustas.

O NDS é um conjunto de possíveis arquiteturas dentro de um espaço de busca. Em cada iteração, esse espaço de amostragem é restringido com o intuito de criar obter redes neurais com desempenho maior ou pelo menos igual, no entanto, utilizando uma arquitetura muito mais simples. Desta forma, com a amostragem, é possível verificar que utilizando uma certa combinação de grupo de parâmetros, conseguimos testar se uma população amostral de arquitetura de redes neurais, consegue desempenhar bem em

¹Medida de operação de ponto flutuante por segundo. Quanto menor este número para uma rede neural menos energia é gasta para ser calculado os resultados.

²*Neural Architecture Search* é uma técnica de automatizar o processo de busca de arquitetura de redes neurais, desempenhando melhor do que redes neurais montadas manualmente.

um problema ao invés de procurar uma arquitetura única que traga o melhor resultado possível, como é utilizado na metodologia NAS[72].

Dentre os parâmetros e estruturas de uma RegNet, esta é composta por:

3.2.1 Parâmetros

- Total de blocos: Cada bloco é composto por um grupo de convoluções 3.3.10.
- Largura do bloco: Total de canais 3.3.10 de cada um das convoluções.
- Razão do gargalo: Utilizado para diminuir o número de canais entre uma convolução e outra, diminuindo o total de operações a serem executadas.
- Largura do grupo: Total de convoluções para cada bloco.

3.2.2 Estrutura

- Tronco: Contém as camadas 3.3.1 de entrada da rede neural.
- Corpo: A parte principal da rede neural, sendo esta a estrutura que vai ser influenciada pelos parâmetros citados acima.
- head: Camada de saída do modelo, contendo o classificador.


A figura a seguir 3.1, apresenta um modelo RegNet.

Um ponto de atenção citado pelos autores é a decisão de manter todos os blocos iguais e com a mesma estrutura de uma ResNet [29]. A imagem 3.2 a seguir exemplifica:

A tabela 3.1 explica um pouco como o modelo RegNet é montado. Como citado anteriormente, é possíveis infinitas combinações de arquitetura de redes neurais dependendo dos parâmetros a serem testados. A primeira arquitetura de rede neural, **AnyNetA**, não possui nenhuma restrição, totalizando aproximadamente $1.8 \cdot 10^{18}$ combinações possíveis. No último modelo, após adicionar todas as restrições e avaliar todas as **AnyNets** o modelo enfim chega no Regnet utilizando uma metodologia conhecida como *quantized linear parameterization*, para que todos os blocos do mesmo estágio tenham o mesmo tamanho.

A desempenho dos modelos amostrados do NDS é calculada através de um procedimento que se resume em treinar o modelo no conjunto de dados ImageNet [17] por 10

Figura 3.1: Corpo de um modelo RegNet contendo 4 (Fixo) estágios. Cada estágio contém número X de blocos.



Fonte: Imagem retirada do artigo [49].

Figura 3.2: Exemplo de um bloco X baseado em uma rede residual.





Imagem retirada do artigo [49].

Tabela 3.1: Tabela de restrições dos modelos até chegar no modelo RegNet [49]. O índice i é o estágio, fixado em 4. O b_i representa razão do gargalo, g_i representa o total de canais da convolução, d_i representa o total de blocos e o w_i representa o tamanho do bloco.

	restriction	dim.	combinations	total
AnyNet _A	none	16	$(16 \cdot 128 \cdot 3 \cdot 6)^4$	$\sim 1.8 \cdot 10^{18}$
AnyNet _B	$+b_{i+1} = b_i$	13	$(16 \cdot 128 \cdot 6)^4 \cdot 3$	$\sim 6.8 \cdot 10^{16}$
AnyNet _C	$+g_{i+1} = g_i$	10	$(16 \cdot 128)^4 \cdot 3 \cdot 6$	$\sim 3.2 \cdot 10^{14}$
AnyNet _D	$+w_{i+1} \geq w_i$	10	$(16 \cdot 128)^4 \cdot 3 \cdot 6 / (4!)$	$\sim 1.3 \cdot 10^{13}$
AnyNet	$+d_{i+1} \geq d_i$	10	$(16 \cdot 128)^4 \cdot 3 \cdot 6 / (4!)^2$	$\sim 5.5 \cdot 10^{11}$
RegNet	quantized linear	6	$\sim 64^4 \cdot 6 \cdot 3$	$\sim 3.0 \cdot 10^8$

Figura 3.3: A imagem da esquerda mostra os *Design Spaces* A, B, e C, sendo o C mais restritivo entre eles. A imagem da direita mostra a distribuição de erro de cada desses espaços, sendo o C aquele que possui melhor desempenho entre eles.



Fonte: Imagem retirada do artigo [49].

épocas 3.3.5 e calcular o erro de inferência nesse mesmo conjunto de dados. É amostrado em torno de 100 modelos para cada NDS com seu conjunto de parâmetros e restrições.

Ao final, os autores chegam a conclusão que os modelos amostrados do espaço **RegNet** possuem desempenho melhor do que os modelos amostrados do **AnyNet** para qualquer valor dos parâmetros escolhidos. Além disso, os autores apresentam o modelo **RegNetY** que é uma variação do **RegNetX** contendo uma técnica conhecida como *squeeze-and-excitation* [32] para que cada bloco seja capaz de adaptar os pesos para capturar as partes mais importantes da imagem com um adicional de custo computacional baixo.

3.3 Conceitos

3.3.1 Camadas


As camadas são onde se encontra os neurônios ou unidades de processamento. Um rede neural normalmente possui múltiplas camadas, ou pelo menos duas, camada de entrada e saída. Quanto mais camada a rede neural possui mais profunda ela é, ou seja, mais neurônios são utilizados. No entanto, é necessário tomar cuidado, pois quanto mais neurônios mais calculos e dados são necessários para utilizar o modelo, demandando mais poder computacional.

3.3.2 Pesos ou Parâmetros

As redes neurais é composta por várias unidades de processamento, cujo o funcionamento é o mais simples possível. As unidades das redes neurais, conhecido também como neurônios, são interligados entre si, e cada um dessas unidades possui um peso, também conhecido como parâmetro. As unidades fazem operações matematicas com os dados locais, sendo estes dados as entradas processada por outra unidade de processamento ou uma tabela de dados se esta unidade estiver na primeira camada do modelo, também conhecida como camada de entrada, do inglês *input layer*.

A figura 3.4 representa uma MLP contendo três camadas. Uma camada de entrada, uma camada intermediária e uma camada de saída. Cada uma desses camadas possui um número N de neurônios. Cada neurônio, ou unidade de processamento, possui conexões com outras unidades, sendo essa conexão seria o **peso** ou **parâmetro**. O peso então é multiplicado pela saída de um neurônio que entra em um próximo neurônio. Dentro do neurônio, todas as entradas são somadas e em seguida passa o resultado da soma em uma função de ativação, como por exemplo uma sigmoid [25], para transformar ou limitar os valores. Todos os neurônios de uma camada possui ligações com todos os neurônios da próxima camada.

Figura 3.4: Uma rede neural MLP, com 3 camadas. Uma de entrada com 3 neurônios, uma camada intermediária com 4 neurônios e uma de saída com dois neurônios.



Fonte: Imagem elaborada pelo autor.

3.3.3 Taxa de aprendizado

A taxa de aprendizado é o valor de atualização dos pesos. Toda vez que uma rede neural erra sua previsão ou resposta, é necessário que estes pesos se ajustem, de forma a diminuir o valor do erro. A taxa de aprendizado é o tanto que esta atualização vai mudar o peso. Quanto mais alta a atualização maior o valor atualizado, e quanto menor menor será essa mudança. É necessário balancear este valor para que as atualizações sejam em tamanho corretos para que o modelo consiga chegar em um mínimo local quanto a métrica de erro [25].

3.3.4 Treino, Teste e Inferência

O processo passa se obter e usar um modelo de aprendizado de máquina é divide em três fases: treino, teste e inferência. O treino é a fase onde ajustamos os parâmetros

do modelo para que ele complete uma tarefa da melhor forma possível, que neste projeto seria diagnosticar o glaucoma. O teste é a fase onde avaliamos a desempenho do modelo utilizando as métricas previamente estabelecidas. E a fase de inferência é quando um modelo já treinado e avaliado será utilizado pelo público alvo. Normalmente, os modelos na fase de inferência são colocados na nuvem³ ou em alguma infraestrutura computacional local para que possam ser acessados e utilizados e por consequência traga valor para o negócio [25].

Cada uma dessas fases possuem seu conjunto de dados. É necessário ressaltar que se deve ter cuidado em dividir o conjunto de dados do treinamento e do teste para que não haja vazamento de dados entre os dois conjuntos e o modelo atinja uma desempenho que não representa a realidade. O conjunto de dados da inferência vem da utilização do modelo, ou seja, todos aqueles dados que não estavam presente dentro do conjunto de treino e teste e é totalmente novo para o modelo. Após um certo tempo, normalmente incluem os dados de inferência dentro do conjunto de dados de treino e teste e o modelo é retreinado e reavaliado.

3.3.5 Batch e Época

O treinamento se divide em épocas. Cada época é uma passagem por todos os dados dentro do conjunto de dados treinamento e teste para o modelo, para que este então possa ajustar os seus pesos (parâmetros). No entanto, não é possível passar todos os dados para o modelo de uma única vez devido ao custo computacional e ao tamanho limitado da memória. Logo, os dados é divididos em *minibatches* que nada mais são que um subgrupo de um grupo de dados. O tamanho deste subgrupo é ajustado de acordo com a tarefa e recursos computacionais disponíveis. No entanto, o ideal é que ele seja menor que o grupo todo e maior do que 1. Neste último caso, o modelo precisará fazer muitas atualizações e também usara recurso computacional excessivamente, além de que, a generalização poderá ser afetada para pior já que 1 amostra dificilmente irá representar ou aproximar mínimamente a distribuição de dados do conjunto todo [25].

³Infraestrutura de computação necessários para rodar uma aplicação que seja acessado através da internet. Os recursos virtuais refletem uma infraestrutura física local, com servidores, memórias, clusters e armazenamentos. Tudo isso voltado para uma escalabilidade e fácil uso.

3.3.6 Função de perda

A função de perda mede o quão longe da resposta correta o modelo está. Também conhecida como **função de custo**, esta função irá indicar a qualidade do modelo e quais são os valores de atualização necessárias para os parâmetros utilizando apenas um número real. O que esta função faz é comparar o que é conhecido como *ground truth*⁴ com a saída do modelo. Neste projeto o *ground truth* é a classe dos dados, indicando presença ou ausência do glaucoma.

3.3.7 Otimizadores


Os otimizadores são algoritmos ou funções responsáveis por atualizar os parâmetros dos modelos. O otimizador acha o melhor valor para esses parâmetros com o objetivo de diminuir o erro do modelo em uma devida tarefa. Dado isso, o otimizador recebe os parâmetros do modelo, a taxa de aprendizado e o erro através da função de custo, e com todos estes recursos e dados, o otimizador escolhe a melhor atualização para os parâmetros. Contudo, é essencial escolher o melhor otimizador para cada uma das tarefas ou modelos que serão utilizados. Desta forma, o aprendizado do modelo possa ser efetivo e o modelo consiga desempenhar com qualidade.

3.3.8 Hiperparâmetros

Os hiperparâmetros dos modelos são configurações de cada um destes modelos ligado ao processo de aprendizado. Por exemplo, citado anteriormente [3.3.3](#), a taxa de aprendizado é um hiperparâmetro a ser escolhido e indica a magnitude de atualização dos parâmetros. Outro hiperparâmetro é o tamanho do *minibatch* [3.3.5](#) e também qual otimizador [3.3.7](#) será utilizado [\[25\]](#). Normalmente, para encontrar os melhores hiperparâmetros para o modelo é necessário repetir o processo de treino e teste múltiplas vezes, tornando este processo extremamente caro.

⁴ *Ground truth* é uma informação que sabemos que é real utilizando métricas ou através da observação.

Figura 3.5: Uma imagem representando o problema de sobreajuste e subajuste.




Fonte: IBM

3.3.9 Sobreajuste

O sobreajuste, do inglês *overfitting*, é um cenário onde o modelo se ajusta de forma quase que perfeita para um conjunto de dados X e por consequência, acaba tendo uma perda de desempenho no conjunto de dados Y que possui uma distribuição diferente de X. É ideal que o modelo consiga generalizar bem para todos os conjuntos de dados disponíveis, no entanto, é praticamente impossível já que qualquer comportamento diferente nos dados pode causar distribuições totalmente diferentes entre eles. Logo, se conjunto de dados X e Y possuem distribuições próximas, mas não iguais, é possível utilizar de um para conseguir inferir o outro. Portanto, se o modelo sobreajusta para X e tenta inferir Y, este modelo irá ter um erro grande quanto a sua inferência, já que apesar das distribuições serem próximas, a distribuição de X é diferente de Y [25].

Com isto, para se evitar o sobreajuste do modelo, este projeto aplicou uma técnica conhecida como *Early Stopping* 3.7. A técnica tem como intuito parar o processo de treinamento quando o modelo começa a aumentar sua desempenho no conjunto de dados de treino (X) e sofre uma piora significativa no conjunto de dados de teste (Y) utilizado para avaliação. A figura 3.5 a seguir mostra visualmente como acontece o sobreajuste.

Figura 3.6: Exemplo de uma convolução com filtro 5×5 . Cada quadrado com este tamanho produz um número com utilizando operações matemáticas. Em seguida, o quadrado é deslocado para o lado ou para baixo e um novo filtro é formado.



3.3.10 Convolução

As convoluções funcionam como filtros que enxergam pequenos quadrados e vão “escorregando” por toda a imagem captando os traços mais marcantes. Explicando melhor, com uma imagem $32 \times 32 \times 3$ e um filtro que cobre uma área de 5×5 da imagem com movimento de 2 saltos (chamado de stride), o filtro passará pela imagem inteira, por cada um dos canais, formando no final um *feature map* ou *activation map* de $28 \times 28 \times 1$. A [image 3.6](#) mostra como uma convolução funciona.


A profundidade da saída de uma convolução é igual a quantidade de filtros aplicados (Total de canais). Quanto mais profundas são as camadas das convoluções, mais detalhados são os traços identificados com o *activation map*. No entanto, quanto maior o número de canais, maior será o número de operações e consequentemente uma demanda maior de hardware.

3.4 Arquiteturas


Neste projeto foram testadas 4 arquiteturas de modelos. Não confundir com arquitetura de redes neurais. Cada uma das arquiteturas visuais apresentadas a seguir será testada com diferentes combinações de hiperparâmetros. O intuito de testar diferentes arquiteturas é que cada uma delas pode se sair melhor à depender da tarefa a ser realizada e os dados disponíveis. Dado isso, iremos testar as seguintes arquiteturas mostradas na [figura 3.7](#).

Figura 3.7: Arquitetura de modelos. O *backbone* pode ser um dos modelos citados anteriormente (RegNet, ResNet, Inception e etc), e o *classifier* é uma rede neural de múltiplas camadas (MLP), assim como o modelo *MLP* que recebe os dados tabelados e também o que faz operação de concatenar (*concat*) juntando todas as saídas e passar para o classificador.


(a) Arquitetura utilizando uma imagem de olho (Single Input)




(b) Arquitetura utilizando uma imagem do olho e os dados tabulados (Single Input Tabular)



(c) Arquitetura utilizando duas imagens do mesmo olho (Dual Input)



(d) Arquitetura utilizando duas imagens do mesmo olho e os dados tabulados (Dual Input Tabular)



Fonte: Imagem elaborada pelo autor.

Todos as arquiteturas de modelos citados na figura 3.7, representados por um retângulo e com exceção do *backbone*, é um modelo de múltiplas camadas (MLP). Os modelos *backbone*, com tradução literária de *espinha dorsal*, são os modelos principais e os utilizados para extrair os padrões mais importantes dos dados. No nosso caso, estes dados serão um conjunto de imagens de fundo de olho.

A primeira arquitetura (SI) 3.7a utilizará somente uma imagem do fundo do olho. Entre as arquiteturas citadas na figura 3.7 esta é a arquitetura mais simples e que utiliza a menor quantidade de recurso computacional. Além disso, temos a arquitetura que utiliza uma imagem do fundo de olho e os dados tabelados do OCT 3.7b. Esta segunda arquitetura junta os dados de imagens e os dados clínicos para trazer mais informações e consequentemente ajudar na classificação/diagnóstico da presença/ausência do glaucoma (SIT).


A terceira arquitetura (DI) 3.7c utiliza duas imagens do fundo de olho. Para que isso fosse possível, foi feita uma limpeza dos dados e uma avaliação manual de cada uma das fotos para cada paciente da base de dados. Escolhendo uma foto mais próxima e outra mais distante. A limpeza de dados é descrita e explicada na seção 4.2. A quarta e última arquitetura é a que utiliza duas imagens do fundo do olho e os dados clínicos. Esta é a arquitetura que utiliza mais recurso computacional, dado que o modelo de imagem é duplicado (*backbone*), utilizando o dobro de memória e adicionamos uma rede MLP para processar os dados clínicos (DIT).

Um **ponto de atenção**, a arquitetura de modelo utilizando somente uma imagem, seleciona aleatoriamente uma das duas imagens disponíveis para processar. Desta forma, este modelo aprende tanto a trabalhar com imagens mais próximas e mais distantes. Para o modelo que utiliza duas imagens, cada imagem passa por um *backbone* diferente. Logo, o mesmo padrão de imagem passa em cada um dos modelos, ou seja, imagens mais próximas são processadas por um modelo de imagem e imagens mais longes são processadas pelo segundo modelo de imagem. Desta forma, cada *backbone* fica responsável por aprender um padrão de cada uma das imagens. Isto é feito tanto no processo de treinamento do modelo quanto no processo de testagem e inferência, quando o modelo já está treinado e é utilizado.

3.5 Métricas de Avaliação

Para modelagem de diagnóstico na área médica, as métricas certas devem ser utilizadas para que possamos avaliar a qualidade do modelo com robustez. Neste projeto, as métricas utilizadas são:

Figura 3.8: AUC e curva ROC.



Fonte: [Ciencias e Negocios, 2020](#)

- Sensibilidade (SN): É a capacidade do modelo de ser assertivo ao fazer diagnósticos positivo quanto a presença do glaucoma no paciente.
- Especificidade (SP): É a capacidade do modelo em detectar todos os casos verdadeiros de glaucoma.
- Característica de Operação do Receptor (ROC): Esta curva ajuda os profissionais e desenvolvedores do modelo a escolher um limiar de corte entre sensibilidade e especificidade que esteja de acordo com o problema de negócio. Esta métrica é a mais importante e utilizada em diagnósticos, pois como citado anteriormente, é possível termos uma flexibilidade de acordo com a regra de negócio, dado mais importância para sensibilidade ou para especificidade [28].
- Área sob a curva ROC (AUC): Permite verificar o quão bom o classificador binário desempenha no problema. O cálculo é feito utilizando a área sob a curva ROC. Quanto maior este valor mais flexível o modelo consegue ser quanto a especificidade e sensibilidade. Esta métrica varia de 0 a 1, sendo o melhor modelo aquele que tem valor igual a 1.

Para selecionar o melhor modelo entre todos os experimentados, iremos utilizar a AUC como métrica principal, já que esta métrica consegue sumarizar, utilizando somente um número, o quão bom a curva ROC se encontra para cada um dos modelos. A figura 3.8 explica, de forma ilustrativa, como a curva ROC e a AUC funcionam. Em aplicações médicas, é mais válido trazer o maior número de verdadeiro positivos sem aumentar significativamente a taxa dos falsos positivos. Normalmente é mais prejudicial deixar de diagnosticar uma doença do que dar um diagnóstico positivo falso. Neste caso, o interesse maior é na sensibilidade. No entanto, se abaixarmos o threshold demais iremos ter bastante falso positivos, ou seja, muito casos para serem analisados pelos especialistas,

gerando um custo humano e de tempo 3.8a. As duas métricas, sensibilidade e especificidade, integrem entre si. Quando se aumenta uma, movimentando threshold, é possível que se perca desempenho na outra. Contudo, o valor da métrica AUC carrega consigo a informação de variação desse ganho e dessa perda, ou seja, quanto melhor o AUC mais fácil movimentar o threshold ganhando de um lado e abdicando menos do outro. O modelo perfeito, com 100% de AUC, na imagem da direita 3.8b, mostra que se movimentarmos o threshold não perderíamos nada, e seria possível capturar todos os casos verdadeiro sem nenhum caso de falso positivo. No entanto, é impossível construir um modelo perfeito, e normalmente os modelos ficam entre 50% e 100%.

3.6 RandAugment

Data Augmentation [46] é uma técnica de aumento do número de dados de forma sintética. Neste caso, operações são aplicadas na imagem de forma que novas imagens sejam criadas a partir das originais e por fim aumentando heterogeneidade do dados para modelagem. Com os dados mais heterogeneo é possível atingir desempenhos melhores para o modelo sem aumentar de forma exponencial o custo computacional (mais poder computacional) que por fim será refletido em custo real.

Para realizar o *Data Augmentation* utilizamos neste projeto o *RandAugment* [16]. De acordo com os autores, o *RandAugment* traz benefícios como: diminuir drasticamente o uso computacional pois não se utiliza políticas para escolher as operações a serem aplicadas nas imagens, mas sim uma probabilidade X de acontecer para cada um delas. Desta forma, é possível manter a diversidade das imagens e ter um custo baixo para isso. As transformações possíveis são: transformação identidade, auto-contraste, equalizador, rotação, solarização, cor tremida, mudança de contraste, mudança de brilho, posterização, mudança de formato, translações e cortes.

Uma decisão feita para a utilização do *RandAugment* é que ele só foi aplicado nos modelos que tiveram a melhor desempenho entre todos os outros. Evitando assim, que infinita combinações sejam testadas e ao mesmo tempo fosse possível avaliar o benefício da técnica.

3.7 Treinamento e Avaliação dos Modelos

Os modelos foram treinados e avaliados utilizando uma técnica conhecida como validação cruzada, do inglês *cross-validation*. A validação cruzada tem como objetivo avaliar a capacidade de generalização de um modelo a partir de um conjunto de dados. Busca-se então estimar o quão preciso é este modelo na prática, ou seja, o desempenho para um novo conjunto de dados. Dado isso, iremos utilizar o método K-Fold [50]. Os autores do artigo [7] citam que dentre o processo de treinamento e validação, a validação cruzada é uma das mais utilizadas.

O método K-Fold consiste em separar os dados em K partes, sendo que K-1 partes serão utilizadas para o treino do modelo e a parte restante será utilizada para validação do modelo. Em uma próxima iteração um novo grupo é selecionado para teste e os outros K-1 para treino, até que todos os grupos passem pela fase de teste. Com isto, é possível que o modelo seja avaliado com mais robustez e com variabilidade controlada.


A imagem 3.9 mostra como os dados são divididos. Existem dois conjuntos de dados que são AC (Amostras Conhecidas) e o AD (Amostras Desconhecidas). Dado isso, utilizando o conjunto AC aplicando a metodologia de validação cruzada, validando assim os melhores modelos. Em seguida, utilizados o conjunto AD para mensurar o desempenho do modelo. Este conjunto AD não entra nas iterações da validação cruzada, portando é possível avaliar a capacidade de generalização do modelo em dados que simulam os dados na etapa de inferência.

Além disso, para que não houvesse *overfitting* [25] do modelo utilizamos o *Early Stopping* para finalizar o treinamento quando o modelo não melhora seu desempenho durante um número E de épocas. Adicionado à isso, economizamos também no custo computacional. E por fim, foram salvos os melhores modelos para cada experimento de acordo com a métrica escolhida, **AUC**.

3.8 Explicabilidade: SHAP

O SHAP (Shapley Additive Explanations) é uma das ferramentas mais utilizadas quando o assunto é explicabilidade. O objetivo por trás do SHAP é trazer um entendimento quanto a decisão de modelos complexos, modelos antes conhecidos como caixa preta devido sua falta de interpretabilidade. Logo, modelos estatísticos como XGBoost, LightGBM e modelos profundos como redes neurais convolucionais (CNN) agora são

Figura 3.9: Imagem contendo ilustrando a validação cruzada. Cada parte assume o papel de teste uma vez e treino K-1 vezes.



Fonte: Elaborado pelo autor.

possíveis de serem entendidos ou interpretados [39].

A interpretação dos modelos trouxe uma forma inovadora de aplicar modelos de aprendizado de máquina, principalmente na área de saúde. O modelo interpretável traz informações extra para que o profissional seja capaz de tomar melhores decisões quanto ao problema que enfrenta.


Modelos foram propostos para diagnosticar e verificar a progressão da evolução da doença de Alzheimer [19]. Os autores aplicam o modelo SHAP para pegar as características que são mais críticas para o modelo. O modelo SHAP foi capaz de dar explicações sobre quais características mais impactam a progressão da doença. Além disso, o modelo também forneceu explicações individuais para cada um dos pacientes. E em seguida foi utilizado um sistema baseado em lógica fuzzy [61] e linguagem natural para poder criar um formulário que os médicos e os pacientes pudessem consumir a explicação do modelo.

Utilizando modelos mais simples, como Árvores de Decisão [48], Regressão Logística [15] e kNN [60] e modelos mais complexos, como SVM [52], XGBoost [13], e RF [11], os autores criaram um sistema de prognóstico da doença de hepatite [45]. Os autores utilizaram o modelo SHAP para verificar as variáveis mais importantes para os modelos, fornecem explicação para cada um dos pacientes e também geraram gráficos de dependência entre as variáveis de entrada e a rótulo dos dados (presença ou ausência de hepatite).

Utilizando modelos como XGBoost [13] para selecionar qual cirurgia refratária deve ser aplicada em um paciente [64]. A escolha certa de uma cirurgia aumenta a satisfação de um paciente ao final do processo. Antes da escolha da cirurgia, o paciente consulta um expert da área e em seguida 80 características da tomografia da cornea são extraídas, 40 características demográficas são coletadas e mais 22 características de exames oftalmológicos, como por exemplo diâmetro da pupila. Ao final, os autores fazem uma validação cruzada de 10 grupos e atinge uma acurácia média de 72% quanto a cirurgia a ser aplicada. Os autores também apresentam as características globais mais importantes e para cada um dos 3 exames aplicados: LASEK, LASIK, SMILE e contraindicação.

O shap utiliza o que chamamos de *Shapley Values* ou valores de *Shapley*. Os valores de *Shapley* é uma média ponderada da contribuição marginal de cada um das características [54]. Isto é caracterizado pelo impacto que cada um destas características tem no valor preditivo do modelo [56].

Figura 3.10: Gráfico resumido para o dataset Boston Housing ordenado pelas características mais importantes do modelo.




Fonte: [SHAP Github](#)

Na figura 3.10 representa um gráfico SHAP para previsão dos preços de moradias em Boston-MA. Se o ponto é azul a variável apresentação um valor baixo, se o ponto é vermelho ela apresenta um valor alto. Se o ponto está do lado direito quer dizer que aquele valor da variável contribui para a resposta seja positiva ou maior, se do lado esquerdo, negativa ou menor. Por exemplo, a variável mais importante é a **LSTAT**. É a proporção de adultos sem ensino superior e a proporção de trabalhadores braçal ou árduo masculinos em uma certa área. Significa que quanto maior essa proporção menor será um preço das casas na vizinhança. Enquanto a variável **RM** é a quantidade de quartos nas casas. Quanto mais quartos na casa maior será o valor atribuído para aquela residência.

No entanto, para imagens, o SHAP funciona um pouco diferente. Na figura 3.11 a explicabilidade do modelo fornece quais são as áreas das imagens mais importantes para identificação de um animal. Por exemplo, para o passarinho podemos observar que existem vários pontos vermelhos fortes na mesma área do bico, indicando dessa forma que essa parte foi uma das mais importantes para a identificação do passarinho.

Figura 3.11: Explicação de uma imagem utilizando SHAP. Os pontos vermelhos e azul mostram onde o modelo julgou como parte importante para a imagem. Seguindo a mesma lógica do 3.10, pontos vermelhos aumenta a probabilidade na saída do modelo, enquanto pontos azuis diminuem.



Fonte: [SHAP Github](#)

Capítulo 4

Sumário e Preprocessamento dos dados

4.1 Sumário dos dados

O dado recebido possui múltiplas imagens de fundo de olho para cada paciente. As imagens estão divididas para cada um dos olhos que foram feitos os exames. Foram recebidos um total de 492 pacientes e 887 olhos. Além disso, também está presente nos dados uma tabela contendo algumas informações do paciente e do exame OCT. Na tabela contém os seguintes dados:

- Dados demográficos: Nome, Idade, Gênero
- Presença ou ausência do glaucoma
- Indicação do olho examinado: esquerdo ou direito. Quando não há indicação, ambos os olhos foram examinados
- Medições de espessura das fibras retiradas do OCT: região nasal (N), nasal inferior (NI), nasal superior (NI), temporal (T), temporal inferior (TI), temporal superior (TS) e a média de todos os quadrantes (G).

Um exemplo na figura 4.1 contendo duas imagens do fundo dos olhos:

A primeira imagem 4.1a é mais distante quando comparada a segunda imagem 4.1b, que possui um zoom mais próximo do disco. Cada paciente testado aqui deve possuir pelo menos duas fotos similares à essa.


Portnato, na próxima seção, será descrito todo o processo de limpeza dos dados realizados como requisitos do experimentos executados neste projeto.

Figura 4.1: Duas imagens do fundo do olho com distâncias diferentes

(a) Imagem do fundo do olho distante do disco e copo



(b) Imagem do fundo do olho próxima do disco e copo



Fonte: Imagem extraída do conjunto de dados.

4.2 Limpeza

Antes da exploração e modelagem dos dados, o dado precisa ser padronizado para que todo o processo fique mais simples, automatizado e consistente. Em seguida, algumas manipulações manuais foram aplicadas aos dados:


- Verificação de duas vias: Verificar se o paciente está presente nos dados tabulares e se existe uma pasta contendo fotos do fundo dos olhos.
- Foi contabilizado o número de fotos para cada um dos pacientes, sendo assim, grande parte dos pacientes possuem pelo menos duas fotos para cada olho. Todos que tivessem uma foto ou nenhuma foram eliminados.
- Foram selecionadas, de forma manual, duas fotos para cada olho de cada paciente. Uma foto mais distante e uma segunda foto mais próxima, sem a parte marginal preta. As fotos foram renomeadas para indicar qual das duas imagens é a mais próxima ou distante, de forma que o modelo receba em cada uma das entradas o mesmo tipo de foto.
- Foram selecionados somente fotos com cores. Fotos preto e branco foram eliminadas.
- Alguns pacientes possuem diferentes datas de exames OCT e imagens do fundo do olhos. Dado isso, foi considerado as fotos que estão, em data, mais próximo do dado tabular contendo o dia que o exame foi realizado.

No total de 492 pacientes e 987 olhos, após a limpeza dos dados, restaram 476 pacientes e 858 olhos que serão utilizados na modelagem.


4.3 Exploração

Para entender melhor o problema é necessário que os dados sejam explorados e que a sua distribuição seja entendida. Nesta seção iremos avaliar os dados quanto as características presentes, como por exemplo, a correlação entre as espessuras das fibras e a presença do glaucoma, a presença do glaucoma quanto a idade e o gênero do paciente, e por fim, criar um entendimento sólido para dar base aos resultados que irão ser apresentados nas próxima seção.


Figura 4.2: Contagem de casos de glaucoma por gênero e por olhos




(a) total de pacientes por gênero



(b) total de pacientes com presença de glaucoma em 0(ausência), 1, 2



(c) Total de olhos com e sem glaucoma




(d) Total de olhos com ou sem glaucoma por gênero

Fonte: Elaborado pelo autor.

Como podemos observar nos histogramas da figura 4.2 é possível observar que temos mais casos de pessoas contendo glaucoma, dentro da base de dados recebida, em somente um dos olhos do que nos dois olhos. Além disso, temos a maior presença de pacientes do gênero feminino comparado ao masculino. Em proporção, a presença de glaucoma é maior em homens do que em mulheres. De acordo com Pesquisa Nacional Nacional de Saúde [47], as mulheres continuam sendo em maior proporção as pessoas que vão ao médico e procuram manter-se saudável. Com isto, o dado acima pode ser uma consequência dessa

Figura 4.3: Distribuição do Glaucoma por variável

Distribuição das dos dados numéricos baseado nas classes




Fonte: Elaborado pelo autor.

cultura, onde temos a maior presença feminina, no entanto, com proporções menores quanto a presença de glaucoma. Na seção de resultados, iremos observar se o modelo coloca a variável gênero como uma das principais para predição do glaucoma.

Os gráficos da figura 4.3 mostra a distribuição das variáveis do OCT quanto a presença de glaucoma ou não. Existe uma separação visível das distribuições das variáveis G, TS, N e TI quanto a presença de glaucoma. Outro ponto importante, é a presença das distribuições contendo caudas para esquerda ou para direita. Estes pontos provavelmente serão detectados pelo modelo mais facilmente.


Existe uma presença de valores atípicos mostrados na figura 4.4. A idade, como mostrado na figura, pode ser um bom separador, já que existe uma tendência a esquerda

Figura 4.4: Boxplot do Glaucoma por variável.



Fonte: Elaborado pelo autor.

Figura 4.5: Correlação absoluta das variáveis



Fonte: Elaborado pelo autor.

(menor idade) quando to a ausência do glaucoma. As variáveis TI, G e TS são as que mais distanciam os casos quanto a presença ou não do glaucoma. Existe uma possibilidade de que essas variáveis sejam umas das mais importantes dos modelos para aqueles que usam os dados OCT.

Existe uma forte correlação entre a variável TS e G 4.5. Sendo G uma média global, existe a possibilidade que a variável TS tenha uma influência forte na média. As variáveis que mais se correlacionam com a classe são: TS, TI e G. A seguir, uma sumarização dos dados após a limpeza:

Tabela 4.1: Tabela contendo sumarização dos dados utilizando as estatísticas: máximo, mínimo, média, desvio e contagem.

	Classe	G	T	NS	TS	N	NI	TI	Idade
count	758.00	758.00	758.00	758.00	758.00	758.00	758.00	758.00	758.00
mean	0.28	87.73	62.65	98.15	117.77	67.15	103.76	122.49	58.57
std	0.45	18.82	14.26	28.11	31.97	16.94	28.63	34.75	15.90
min	0.00	27.00	20.00	13.00	12.00	9.00	25.00	17.00	3.00
max	1.00	145.00	129.00	188.00	228.00	136.00	204.00	228.00	96.00

Fonte: Elaborado pelo autor.


4.4 Engenharia de características e Normalização

Quanto a engenharia de características, apenas uma operação matemática foi aplicada. Sabendo que uma das características importante para detecção do glaucoma é a razão entre o copo e o disco presente no fundo do olho, as características criadas é a razão entre as medições numéricas do exame do OCT [69]. Desta forma, cada caraterística numérica do OCT irá criar uma característica de razão entre pares com as outras. No total, 15 novas características foram criadas para serem utilizadas nos modelos. Além de serem características facilmente criadas, são fáceis de ser interpretadas pelos profissionais responsáveis ao analisar os resultados e a explicabilidade do modelo.

A normalização é um processo de redimensionar os valores das características numéricas para limites entre 0 e 1. A importância da normalização nas redes neurais está diretamente ligado ao fato de atualização dos pesos e otimização do modelo. Os algoritmos de otimização utilizam a descida gradiente para encontrar os melhores valores para diminuir o erro. Dentro da formula de descida gradiente, é utilizado os valores das características e da saída do modelo para em seguida os valores sejam somados ou subtraídos aos pesos e o modelo seja atualizado. Contudo, se os valores das características não forem normalizados e se dentro dos dados existem características com valores altos de magnitude diferentes, características com magnitudes maiores terão mais importância, o que não podemos assumir como verdade. Com isto, o ideal é que todas as caraterísticas tenham a mesma magnitude e o modelo escolhe a importância de cada um delas.

Foi uma comparação entre os modelos de redes neurais, modelos de árvore de decisão e modelos matemáticos como SVM e regressão logística [40]. Para os modelos que não são redes neurais, 22 características foram medidas utilizando um scanner OCT. Uma destas características é a razão entre o copo e o disco. Todas as características foram normalizadas antes de serem processadas pelos modelos de aprendizado de máquina. Um ponto importante que os autores citaram, e que também foi aplicado nesse projeto, é que a normalização foi calculada e mensurada utilizando os dados de treino e aplicadas

Figura 4.6: Correlação das características criadas pela operação razão.



Fonte: Elaborado pelo autor.

ao dados de teste. Desta forma, evita-se que haja qualquer tipo de vazamento de dados entre o conjunto de treino e teste.

Sendo assim, todas as variáveis numéricas como a idade, os medidas do exame OCT e as características derivadas do OCT mencionadas acima, foram normalizadas entre 0 e 1. Quanto ao gênero do paciente, foi utilizado 1 para o gênero masculino e 0 para o gênero feminino. Deste modo, o modelo consegue mensurar de forma o correto o impacto de cada um destas características.

A figura 4.6 mostra a correlação das características criadas sinteticamente com a operação de razão. Podemos observar que as duas características que mais apresentam

correlação com a classe (presença ou ausência de glaucoma) são: N/TI e T/TI . No capítulo de resultados [6](#), mais especificamente na seção de explicabilidade [6.2](#), será averiguado se alguma destas características criadas foram importantes para o modelo.

Capítulo 5

Experimentos

5.1 Setup

Todos os experimentos foram executados em uma máquina com processador i7-3770, 16 gigabytes¹ de ram e uma placa de video Nvidia RTX-3060 com 12 gigabytes de memória.

Dentre os *softwares*² utilizados estão as seguintes bibliotecas de Python³: *Pytorch*⁴, *Seaborn*⁵, *SHAP*⁶ e *Pandas*⁷. Para execução das análises foi utilizada o *Jupyter Notebook*⁸.

5.2 *Fine-Tunning*

Os modelos que foram utilizados como *backbones* são modelos que já foram treinados anteriormente com algum conjunto de dados de imagens, não necessariamente similar ao desse projeto. Dado isso, existem três formas mais utilizadas para fazer o treinamento para cada modelo. A primeira, conhecida como *scratch*, é um treinamento em que inicializamos os modelos com parâmetros de forma randômica e em seguida aplicamos nossos dados para que o modelo consiga aprender padrões do zero. O segundo método

¹Gigabyte (símbolo Gbyte, GB, G) é uma unidade de medida de informação, segundo o Sistema Internacional de Unidades S.I., que equivale a um bilhão (milhar de milhões) de bytes, ou seja, 1.000.000.000 bytes, ou ainda 10^9 bytes

²Software é um termo técnico que foi traduzido para a língua portuguesa como suporte lógico e trata-se de uma sequência de instruções a serem seguidas e/ou executadas, na manipulação, redirecionamento ou modificação de um dado (informação) ou acontecimento.

³<https://www.python.org/>

⁴<https://pytorch.org/>

⁵<https://seaborn.pydata.org/>

⁶<https://github.com/slundberg/shap>

⁷<https://pandas.pydata.org/>

⁸<https://jupyter.org/>

é conhecido como *feature extract* que é quando utilizamos os modelos *backbones*, com os pesos já treinados em um grupo de dados diferente, e queremos utilizar deste pesos e apenas adicionar uma nova camada (normalmente a última) que será adaptada para o nosso conjunto de dados. Neste caso, todo o treinamento será feito apenas nessa última camada adicionada, enquanto os pesos das redes neurais pretreinadas serão congelados. E existe um terceiro modo, conhecido como *fine-tunning*, onde iremos treinar todo o modelo pretreinado com os dados desejados.


Dos métodos citados acima, as literaturas apontam que o *fine-tunning* consegue desempenhar melhor em grande maioria das tarefas. Primeiro, para o caso de treinamento utilizando o método *scratch* é necessário um volume grande de dados, já que redes neurais convolucionais possuem um número grande de pesos ou parâmetros a serem treinados. Desta forma, quanto mais parâmetros mais dados são necessários para generalizar. Para o segundo caso de *feature extraction* o modelo preserva os pesos em que foi treinado originalmente e então é treinado somente a camada nova adicionada com o conjunto de dados que queremos utilizar. No entanto, o modelo não consegue se especializar já que teremos algumas poucas adaptações dos pesos para a tarefa que queremos aplicar, limitado em pequenas mudanças nesta última camada adicionada. Enquanto no terceiro caso, o *fine-tunning*, conseguimos aproveitar a complexidade do modelo treinado em um conjunto de dados mais volumoso e heterogêneo e ao mesmo tempo conseguimos adaptar este modelo para a tarefa que desejamos [37, 24, 5, 3, 65].

Logo, para este projeto, iremos utilizar somente o *fine-tunning* como método de treinamento dos modelos.

5.3 *Learning Rate Decay*

Learning Rate Decay (LRD) é uma técnica de treinamento de rede neurais. O modelo começa com taxa de aprendizagem e vai decaindo essa taxa múltiplas vezes durante o treinamento. Dessa maneira, o modelo começa atualizando os pesos mais rapidamente até que se chega em um certo ponto onde é necessário trabalhar com números menores e atualizações mais lentas. Dado isto, a taxa de aprendizagem do modelo irá diminuir, diminuindo os valores de atualização dos parâmetros e consequentemente atingindo valores melhores em desempenho.

Os seguintes trabalhos trazem um pouco do benefício do *learning rate decay* [66, 30]. A imagem na figura 5.1 mostra que em um certo momento os modelos ResNet-18 e ResNet-34 chegam em um platô onde o erro do modelo não decrementa. A partir deste momento, a taxa de aprendizagem é subtraída por um valor e em seguida, o modelo volta a melhorar

Figura 5.1: *Learning Rate Decay* aplicado a modelos visuais.

Fonte: [Towards Data Science](#)

sua desempenho. Com isso, o modelo com taxas menores consegue fazer ajustes mais finos, ou em outras palavras, dar passos menores.

5.4 Experimentação

Os experimentos foram divididos em etapas, da seguinte forma:

- Primeiro foram testados os seguintes modelos utilizando diferente configurações: Mobile, RegNet (X e Y), ShuffleNet, EfficientNet, Inception-V3, ResNet, e ViT. Cada um dos modelos citados anteriormente foram testados com 4 diferente otimizadores (Adam, RAdam, SGD, Ranger) de parâmetros e 4 valores de taxa de aprendizagem (0.01, 0.001, 0.0001, 0.0005). Ao final desta etapa, foram selecionado os melhores modelos de acordo com a métrica AUC para a próxima etapa. Além disso, esta etapa forneceu o melhor momento para aplicar o *Learning Rate Decay* e o *Early Stopping* para ser utilizado nas próximas etapas.

- Em seguida os melhores K modelos são testado, utilizando decaimento de taxa de aprendizagem e *Early Stopping* utilizando validação cruzada.
- Em seguida, os melhores M modelos dos K foram selecionados e é aplicado o *RandomAugment* 3.6 para trazer mais diversidade para os dados de treino e verificar o impacto, em questão de desempenho, do *Data Augmentation*

A partir do segundo passo, todos os testes foram feitos utilizando a metodologia validação cruzada citada anteriormente com parâmetro igual 5, ou seja, dividido em 5 grupos. A decisão de aplicar somente a partir do segundo passo é o número exponencial de modelos a serem treinados caso fosse aplicado desde primeiro passo. Em todas as etapas, o número de épocas padrão é 100.

Uma **observação** importante é sobre a separação dos dados de treino e teste. A separação deve acontecer a nível de paciente e não de olho, para que assim, um paciente não tenha dados de um olho no treino e dados de outro olho no teste. Desta modo, evitou-se que houvesse vazamento de dados e o modelo demonstre um desempenho irreal.

Tabela 5.1: Versões dos modelos visuais utilizados como Backbones e o total de parâmetros de cada um. O modelo ViT é o que possui maior número de parâmetros, aproximadamente 86 milhões, enquanto o modelo Shuffle possui somente 2.5 milhões.

<i>Backbone</i>	Parâmetros
RegNet800MFX	6.586.329
RegNet800MFY	5.648.297
RegNet1.6GFX	8.279.048
RegNet1.6GFY	10.314.319
RegNet3.2GFX	14.288.561
RegNet3.2GFY	17.824.851
MobileV3Large	4.203.313
Resnet50	23.510.081
EfficientNetb0	4.008.829
ShuffleNetV1X1.5	2.479.649
VitBase16_224	85.799.425
InceptionV3	24.346.082

Fonte: Elaborado pelo autor.

A tabela 5.1 possui a versão e o total de parâmetros dos modelos citados na seção 3.1 implementados dentro da biblioteca Pytorch⁹.

⁹Biblioteca Python de aprendizado de máquina

Capítulo 6

Resultados

Neste capítulo iremos apresentar os resultados. Na primeira seção iremos apresentar uma visão geral dos modelos quanto a desempenho relação a nossa métrica principal, AUC 3.5. Além disso, pela gráfico de perda (loss) teremos um ponto ideal para cada um dos modelos quanto a hora de aplicarmos a técnica de *Learning Rate Decay* 5.3 para conseguirmos uma desempenho ainda melhor nas próximas etapas.


6.1 Desempenho Geral

A figura 6.1 mostra como foi a desempenho geral dos modelos. Nota-se que os modelos utilizando os dados de OCT atingiram melhores resultados do que aqueles que não usa, tanto para modelos utilizando uma imagem quanto para modelos utilizando duas imagens. A distuição do modelo que não utiliza OCT é menos esparsa quanto aos resultados no teste, com exceção do ViT. Enquanto, os modelos utilizando OCT possuem uma variabilidade maior quanto ao desempenho. Este comportamento é encontrado quanto nos modelos utilizando uma ou duas imagens.

O gráfico 6.2 usa a média da AUC no treinamento e o valor máximo atingido para comparar os modelos. É perceptível que os modelos estão distribuídos de forma uniforme no gráfico quando comparamos os grupos. Os modelos RegNetY e RegNetX não sobrepõem quanto ao desempenho quando comparados juntos. Além disso, existe uma relação direta entre a média de AUC no treinamento e o valor máximo que essa atinge durante todo o processo, com raros casos de discrepância.

As tabelas 6.1 e 6.2 resumizam todas as execuções dos *backbone* em todas as arquiteturas discutidas 3.7. Quanto a máxima AUC atingida pelos modelos, todos estes tiveram valor próximo de 0.93. Quanto as arquiteturas testadas, podemos observar que a presença do OCT traz benefícios para o modelo, aumentando até em 12% o desem-

Figura 6.1: Avaliação geral dos modelos divididos em uso de duas imagens e presença das métricas do OCT. O gráfico violino mostra a distribuição dos valores máximos atingidos por cada *backbone*



Fonte: Elaborado pelo autor.

penho dos modelos. No entanto, não houve melhora dos modelos quando utilizamos uma ou duas imagens na arquitetura. Dito isso, foi limitado daqui pra frente o uso de modelos utilizando somente uma imagem de entrada.


A distribuição dos desempenhos apresentados na figura ?? mostra uma separação clara entre OCT e não. No entanto, como citado anteriormente não há diferença do modelo utilizando uma ou duas imagens. Dado isso, foi selecionado os melhores 5%, baseado na AUC, dos modelos usando uma image e uma imagem mais os dados de OCT. Para seleção foi utilizado o percentil¹ 95 e todos os modelos abaixo desse valor foram

¹Em estatística descritiva, os percentis são medidas que dividem a amostra (por ordem crescente dos dados) em 100 partes, cada uma com uma percentagem de dados aproximadamente igual. O k-ésimo percentil P_k é o valor x (x_k) que corresponde à frequência cumulativa de N .k/100, onde N é o tamanho

Figura 6.2: Comparação das estatísticas da métrica AUC. O eixo y é o melhor resultado do modelo durante todas as épocas, enquanto o eixo x é a média do modelo durante o treinamento.

(a) Comparação entre grupo de modelos Reg-Net e todos os outros.

(b) Comparação entre os modelos RegNet por si.



Fonte: Elaborado pelo autor.

Tabela 6.1: Valores médios, desvio padrão, mínimo e máximo, incluindo todas as arquiteturas visuais, dos modelos backbones em relação a AUC

backbone	val_best_auc				val_avg_auc			
	min	max	mean	std	min	max	mean	std
efficient	0.50	0.93	0.80	0.11	0.5	0.85	0.72	0.10
inception	0.50	0.94	0.79	0.14	0.5	0.86	0.70	0.12
mobile	0.50	0.93	0.79	0.11	0.5	0.84	0.69	0.10
regnet16x	0.50	0.93	0.79	0.10	0.5	0.86	0.71	0.09
regnet16y	0.50	0.94	0.79	0.11	0.5	0.87	0.71	0.09
regnet32x	0.50	0.94	0.79	0.11	0.5	0.87	0.71	0.10
regnet32y	0.52	0.93	0.80	0.10	0.5	0.86	0.71	0.09
regnetx	0.50	0.94	0.79	0.11	0.5	0.86	0.71	0.09
regnety	0.51	0.93	0.78	0.11	0.5	0.85	0.70	0.09
resnet	0.50	0.95	0.79	0.10	0.5	0.87	0.70	0.10
shuffle	0.50	0.95	0.80	0.09	0.5	0.88	0.70	0.10
vit	0.50	0.92	0.75	0.15	0.5	0.85	0.67	0.12

filtrados. Ao final, restaram um total 28 modelos.

E por último, o gráfico ?? da função de custo durante o treinamento. O gráfico mostrou uma média global de todos os modelos treinados com um intervalo de confiança de 0.95. O gráfico mostra que a partir da época 30 o modelo não consegue ter uma melhoria no seu desempenho. Portanto, é nesse momento que aplicamos o *Early Stopping* e o *Learning Rate Decay* para próxima fase de experimentos utilizando validação cruzada.

amostral.

Tabela 6.2: Valores médios, desvio padrão, mínimo e máximo, incluindo todas as arquiteturas dos modelos, separado por uso de duas imagens e OCT

Dual Image	Usando OCT	val_best_auc				val_avg_auc			
		min	max	mean	std	min	max	mean	std
Não	Não	0.5	0.85	0.75	0.08	0.5	0.74	0.66	0.07
	Sim	0.5	0.95	0.85	0.10	0.5	0.88	0.75	0.10
Sim	Não	0.5	0.85	0.74	0.11	0.5	0.77	0.66	0.09
	Sim	0.5	0.95	0.83	0.11	0.5	0.87	0.74	0.10




Figura 6.3: Distribuição dos desempenhos separado por arquiteturas de modelos




Figura 6.4: Comportamento da função de custo durante as épocas de treinamento. O gráfico mostra um valor médio e um intervalo de confiança de 0.95




Figura 6.5: Comparação do uso do *Learning Rate Decay* nos melhores modelos. Os melhores modelos da etapa anterior foram re-executados utilizando validação cruzada para uma comparação justa.

6.1.1 Validação Cruzada e *Learning Rate Decay*

Nesta seção iremos avaliar os melhores modelos selecionados na etapa anterior e verificar seu desempenho utilizando a validação cruzada [50]. O total de grupos para experimento foi igual 5, ou seja, cada configuração de hiperparâmetros gerou 5 modelos diferentes, totalizando 140 modelos, com seus respectivos desempenhos. Além disso, será ilustrada uma comparação entre a utilização do *Learning Rate Decay* utilizando validação cruzada.

A seguir ??, a tabela contendo os hiperparâmetros e os *backbones* dos modelos testados. O campo **Usando OCT** se refere a usar os dados do exame OCT junto com o modelo de imagem. Dentre os melhores modelos, a família de modelos RegNet aparece em 16 dos 18 melhores modelos. Isso mostra que o RegNet além ter um desempenho bom, é também um modelo a ser escolhido na tentativa de executar uma tarefa de visão computacional. As várias versões do modelo que aparece, mostra que este modelo é flexível e pode ser utilizado em diferentes contextos, com diferentes disponibilidades de recursos.

A figura ?? mostra a distribuição do desempenho dos modelos testados. O *Learning Rate Decay* trouxe uma melhora significativa para as duas arquiteturas. Apesar de ter aumentando a variabilidade da AUC, a técnica trouxe benefícios positivos quanto a métrica. O salto maior foi para a arquitetura de modelos utilizando somente imagem.

Quanto ao uso de memória e tempo de inferência, é possível observar que o modelos RegNets possuem tempo de inferência menor quando comparado aos modelos mais complexos ou até mesmo com os mais simples, como é no caso no ShuffleNet. Isto proporciona flexibilidade para que o modelo RegNet possa ser utilizado em diferente contextos

Tabela 6.3: Resultados comparando a utilização do Learning Decay(ld) e sua ausência nas métricas de AUC, especificidade(sp) e sensibilidade(sn)

idx_avg_sp_val_ld backbone	optim idx_avg_sn_val	lr idx_avg_sn_val_ld	output_tab	val_best_auc	val_best_auc_ld
regnet16x 0.913	radam NaN	0.001 0.722	0.0	0.792	0.899
regnet16x 0.906	radam NaN	0.000 0.695	0.0	0.828	0.888
inception 0.891	ranger NaN	0.000 0.670	0.0	0.810	0.859
inception 0.880	sgd NaN	0.010 0.633	0.0	0.812	0.811
inception 0.923	ranger NaN	0.001 0.666	0.0	0.812	0.899
regnet32x 0.905	radam NaN	0.001 0.706	0.0	0.849	0.882
resnet 0.993	adam NaN	0.010 0.353	5.0	0.939	0.943
resnet 0.969	ranger NaN	0.010 0.702	5.0	0.937	0.961
regnet32y 0.951	adam NaN	0.000 0.842	5.0	0.930	0.945
regnet32y 0.989	adam NaN	0.010 0.501	5.0	0.926	0.937
mobile 0.946	radam NaN	0.010 0.839	5.0	0.926	0.928
shuffle 0.963	ranger NaN	0.010 0.907	5.0	0.949	0.981
shuffle 0.924	radam NaN	0.001 0.728	5.0	0.934	0.926
shuffle 0.927	ranger NaN	0.001 0.663	5.0	0.932	0.903
shuffle 0.976	radam NaN	0.010 0.897	5.0	0.932	0.989
regnetx 0.968	adam NaN	0.010 0.900	5.0	0.926	0.984
regnetx 0.967	adam NaN	0.001 0.860	5.0	0.915	0.986
regnetx 0.968	radam NaN	0.010 0.897	5.0	0.932	0.986
regnet16y 0.947	ranger NaN	0.010 0.833	5.0	0.932	0.973
regnet16y 0.991	adam NaN	0.010 0.335	5.0	0.939	0.939
regnet16y 0.973	radam NaN	0.010 0.893	5.0	0.934	0.989
efficient 0.960	adam NaN	0.010 0.734	5.0	0.928	0.979
regnet32x	radam	0.010	5.0	0.926	0.986

que é necessário uma resposta rápida, como por exemplo quadros de um video ou em algum sistema nuvem que recebe milhares de requisições ao mesmo tempo. Quanto ao uso de memória, os modelos RegNets apresentam várias versões com diferentes uso de recursos computacionais. Variando de 1600 megabytes até 4182, o modelo consegue apresentar desempenho mesmo no modelo com menor uso, até mesmo que o mobile (1662), ultrapassando modelos mais caros como por exemplo inception (4722). Com tudo, os modelos acima ainda consegue oferecer desempenhos satisfatórios para o caso de uso de uma imagem e de image somados ao exame OCT.

6.1.2 *RandAugment*

Dado os resultados da seção anterior, foram selecionados 3 modelos para aplicar *data augmentation*. Um dos hiperparâmetros do *RandAugment* é o nome de operações sequenciais em uma foto. Por esse motivo, foram testados diferentes valores para este hiperparâmetro: 1, 2, 3 e 4. Nesta etapa também foi utilizada validação cruzada para avaliar o modelo.

A tabela acima mostra que o *RandAugment* não trouxe melhoras significativas para o modelo. O resultado foi inverso do esperado, diminuindo o desempenho dos modelos, tanto na métrica de AUC quanto nas métricas de especificidade(sp) e sensibilidade(sn).

6.2 Explicabilidade

Nesta seção iremos trazer a explicabilidade dos melhores modelos. O objetivo é entender a interação do modelos com os dados, tanto de imagen quanto os tabulares, para então seja possível entender o porque da decisão do modelo. Iremos avaliar tanto as imagens do fundo do olho e verificar quais foram as partes cruciais das imagens, quanto os valores tabelados contendo as medições e as características criadas e descritas na seção 4.4.

6.2.1 Compara arquitetura 1 olho e dois olhos

6.2.2 1 olho e 1 olho + tabular

6.2.3 Importância média das features tab

6.2.4 Caso positivo e negativo

Capítulo 7

Conclusão

Ao final do projeto foi perceptível como os modelos RegNet conseguem ser flexíveis em todos os contextos. O modelo apresentou desempenho ótimo em diferentes arquiteturas de modelos. Dentre os melhores modelos, o modelo RegNet é o que mais aparece com suas diferentes versões quanto ao uso de memória e ao número de parâmetros. Contudo, a escolha do modelo RegNet proporciona uma maior probabilidade de se obter um desempenho na detecção do glaucoma utilizando imagens do fundo do olho e do exame OCT. Além disso, o modelo também apresenta um custo computacional (memória) menor em vários casos e ao mesmo tempo sobresaindo em desempenho, inclusive quanto ao tempo de inferência. Dado isso, é possível que o modelo RegNet seja uma escolha sólida em tarefas de visão computacional que exige eficiência, eficácia e flexibilidade ao mesmo tempo.

O *Rand Augmentation* não mostrou benefícios quanto ao desempenho do modelo ou ao menos quanto sua variabilidade. No entanto, apesar de não ter sido um sucesso neste projeto, este tipo de técnica não deve ser descartada já que aqui não foram testados todas as combinações de hiperparâmetros e modelagens possíveis devido ao limitante computacional. Por outro lado, a técnica de *Learning Rate Decay* apresentou benefícios para os modelos, aumentando seu desempenho quanto a métrica AUC.

Referências Bibliográficas

- [1] The pathophysiology and treatment of glaucoma: A review, 2014.
- [2] As condições de saúde ocular no brasil, 2019.
- [3] Pulkit Agrawal, Ross B. Girshick, and Jitendra Malik. Analyzing the performance of multilayer neural networks for object recognition. *ArXiv*, abs/1407.1610, 2014.
- [4] Ioannis D. Apostolopoulos, Dimitris I. Apostolopoulos, Trifon I. Spyridonidis, Nikolaos D. Papathanasiou, and George S. Panayiotakis. Multi-input deep learning approach for cardiovascular disease diagnosis using myocardial perfusion imaging and clinical data. *Physica Medica*, 84:168–177, 2021.
- [5] Hossein Azizpour, Ali Sharif Razavian, Josephine Sullivan, Atsuto Maki, and Stefan Carlsson. Factors of transferability for a generic convnet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38:1790–1802, 2016.
- [6] baidaa al bander, waleed al nuaimy, bryan m. williams, and yalin zheng. multiscale sequential convolutional neural networks for simultaneous detection of fovea and optic disc. *biomedical signal processing and control*, 40:91–101, 2018.
- [7] Daniele Barros, Julio Moura, Cefas Freire, Alexandre Taleb, Ricardo Valentim, and Philippi Moraes. Machine learning applied to retinal image processing for glaucoma detection: Review and perspective. *BioMedical Engineering OnLine*, 19, 04 2020.
- [8] Daniele M. S. Barros, Julio C. C. Moura, Cefas R. Freire, Alexandre C. Taleb, Ricardo A. M. Valentim, and Philippi S. G. Moraes. Machine learning applied to retinal image processing for glaucoma detection: review and perspective. *BioMedical Engineering OnLine*, 19(1):20, Apr 2020.
- [9] Yuemin Bian, Junmei Wang, Jaden Jungho Jun, and Xiang-Qun Xie. Deep convolutional generative adversarial network (dcgan) models for screening and design of small molecules targeting cannabinoid receptors. *Molecular Pharmaceutics*, 16(11):4451–4460, Nov 2019.
- [10] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, Oct 2001.
- [11] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

- [12] Claude Burgoyne, J. Downs, Anthony Bellezza, Jun-Kyo Suh, and Richard Hart. The optic nerve head as a biomechanical structure: A new paradigm for understanding the role of iop-related stress and strain in the pathophysiology of glaucomatous optic nerve head damage. *Progress in retinal and eye research*, 24:39–73, 02 2005.
- [13] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. *CoRR*, abs/1603.02754, 2016.
- [14] Gabriel Costa, Anselmo Paiva, Geraldo Braz Júnior, and Marco Ferreira. Covid-19 automatic diagnosis with ct images using the novel transformer architecture. In *Anais do XXI Simpósio Brasileiro de Computação Aplicada à Saúde*, pages 293–301, Porto Alegre, RS, Brasil, 2021. SBC.
- [15] David R Cox. The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B (Methodological)*, 20(2):215–232, 1958.
- [16] Ekin D. Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V. Le. Randaugment: Practical data augmentation with no separate search. *CoRR*, abs/1909.13719, 2019.
- [17] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009.
- [18] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *CoRR*, abs/2010.11929, 2020.
- [19] Shaker El-Sappagh, Jose M. Alonso, S. M. Riazul Islam, Ahmad M. Sultan, and Kyung Sup Kwak. A multilayer multimodal detection and prediction model based on explainable artificial intelligence for alzheimer’s disease. *Scientific Reports*, 11(1):2660, Jan 2021.
- [20] Hitendra Garg, Neeraj Gupta, Rohit Agrawal, Shivendra Shivani, and Bhisham Sharma. A real time cloud-based framework for glaucoma screening using efficientnet. *Multimedia Tools and Applications*, 81(24):34737–34758, Oct 2022.
- [21] David F. Garway-Heath, Gerassimos Lascaratos, Catey Bunce, David P. Crabb, Richard A. Russell, and Ameet Shah. The united kingdom glaucoma treatment study: A multicenter, randomized, placebo-controlled clinical trial: Design and methodology. *Ophthalmology*, 120(1):68–76, 2013.
- [22] Leon A. Gatys, Alexander S. Ecker, and Matthias Bethge. A neural algorithm of artistic style. *CoRR*, abs/1508.06576, 2015.

- [23] Timnit Gebru, Jonathan Krause, Yilun Wang, Duyun Chen, Jia Deng, Erez Lieberman Aiden, and Li Fei-Fei. Using deep learning and google street view to estimate the demographic makeup of neighborhoods across the united states. *Proceedings of the National Academy of Sciences*, 114(50):13108–13113, 2017.
- [24] Ross B. Girshick, Jeff Donahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. *2014 IEEE Conference on Computer Vision and Pattern Recognition*, pages 580–587, 2014.
- [25] Ian J. Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, Cambridge, MA, USA, 2016. <http://www.deeplearningbook.org>.
- [26] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks, 2014.
- [27] Yuki Hagiwara, Joel En Wei Koh, Jen Hong Tan, Sulatha V. Bhandary, Augustinus Laude, Edward J. Ciaccio, Louis Tong, and U. Rajendra Acharya. Computer-aided diagnosis of glaucoma using fundus images: A review. *Computer Methods and Programs in Biomedicine*, 165:1–12, 2018.
- [28] Karimollah Hajian-Tilaki. Receiver operating characteristic (roc) curve analysis for medical diagnostic test evaluation. *Caspian journal of internal medicine*, 4:627–635, 09 2013.
- [29] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *CoRR*, abs/1512.03385, 2015.
- [30] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *CoRR*, abs/1512.03385, 2015.
- [31] Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. Mobilenets: Efficient convolutional neural networks for mobile vision applications. *CoRR*, abs/1704.04861, 2017.
- [32] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. *CoRR*, abs/1709.01507, 2017.
- [33] Diederik Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *International Conference on Learning Representations*, 12 2014.
- [34] Seung Hoon Lee, Seunghyun Lee, and Byung Cheol Song. Vision transformer for small-size datasets. *CoRR*, abs/2112.13492, 2021.

- [35] Lili Li, Shujuan Zhang, and Bin Wang. Apple leaf disease identification with a small and imbalanced dataset based on lightweight convolutional networks. *Sensors (Basel)*, 22(1):173, December 2021.
- [36] Zhixi Li, Yifan He, Stuart Keel, Wei Meng, Robert T. Chang, and Mingguang He. Efficacy of a deep learning system for detecting glaucomatous optic neuropathy based on color fundus photographs. *Ophthalmology*, 125(8):1199–1206, 2018.
- [37] Zhizhong Li and Derek Hoiem. Learning without forgetting. *CoRR*, abs/1606.09282, 2016.
- [38] Shuying Liu and Weihong Deng. Very deep convolutional neural network based image classification using small training sample size. In *2015 3rd IAPR Asian Conference on Pattern Recognition (ACPR)*, pages 730–734, 2015.
- [39] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 4765–4774. Curran Associates, Inc., 2017.
- [40] Stefan Maetschke, Bhavna Antony, Hiroshi Ishikawa, Gadi Wollstein, Joel Schuman, and Rahil Garnavi. A feature agnostic approach for glaucoma detection in OCT volumes. *PLoS One*, 14(7):e0219126, July 2019.
- [41] Felipe A Medeiros, Alessandro A Jammal, and Atalie C Thompson. From machine to machine: An OCT-trained deep learning algorithm for objective quantification of glaucomatous damage in fundus photographs. *Ophthalmology*, 126(4):513–521, April 2019.
- [42] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharmashan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, Feb 2015.
- [43] Kenichi Nakahara, Ryo Asaoka, Masaki Tanito, Naoto Shibata, Keita Mitsuhashi, Yuri Fujino, Masato Matsuura, Tatsuya Inoue, Keiko Azuma, Ryo Obata, and Hiroshi Murata. Deep learning-assisted (automatic) diagnosis of glaucoma using a smartphone. *British Journal of Ophthalmology*, 106(4):587–592, 2022.
- [44] Sejong Oh, Yuli Park, Kyong Jin Cho, and Seong Jae Kim. Explainable machine learning model for glaucoma diagnosis and its interpretation. *Diagnostics*, 11(3), 2021.

- [45] Junfeng Peng, Kaiqiang Zou, Mi Zhou, Yi Teng, Xiongyong Zhu, Feifei Zhang, and Jun Xu. An explainable artificial intelligence framework for the deterioration risk prediction of hepatitis patients. *Journal of medical systems*, 45(5):61–61, 2021.
- [46] Luis Perez and Jason Wang. The effectiveness of data augmentation in image classification using deep learning, 2017.
- [47] PNS. Pesquisa nacional de saúde. Disponível em: <https://www.ibge.gov.br/estatisticas/sociais/saude/9160-pesquisa-nacional-de-saude.html?t=sobre>. Acesso em 08 de outubro de 2022, 2019.
- [48] J. R. Quinlan. Induction of decision trees. *Machine Learning*, 1:81–106, 1986.
- [49] Ilija Radosavovic, Raj Prateek Kosaraju, Ross B. Girshick, Kaiming He, and Piotr Dollár. Designing network design spaces. *CoRR*, abs/2003.13678, 2020.
- [50] Sebastian Raschka. Model evaluation, model selection, and algorithm selection in machine learning. *CoRR*, abs/1811.12808, 2018.
- [51] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael S. Bernstein, Alexander C. Berg, and Li Fei-Fei. Imagenet large scale visual recognition challenge. *CoRR*, abs/1409.0575, 2014.
- [52] Sebastian Schlag, Matthias Schmitt, and Christian Schulz. Faster support vector machines. *CoRR*, abs/1808.06394, 2018.
- [53] Ursula Schmidt-Erfurth, Amir Sadeghipour, Bianca S. Gerendas, Sebastian M. Waldstein, and Hrvoje Bogunović. Artificial intelligence in retina. *Progress in Retinal and Eye Research*, 67:1–29, 2018.
- [54] L.S. Shapley and A.E. Roth. *The Shapley value: essays in honor of Lloyd S. Shapley*. Cambridge University Press, 1988.
- [55] Jaemin Son, Joo Young Shin, Hoon Dong Kim, Kyu-Hwan Jung, Kyu Hyung Park, and Sang Jun Park. Development and validation of deep learning models for screening multiple abnormal findings in retinal fundus images. *Ophthalmology*, 127(1):85–94, 2020.
- [56] Erik Štrumbelj and Igor Kononenko. Explaining prediction models and individual predictions with feature contributions. *Knowledge and Information Systems*, 41(3):647–665, Dec 2014.
- [57] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. *CoRR*, abs/1512.00567, 2015.

- [58] Raquel Sánchez-Cauce, Jorge Pérez-Martín, and Manuel Luque. Multi-input convolutional neural network for breast cancer detection using thermal images and clinical data. *Computer Methods and Programs in Biomedicine*, 204:106045, 2021.
- [59] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. *CoRR*, abs/1905.11946, 2019.
- [60] Kashvi Taunk, Sanjukta De, Srishti Verma, and Aleena Swetapadma. A brief review of nearest neighbor algorithm for learning and classification. In *2019 International Conference on Intelligent Computing and Control Systems (ICCS)*, pages 1255–1260, 2019.
- [61] Michael Voskoglou. A study on fuzzy systems. *American Journal of Computational and Applied Mathematics*, 2, 12 2012.
- [62] Jing Xu, Yu Pan, Xinglin Pan, Steven Hoi, Zhang Yi, and Zenglin Xu. Regnet: Self-regulated network for image classification, 2021.
- [63] Peng Yao, Shuwei Shen, Mengjuan Xu, Peng Liu, Fan Zhang, Jinyu Xing, Pengfei Shao, Benjamin Kaffenberger, and Ronald X. Xu. Single model deep learning on imbalanced small datasets for skin lesion classification. *CoRR*, abs/2102.01284, 2021.
- [64] Tae Keun Yoo, Ik Hee Ryu, Hannuy Choi, Jin Kuk Kim, In Sik Lee, Jung Sub Kim, Geunyoung Lee, and Tyler Hyungtaek Rim. Explainable Machine Learning Approach as a Tool to Understand Factors Used to Select the Refractive Surgery Technique on the Expert Level. *Translational Vision Science Technology*, 9(2):8–8, 02 2020.
- [65] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In *NIPS*, 2014.
- [66] Kaichao You, Mingsheng Long, Michael I. Jordan, and Jianmin Wang. Learning stages: Phenomenon, root cause, mechanism hypothesis, and implications. *CoRR*, abs/1908.01878, 2019.
- [67] Camila Zangalli, Shelly Gupta, and George Spaeth. The disc as the basis of treatment for glaucoma. *Saudi journal of ophthalmology : official journal of the Saudi Ophthalmological Society*, 25:381–7, 10 2011.
- [68] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, and Jian Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices. *CoRR*, abs/1707.01083, 2017.
- [69] R. Zhao, X. Chen, X. Liu, Z. Chen, F. Guo, and S. Li. Direct Cup-to-Disc Ratio Estimation for Glaucoma Screening via Semi-Supervised Learning. *IEEE J Biomed Health Inform*, 24(4):1104–1113, Apr 2020.

-
- [70] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. Unet++: A nested u-net architecture for medical image segmentation. *CoRR*, abs/1807.10165, 2018.
 - [71] Chengzhang Zhu, Beiji Zou, Rongchang Zhao, Jinkai Cui, Xuanchu Duan, Zailiang Chen, and Yixiong Liang. Retinal vessel segmentation in colour fundus images using extreme learning machine. *Computerized Medical Imaging and Graphics*, 55:68–77, 2017. Special Issue on Ophthalmic Medical Image Analysis.
 - [72] Barret Zoph and Quoc V. Le. Neural architecture search with reinforcement learning. *CoRR*, abs/1611.01578, 2016.